

An Integrated Multiaxial Model for Computer-Assisted Psychiatric Diagnosis

Synthesis of DSM-5-TR, ICD-11, and ICF
in a 6-Axis Decision Support System

A Methods and Design Paper

Lukas Geiger^{*1}

¹Independent Researcher, Bernau

June 2026

Abstract

The abolition of the multiaxial diagnostic system in DSM-5 (2013) left a structural gap in psychiatric diagnostics. This paper presents a 6-axis model for computer-assisted multiaxial diagnosis that unifies categorical classification according to DSM-5-TR and ICD-11 with the functional assessment of the ICF in a decision support system. The model comprises: Axis I (Mental Health Profiles with temporal diagnostics and quantitative coverage analysis), Axis II (dimensional personality assessment via PID-5 and biographical contextualization), Axis III (Medical Synopsis in symmetric parallel structure to Axis I), Axis IV (ICF integration, WHODAS 2.0, Cultural Formulation), Axis V (operationalized case formulation in a 3P/4P model), and Axis VI (evidence matrix, CAVE alerts, longitudinal symptom tracking). Three central design contributions are highlighted: (1) the quantitative coverage analysis (Diagnostic Coverage Index) as a percentage-based metric for diagnostic completeness, (2) the symmetric Axis I/III architecture for multi-professional collaboration, and (3) the operationalized connection between classification and individualized case formulation. The 6-step gatekeeper logic maps the differential diagnosis sequence published by First (2024). A Python reference implementation as a hierarchical state machine is publicly available. This is a methods and design paper; empirical validation is still pending.

Keywords: Multiaxial Diagnosis, DSM-5-TR, ICD-11, Coverage Analysis, Decision Support System, HiTOP, HL7 FHIR, Case Formulation, ICF

^{*}Correspondence: Lukas Geiger, Bernau, Germany. ORCID: [0009-0005-7296-1534](https://orcid.org/0009-0005-7296-1534)

Contents

Declaration on the Use of AI-Assisted Tools	3
1 Methods	4
2 Introduction: The Diagnostic Gap After the Abolition of the Multiaxial System	5
2.1 Institutional Convergence	7
2.2 Design Philosophy: Skeleton, Living Document, Maximum Freedom	7
3 Architecture of the 6-Axis Model	8
3.1 Axis I: Mental Health Profiles — Temporal Diagnostics	9
3.2 Axis II: Biography and Dimensional Personality	10
3.3 Axis III: Medical Synopsis — Symmetric Parallel Structure to Axis I	11
3.4 Axis IV: Environment and Functioning — ICF Integration and Cultural Formulation	12
3.4.1 Contact Persons and Treatment Network	13
3.4.2 Cultural Formulation Interview (CFI)	13
3.5 Axis V: Integrated Condition Model — Operationalized Case Formulation	13
3.6 Axis VI: Evidence Collection, CAVE Alerts, and Symptom Course	14
3.7 Multi-Professional Team Assignment	15
3.8 Comorbidity Rules and Diagnostic Hierarchy	15
3.9 Complete Sub-Axis Inventory	16
4 The 6-Step Gatekeeper Logic	18
5 Cross-Cutting Screening	20
5.1 Child and Adolescent Version	20
5.2 Comprehensive Screening Instrument Matrix	20
6 Critical Divergences Between DSM-5-TR and ICD-11	21
6.1 Schizophrenia Duration	21
6.2 PTSD Architecture	21
6.3 Personality Disorders	23
6.4 Gaming Disorder	23
6.5 Prolonged Grief Disorder	23
7 The Coverage Analysis: A Proposed Approach	23
7.1 Formal Definition of Coverage Analysis	23
7.2 Threshold Rationale and Sensitivity	24
7.3 Implementation	24
8 Dimensional Integration: HiTOP and RDoC as Complementary Perspectives	25
8.1 HiTOP (Hierarchical Taxonomy of Psychopathology)	25
8.2 RDoC (Research Domain Criteria)	26
9 Technical Architecture of the Python Implementation	26
9.1 Hierarchical State Machines as Decision Engine	26
9.2 Recommended Technology Stack	28
9.3 Open-Source Reference Implementation	28
10 Functional Assessment: Bridge Between Diagnosis and Disability	28
11 Illustrative Case Vignette	28
12 Ethics, Data Protection, and Algorithmic Bias	30
12.1 Algorithmic Bias and Validation Populations	30
12.2 Data Protection and GDPR	30
12.3 Informed Consent and Patient Autonomy	30
12.4 Liability and Medico-Legal Responsibility	31
12.5 Clinical Responsibility and Epistemic Boundaries	32
13 Validation Strategy	32
14 Interoperability and Health IT Standards	34

15 Discussion and Outlook	35
16 Limitations and Future Research Needs	37
17 Conclusion	38

Declaration on the Use of AI-Assisted Tools

Generative AI tools were used as non-authorial aids for literature organization, text structuring, translation support, linguistic revision, consistency checks, and LaTeX/PDF quality assurance. Their outputs were treated as provisional suggestions and were checked, revised, or rejected by the author. They did not serve as authors, co-authors, acknowledgement recipients, factual authorities, or independent validators. The research design, source selection, scientific argumentation, clinical interpretation, final editorial decisions, and responsibility for the manuscript remain solely with the author.

1 Methods

This paper follows a design science methodology for the development of a clinical decision support artifact. The research process comprised four phases:

Phase 1: Problem identification and requirements analysis. A structured literature review on the abolition of the DSM-IV multi-axial system identified five specific clinical deficits: loss of the structured prompt for biopsychosocial assessment, poor GAF inter-rater reliability, inconsistent Axis IV usage, the artificial Axis I/II boundary, and the low adoption rate of replacement V/Z codes. Requirements were derived from these deficits, from First's (2024) reference framework for differential diagnosis, and from current dimensional approaches (HiTOP, RDoC, ICD-11 dimensional personality model).

Phase 2: Iterative design. The 6-axis architecture was developed through iterative cycles of design and refinement. Design decisions—such as the symmetric Axis I/III structure, the coverage analysis concept, and the CAVE alert system—were evaluated against the identified requirements. Each iteration was documented and versioned (V1–V5). It should be noted that the design process did not include a formal expert panel; the iterative refinement was primarily conducted by the author with AI-assisted consistency checking. A formal expert review is planned as Phase 1 of the validation strategy (Section 13).

Phase 3: Prototypical implementation. A Python reference implementation (approx. 1,850 lines) using hierarchical state machines (`transitions` library) and a Streamlit interface was developed to demonstrate feasibility. The source code is publicly available in the [project repository on GitHub](#).

Phase 4: AI-assisted process support. The author used generative AI tools for non-authorial support in literature organization, text structuring, linguistic revision, and consistency checking. All generated suggestions remained subject to authorial review; AI-assisted work did not replace empirical validation or expert review. The scientific responsibility for all content lies with the author.

Scope and limitations of the present paper. This is a methods and design paper. It presents the architecture, rationale, and prototypical implementation of the 6-axis model. Empirical validation (inter-rater reliability, clinical utility, convergent validity) is planned in four phases (Section 13) but has not yet been conducted. The coverage analysis thresholds (85%/60%) are proposed as initial values based on clinical reasoning and require empirical calibration in future studies. Following design science methodology (Hevner et al., 2004; Peffers et al., 2007), the formal evaluation phase of the artifact is still pending; the validation strategy described in Section 13 outlines the planned evaluation framework.

Table 1: Comparison of computer-assisted diagnostic systems: OPCRIT (McGuffin et al., 1991), CATEGO (Wing et al., 1974), DTREE (First et al., 1993), CIDI (Kessler and Üstün, 2004), MHIRA (Zimmermann et al., 2023). DTREE and CIDI entries are based on published documentation. Note: All existing systems have empirical validation, which is still pending for the present model.

Feature	OPCRIT	CATEGO	DTREE	CIDI	MHIRA	Present Model
Multiaxial structure	No	No	No	No	No	Yes (6 axes)
Dual coding (DSM/ICD)	Partial	ICD only	DSM/ICD	DSM/ICD	Flexible	Full
Coverage analysis	No	No	No	No	No	Yes
Dimensional integration	No	No	No	No	Partial	Yes (HiTOP)
FHIR interoperability	No	No	No	No	Partial	Planned
Empirical validation	Yes	Yes	Yes	Yes (ext.)	Partial	Planned

2 Introduction: The Diagnostic Gap After the Abolition of the Multi-axial System

The abolition of the multiaxial diagnostic system in DSM-5 (APA, 2013) left a structural gap in psychiatric diagnostics. The original system introduced with DSM-III (APA, 1980) comprised five axes: Axis I (clinical disorders), Axis II (personality disorders and intellectual disability), Axis III (medical conditions), Axis IV (psychosocial and environmental problems in 9 categories), and Axis V (Global Assessment of Functioning, GAF score 0–100). The APA eliminated this system following an abolition proposal initiated as early as 2004 for the following reasons: poor inter-rater reliability of the GAF score, conceptual conflation of symptoms and functioning in Axis V, inconsistent clinical use of Axis IV, and the artificial boundary between Axes I and II.

Several clinical functions of the previous system were not fully replaced. Probst (2014) documented that the elimination of Axis IV “does not eliminate the necessity of considering context.” Kress et al. (2014) found that clinicians must now “be all the more vigilant in finding systematic ways to capture biopsychosocial information”—without the structured prompts of the old system. The V/Z codes introduced as an Axis IV replacement have seen low adoption: Erlich et al. (2025) note that “a general awareness of these codes and the importance of their use in communicating social determinants of health has not materialized.”

Most critically, the abolition resulted in the loss of structured multiaxial assessment, leaving clinicians without a systematic framework for integrating biological, psychological, and social dimensions.

Existing multiaxial and integrative approaches. The present model builds upon several foundational approaches to multiaxial and integrative psychiatric assessment and extends them in a computer-assisted direction. Williams (1985) documented the origins and early critiques of the DSM-III multiaxial system, identifying both its clinical utility as a structured prompt for comprehensive assessment and its operational weaknesses—particularly the unreliable GAF score and the inconsistent application of the psychosocial stressors axis. The present model addresses these specific critiques: it replaces the GAF with validated instruments (WHODAS 2.0, ICF Core Sets), eliminates the artificial Axis I/II boundary, and introduces quantitative coverage analysis as a structured complement to clinical judgment.

Bolton (2008) argued that formulation—the individualized narrative account of a patient’s difficulties—should complement, not replace, categorical diagnosis. Bolton’s key insight was that classification systems capture *what* a patient has, while formulation captures *why* and *how*. The present model operationalizes this insight through Axis V (Integrated Condition Model), which implements a structured 3P/4P formulation schema with explicit links back to the diagnostic axes—bridging the gap between Bolton’s narrative formulation and the structured classification that clinical systems require.

Wakefield (1992) proposed the influential “harmful dysfunction” analysis, arguing that mental disorder is a condition in which an internal mechanism fails to perform its natural function *and* the dysfunction causes harm to the individual. This conceptual framework informs the present model’s approach to differential diagnosis: the 6-step gatekeeper logic (after First, 2024) systematically distinguishes normal variation from dysfunction by requiring evidence of both impaired mechanism *and* clinically significant distress or functional impairment. The coverage analysis further operationalizes this distinction by quantifying which symptoms are explained by established diagnoses and which remain unexplained—one route for making Wakefield’s distinction between dysfunction and statistical deviance explicit in clinical documentation.

Relationship to the OPD system. The Operationalized Psychodynamic Diagnostics system (OPD-3) is a widely used multiaxial diagnostic system in the German-speaking world and also uses a multi-axis approach with five axes (illness experience and treatment prerequisites, relationship, conflict, structure, mental and psychosomatic disorders). While the OPD is primarily psychodynamically grounded and supports treatment planning within this paradigm, the present model pursues a transtheoretical, categorical-dimensional approach focused on computer-assisted decision support. The systems are complementary: the OPD captures intrapsychic dynamics (conflicts, structure, relational patterns) with a depth that the present system does not attempt; the 6-axis model adds quantitative coverage analysis, the somatic-psychological parallel structure, and algorithmic gatekeeper logic not contained in the OPD. In clinical practice, OPD findings (particularly the conflict and structure axes) can be used as material for Axis II (core conflicts) and Axis V (case formulation) of the present model.

Relationship to the AMDP system. The AMDP system (Association for Methodology and Documentation in Psychiatry) is the standard instrument for psychopathological assessment in the German-speaking world. In the present model, the AMDP assessment provides the *raw material* for Axis I: the symptoms documented there are mapped to diagnostic criteria in the coverage analysis (Ii). The 6-axis system does not replace the AMDP assessment but builds upon it.

Notably, multiaxial classification remains explicitly preserved in child and adolescent psychiatry: Mayall et al. (2024) argue that the multiaxial framework represents a “clinically useful biopsychosocial framework” that was prematurely abandoned in adult psychiatry. This persistence in a field that inherently requires multidisciplinary collaboration supports the reintroduction of multiaxial structures for adults as well.

A legitimate objection to the reintroduction of multiaxial systems is that the problems of DSM-IV may not merely be matters of implementation but rather inherent to the multiaxial approach itself: the forced partitioning into discrete axes may fragment clinical information that would be better captured holistically. The present model addresses this objection through the skeleton principle (no mandatory fields), the cross-axis case formulation (Axis V), and the deliberate flexibility of multi-professional assignment. Whether these design decisions actually solve the fragmentation problem is an empirical question that can

only be answered through the planned validation.

The present paper introduces a 6-axis model that addresses the specific weaknesses of the historical system while proposing capabilities that go beyond existing systems.

2.1 Institutional Convergence

The proposed model does not stand in isolation but anticipates the direction in which psychiatric institutions themselves are moving. The 17-member *APA Future DSM Strategic Committee* is currently developing a “roadmap” with four subcommittees exploring dimensionality, biomarkers, functioning/quality of life, and socioeconomic/cultural/environmental determinants. Erlich et al. (2025) explicitly call for a return to a biaxial system to capture social determinants of health.

2.2 Design Philosophy: Skeleton, Living Document, Maximum Freedom

Three design principles guide the entire system:

Skeleton Principle

The system functions as a diagnostic *skeleton*: it provides a defined location for every clinically relevant piece of information without declaring any field as mandatory. No clinician is forced to complete sections irrelevant to the current case. The system is a supportive framework—not a constraint—for the diagnostic process.

Living Document

The diagnostic record is not a static form but a *living document* that grows with the clinical process. New test results, lab reports, observation protocols, and assessments can be integrated at any time. Each axis is open for iterative additions: a lab report is entered into the evidence matrix (Axis VI) with date, designation, clinical assessment, and axis reference; a later collateral history supplements the contact log; a new psychometric test updates Axis I.

Report as Snapshot

Reports—whether discharge letters, expert opinions, or progress reports—are *frozen snapshots* of the living document at a specific point in time. The document itself continues to evolve and can incorporate new information after a report, while the report represents the state at the time of its creation.

This philosophy fundamentally distinguishes the system from rigid form-based systems: it provides structure where structure is useful, and freedom where freedom is clinically warranted.

Contribution. The paper’s primary contributions are threefold: (1) the quantitative coverage analysis as a clinical quality assurance metric for diagnostic completeness, (2) the symmetric Axis I/III architecture enabling structured multi-professional collaboration, and (3) the operationalized connection between categorical diagnostics and individualized case formulation within a single system. Related approaches exist in sub-areas (e.g., Bayesian diagnostic systems, OPD multiaxiality); the specific contribution lies in their integration into a computer-assisted decision-support architecture. These design elements address clinical deficits that have persisted since the abolition of the DSM-IV multiaxial system and that have regained urgency through recent calls (Erlich et al., 2025).

3 Architecture of the 6-Axis Model

The proposed model integrates categorical diagnostics (DSM-5-TR (APA, 2022); ICD-11 (WHO, 2019)) into a structured clinical reasoning architecture. It serves to capture the diagnostic lifespan, to examine causality between somatic and psychological conditions, and to document treatment and remission history. A central design principle is the **symmetric parallel structure** between Axis I and Axis III: both axes feature analogous sub-axes (suspected diagnoses, refutations, treatment history, coverage analysis, investigation plan), enabling psychologists and physicians to work with comparable structural tools in their respective domains. Table 2 provides an overview.




Figure 1: Architecture of the 6-axis model with sub-axes. Axes I and III share a symmetric parallel structure (indicated by the dashed arrow).

Table 2: Overview of the diagnostic axes of the 6-axis model

Axis	Designation	Subdivision	Core Content	Typical Profession
I	Mental Health Profiles	Ia: Acute Disorders Ib: Chronic Courses Ic: Refuted Suspects Id: Remitted Diagnoses Ie: Remission Factors If: Treatment History Ig: Treatment Adherence Ih: Suspected Diagnoses Ii: Coverage Analysis Ij: Investigation Plan	DSM-5 Cross-Cutting; PHQ-9, PCL-5, ITQ; Differential Diagnosis; Chronification; Temporal Mapping	Psychologist / Psychiatrist
II	Biography & Personality	Developmental History Formative Experiences Core Conflicts Personality (PID-5)	IQ, Education, Socialization; Life Events; OPD Conflicts; PID-5-BF/+M	Psychologist / Social Worker
III	Medical Synopsis	IIIa: Acute Med. Diagnoses IIIb: Chronic Diagnoses (expl.) IIIc: Contributing Factors IIId: Remitted Conditions IIIe: Remission Factors IIIf: Treatment History IIIg: Medication Adherence IIIh: Suspected Diagnoses IIIi: Coverage Analysis IIIj: Investigation Plan IIIk: Causal Analysis IIIl: Genetic/Family IIIm: Medication History	Biographical Medical History; Causal Analysis Soma–Psyche; Genetic Burden; Pharmacotherapy with Efficacy Rating	Physician / Specialist
IV	Environment & Functioning	Participation (ICF) Psychosocial Circumstances Contact Network Cultural Formulation	WHODAS 2.0, GdB; Mini-ICF-APP; Stressors; Treatment Network; CFI	Social Worker
V	Condition Model	Predisposing Factors Precipitating Factors Perpetuating Factors Protective Factors Clinical Synthesis	3P/4P Model; Axis Integration; Treatment Planning; Prognosis	Interdisciplinary Team
VI	Evidence Collection & Clinical Safety	Evidence Matrix (with assessment) CAVE Alerts Symptom Course Contact Log	Document register with clinical assessment; CAVE alerts; Symptom course; Contact/Observation log	All Professions

3.1 Axis I: Mental Health Profiles — Temporal Diagnostics

Axis I extends beyond a simple diagnosis list by capturing diagnoses in their temporal dynamics. The division into ten sub-axes (Ia–Ij) enables documentation of the entire diagnostic lifecycle: current acute disorders (Ia), chronic courses with chronification risk (Ib), explicitly refuted diagnostic hypotheses with differential-diagnostic rationale (Ic), remitted diagnoses with documented inactivity (Id), remission factors such as therapy, medication, or spontaneous coping (Ie), complete treatment history including effects and

side effects (If), treatment adherence from self-report and collateral perspectives (Ig), active suspected diagnoses as diagnostic hypotheses (Ih), the coverage analysis of unexplained residual symptoms (Ii), and structured investigation plans for next diagnostic steps (Ij).

The ordering of coverage analysis (Ii) before investigation plan (Ij) follows clinical logic: diagnostically unexplained symptoms must first be systematically identified before targeted investigations for their clarification can be planned. The investigation plan thus derives directly from the gaps identified by the coverage analysis.

PRO/CONTRA evidence evaluation: Each diagnosis receives a structured evidence evaluation with explicit documentation of findings supporting (PRO) and opposing (CONTRA) the diagnosis, together with a numerical confidence estimate (0–100%). This operationalization follows the principle of differential-diagnostic transparency: the clinician must document not only *that* a diagnosis is made, but *why*—and which counterarguments were considered and rejected.

Quantitative coverage analysis (Ii): A symptom–diagnosis matrix quantifies the degree of diagnostic explanation for each symptom through the active diagnoses. The formal definition, thresholds, and sensitivity analysis are presented in detail in Section 7.

Prioritized investigation plan (Ij): The investigation plan uses a 3-tier prioritization scheme: *Urgent* (to be clarified within 4 weeks—e.g., suicidality assessment, emergency medical diagnostics), *Important* (within 3 months—e.g., neuropsychological testing, differential diagnostics), and *Monitoring* (continuous monitoring—e.g., symptom course under therapy). Each planned investigation is assigned to a specialty and provided with a clinical rationale.

This temporal dimensionality was missing both in Axis I of the DSM-IV and in the flat listing of the DSM-5.

3.2 Axis II: Biography and Dimensional Personality

Axis II modernizes personality assessment through dimensional PID-5 trait profiling as recommended by both ICD-11 and the DSM-5 Alternative Model. The ICD-11 model replaces categorical personality disorder types with a severity rating (personality difficulty → mild → moderate → severe), five trait qualifiers (Negative Affectivity, Detachment, Dissociality, Disinhibition, Anankastia), and a Borderline Pattern specifier. The DSM-5 AMPD uses the Level of Personality Functioning Scale (LPFS) for Criterion A and five trait domains with 25 facets for Criterion B.

The **PID-5-BF+M** (36 items, 6 domains, 18 facets) bridges both systems and is available in over 12 languages. Meta-analyses show overall convergence of $r = 0.62$ between the systems, with domain correlations of $r = 0.78$ – 0.86 , except for Anankastia ($r = 0.34$), which has no direct AMPD equivalent.

Recent work on integrating the ICD-11 and DSM-5 dimensional systems for personality disorders into a unified taxonomy with non-overlapping traits supports the PID-5-based approach adopted here (Bach et al., 2022).

Beyond dimensional personality assessment (IIa), Axis II integrates two additional biographical components: **Formative experiences (IIb)** document life events of biographical significance with life stage and impact on the current situation (e.g., early loss, violence, migration). **Core conflicts (IIc)** capture recurring intrapsychic themes (e.g., autonomy–dependency conflict, self-worth conflict) as described in the psychodynamic tradition and the OPD system. Both components are implemented as open lists that grow with the diagnostic process, providing essential material for case formulation in Axis V.

Relationship to the DSM-5 AMPD: The Alternative Model for Personality Disorders is implicitly biaxial (Criterion A: LPFS functioning level; Criterion B: pathological traits). The present model adopts Criterion B (PID-5 traits) in Axis II but extends it with biographical contextualization (formative experiences, core conflicts), while relocating the functional assessment (LPFS analogue) to Axis IV (WHODAS 2.0, Mini-ICF-APP). This preserves the AMPD’s diagnostic information while distributing it across axes aligned with distinct professional responsibilities.

3.3 Axis III: Medical Synopsis — Symmetric Parallel Structure to Axis I

A central design principle of the model is the **structural symmetry** between Axis I (psychological) and Axis III (somatic). The rationale is that if Axis I supports suspected diagnoses, documented refutations, and coverage analyses, Axis III should offer comparable capabilities for the somatic domain. This symmetry is intended to make multi-professional work more consistent.

Axis III therefore encompasses 13 sub-axes:

IIIa–IIIj: Parallel Core Structure

These ten sub-axes follow the basic structure of Axis I, where sub-axes IIIb (explanatory chronic diagnoses) and IIIc (contributing factors) represent a domain-specific differentiation without a direct equivalent in Axis I: acute somatic diagnoses (IIIa), chronic somatic diagnoses with fully explanatory character (IIIb), contributing medical factors—somatic findings that promote or exacerbate psychopathology without fully explaining it (IIIc), remitted somatic conditions (IIId), somatic remission factors—surgical interventions, medication, lifestyle changes (IIIe), medical treatment history including surgeries, pharmacotherapy, and side effects (IIIf), medication adherence from medical documentation and patient report (IIIg), medical suspected diagnoses as active diagnostic hypotheses (IIIh), somatic coverage analysis—physical symptoms not explained by any current medical diagnosis (IIIi), and medical investigation plan for further somatic diagnostics (IIIj).

IIIk–IIIIm: Axis-III-Specific Sub-Axes

Three sub-axes have no counterpart in Axis I, as they map the specific soma–psyche relationship: integrated causal analysis—systematic assignment of somatic findings to psychopathology distinguishing full explanation (e.g., hypothyroidism explains depression) from contributing effect (e.g., chronic pain exacerbates anxiety disorder) (IIIk); genetic and family burden—family history for somatic and psychiatric disorders, known genetic predispositions, and where applicable results from exome sequencing (IIIl); medication history and interactions—structured recording of all current and past medications with dosage, unit, purpose/indication, schedule, efficacy rating (0–10), side effects, and potential interactions (IIIIm).

Note on the IIIb/IIIc design decision: The explicit differentiation between fully explanatory chronic diagnoses (IIIb) and merely contributing factors (IIIc) integrates causal analysis directly into the classification structure. Refuted medical suspected diagnoses are documented within IIIh (suspected diagnoses) through a status change, analogous to clinical practice where suspected diagnoses are excluded and dismissed with rationale.

Note on IIIIm: The medication history as a standalone sub-axis (rather than a mere listing in IIIf) enables structured capture of efficacy profiles, interaction risks, and adherence at the preparation level.

This is clinically essential, as polypharmacy and drug interactions are a frequent cause of both somatic and psychiatric complications.

This symmetry ensures that the system functions as a *shared tool* for physicians and psychologists. A physician completing Axis III has the same diagnostic depth available as a psychologist working in Axis I.

3.4 Axis IV: Environment and Functioning — ICF Integration and Cultural Formulation

Axis IV combines multiple validated instruments. The **WHODAS 2.0** (WHO, 2010) (WHO Disability Assessment Schedule) captures six domains—Cognition, Mobility, Self-care, Getting Along, Life Activities, and Participation—optionally as 12-item short form (explains 81% of variance; Luciano et al., 2010) or 36-item full version. Psychometric properties are strong: Cronbach's $\alpha = 0.94$ – 0.96 , test-retest ICC = 0.93 – 0.96 .

WHODAS 2.0 and GAF measure *fundamentally different constructs*: GAF conflates symptoms and functioning; WHODAS 2.0 measures disability independently of symptom severity. Gspandl et al. (2018) found *no significant correlation* between self-rated WHODAS 2.0 and GAF in schizophrenia spectrum disorders. The system primarily uses WHODAS 2.0 for disability assessment. The GAF may optionally be retained for backward compatibility but is not a core component.

For the German context, the **GdB integration** (Grad der Behinderung, degree of disability) is essential. The GdB uses a 20–100 scale (≥ 50 = severe disability) and is assessed according to the Versorgungsmedizinische Grundsätze (VMG). For international implementations, this sub-axis should be replaced with the equivalent national disability assessment framework (e.g., Disability Adjusted Life Years in WHO contexts, or the Social Security Disability determination in the U.S.).

Three mental-health **ICF Core Set** families have been developed for depression, bipolar disorder, and schizophrenia (Cieza et al., 2004; Ayuso-Mateos et al., 2013; Gómez-Benito et al., 2018): depression (31 brief/121 comprehensive categories), bipolar disorder (19/38), and schizophrenia (25/97). For practical implementation, the **Mini-ICF-P** rating by Linden & Baron (2005) with 13 capacity dimensions is the most efficient tool.

Operationalization of ICF integration in Axes III and VI: The ICF coding in the 6-axis model follows a three-stage logic. *First*, on Axis III (Medical Synopsis), the body functions (ICF Chapter b) and body structures (ICF Chapter s) relevant to the somatic-psychological causal analysis (IIIk) are documented—e.g., b130 (energy and drive functions), b152 (emotional functions), or b144 (memory functions). *Second*, Axis IV captures activities and participation (ICF Chapter d) and environmental factors (ICF Chapter e)—operationalized through WHODAS 2.0 (domains d1–d6) and Mini-ICF-APP (13 capacity dimensions, e.g., regularity, flexibility, social competence). *Third*, the evidence matrix (Axis VI) documents the ICF qualifiers (extent of impairment: 0–4) for each coded functional restriction, enabling quantification over time.

Added value beyond WHODAS 2.0 alone: While WHODAS 2.0 as a global disability instrument captures six domains on a summary scale, the 6-axis model enables *axis-specific differentiation*: functional restrictions are not only quantified but causally attributed to Axes I (psychological) and III (somatic). The coverage analysis (Ii/IIIi) additionally identifies functional deficits not explained by any current diagnosis—a dimension that WHODAS 2.0 does not address. The Mini-ICF-APP complements WHODAS 2.0 with disorder-specific capacity profiles directly usable for treatment planning and prognosis in Axis V

(Condition Model).

3.4.1 Contact Persons and Treatment Network

Axis IV also captures the patient's **contact persons and treatment network**. For each contact person, name, role (parent, partner, GP, specialist, therapist, social worker, guardian, etc.), institution, contact details, and notes are documented. This structured network recording serves multiple purposes: it makes the social support system visible, which is essential for case formulation (Axis V, protective factors) and treatment planning; it documents the professional network involved for coordination; and it identifies potential sources for collateral histories.

3.4.2 Cultural Formulation Interview (CFI)

The DSM-5-TR contains a structured **Cultural Formulation Interview** (CFI) with 16 core questions across four domains: cultural definition of the problem, cultural perception of cause/context/support, cultural factors in coping, and cultural factors in the clinician–patient relationship. For a model claiming comprehensive biopsychosocial assessment, integration of the CFI as an optional module in Axis IV is essential. The 12 supplementary CFI modules (for specific populations and contexts) can be activated as needed.

3.5 Axis V: Integrated Condition Model — Operationalized Case Formulation

Axis V represents a proposed extension not contained in previous systems. The predisposing–precipitating–perpetuating factor model (clinical 3P/4P model) bridges diagnostic classification with case formulation—something no DSM edition has ever contained. Owen (2023) argues that this formulation approach “disciplines the selection of facts and makes treatment goal-directed.” The synthesis of all axes—how biology (III), biography (II), and current stressors (IV) interact with psychopathology (I)—is made explicit here.

The model operationalizes case formulation through four structured components:

Predisposing Factors (P1)

Vulnerability factors that existed before the disorder. Sources: Axis II (biographical risk factors, personality traits), Axis III (genetic burden, III_m), Axis IV (early psychosocial stress). Coding: factor, source axis, evidence strength (established/probable/possible), evidence (Axis VI reference).

Precipitating Factors (P2)

Events or changes that triggered disorder onset. Sources: Axis IV (current stressors, life events), Axis III (somatic triggers). Coding: factor, temporal relationship, source axis, evidence.

Perpetuating Factors (P3)

Conditions that maintain the disorder. Sources: Axis I (comorbidities, treatment adherence), Axis III (untreated somatic findings), Axis IV (persistent psychosocial stress). Coding: factor, mechanism, modifiability (modifiable/stable), intervention priority.

Protective Factors (P4)

Resources that promote resilience. Sources: Axis II (personality strengths), Axis IV (social

support, economic resources), Axis I (remission factors, Ie). Coding: factor, source axis, activatability.

Transtheoretical compatibility: The 3P/4P model is deliberately transtheoretical in design. Behavioral case conceptualizations (e.g., the SORKC model) can be directly translated into the Axis V structure: stimulus situations correspond to precipitating factors (P2), organism variables to predisposing factors (P1), response patterns and consequences to perpetuating factors (P3). Psychodynamic formulations (OPD conflicts, structural limitations) likewise find their place in P1 and P3. This compatibility is no coincidence but reflects the empirical convergence of different therapeutic schools on common etiological factors.

The link to coverage analysis (Axis Ii) is central: symptoms not covered by any Axis I diagnosis are expected to be examined through the Axis V formulation. Symptoms that are neither diagnostically nor formulationally explained represent remaining diagnostic gaps and trigger the investigation plan (Axis Ij).

3.6 Axis VI: Evidence Collection, CAVE Alerts, and Symptom Course

Axis VI has been substantially expanded from the original design and now comprises four components:

Evidence Matrix

A central document register linking every coded piece of information to evidence (document analysis, interview, testing). Each entry includes, beyond axis reference, document type, and description, an explicit **assessment field** for the clinical evaluation: an incoming lab report is documented with date, designation, source, *and* clinical interpretation—making transparent how the clinician interprets the finding in the diagnostic context.

CAVE Alerts

A structured warning system for critical clinical risks with cross-axis relevance. Each alert is categorized as: *Drug interaction* (e.g., Lithium + NSAIDs), *Lab artifact* (e.g., CRP elevation due to chronic inflammation, not acute infection), *Contraindication* (e.g., pregnancy with certain medications), *Temporal misattribution* (e.g., symptom onset before or after suspected trigger), *Diagnostic limitation* (e.g., unusable test result), and *Other warning*. Each alert references the affected source axis (I–VI) for immediate contextualization. CAVE alerts are prominently highlighted in red in the overall synopsis.

Longitudinal Symptom Course

Structured documentation of the temporal symptom course: for each relevant symptom, onset (first manifestation), current status (active/remitted/fluctuating), and therapy response (response/non-response/partial response) are recorded.

Contact and Observation Log

A structured protocol for all clinically relevant contacts and observations. Each entry comprises date, contact type (phone call, interview, observation, home visit, collateral history, email/letter), contact person, content, and optional axis reference. The log documents the *process* of information gathering.

3.7 Multi-Professional Team Assignment

The 6-axis model provides a **recommended**, non-mandatory assignment of axes to professional groups. Table 3 shows an exemplary configuration for interdisciplinary teams. In clinical practice, responsibilities can be flexibly adapted: a psychiatrist with both psychodiagnostic and somatic competence can naturally complete both Axis I *and* Axis III; a psychosomatic medicine specialist can serve all six axes. The system *enables* interdisciplinary division of labor but does not *enforce* it.

The value of the assignment lies not in rigid access restrictions but in the **structured prompt**: the system makes transparent *which* competence is typically needed for which axis. In solo practices or smaller settings, a single professional can work on all axes; in clinics and interdisciplinary teams, the model enables efficient division of labor where each profession works in its domain with identical structural tools. The identical sub-axis structure of Axes I and III is not coincidental but a design decision: a physician formulating a somatic suspected diagnosis in IIIh uses exactly the same logic as a psychologist entering a psychological suspected diagnosis in Ih.

Table 3: Exemplary multi-professional axis assignment (non-mandatory)

Axis	Typical Profession	Professional Rationale
I	Psychologist / Psychiatrist	Psychodiagnostic competence; testing authority
II	Psychologist / Social worker	Biographical history; personality assessment
III	Physician / Specialist	Somatic diagnosis; causal analysis
IV	Social worker	Life-world expertise; ICF competence; participation assessment
V	Interdisciplinary team	Synthesis benefits from all perspectives
VI	All professions	Each participating profession documents its own findings

3.8 Comorbidity Rules and Diagnostic Hierarchy

The system implements three levels of comorbidity rules essential for correct diagnostic decision-making:

Hierarchical Exclusion Rules

Certain diagnoses exclude others. Example: a schizophrenia diagnosis excludes a concurrent schizoaffective disorder. The system codes these as hard constraints that are automatically checked upon diagnosis entry.

“Due to Another Condition” Rules

Many DSM-5-TR diagnoses require ruling out that the symptomatology is better explained by another mental disorder, a substance, or a medical condition. These rules are directly implemented through Gatekeeper Steps 1–3 (Section 4).

Permitted Comorbidities with Prioritization

With 4+ active diagnoses, the system prioritizes by: (1) clinical urgency (suicidality, psychosis), (2) severity (Axis I acute status), (3) treatability (modifiable perpetuating factors from Axis V), (4) chronological order.

3.9 Complete Sub-Axis Inventory

Tables 4, 5, and 6 provide a complete inventory of all sub-axes across the six main axes, including associated instruments and data sources.

Table 4: Sub-axis inventory: Axes I–II

Axis	Sub-Axis	Description	Instrument / Source
I			
Psychological	Ia: Acute Disorders	Current DSM-5-TR/ICD-11 diagnoses with PRO/CONTRA evidence and confidence	DSM-5-TR, ICD-11
	Ib: Chronic Courses	Long-term diagnoses with chronification risk	Clinical records
	Ic: Refuted Suspects	Explicitly ruled-out diagnoses with differential-diagnostic rationale	Differential diagnosis
	Id: Remitted Diagnoses	Former diagnoses with documented inactivity	Clinical records
	Ie: Remission Factors	Therapy, medication, or spontaneous coping as remission cause	Clinical records
	If: Treatment History	Prior treatments, medications, effects and side effects	Clinical records
	Ig: Treatment Adherence	Adherence from self-report and collateral perspectives	Clinical interview
	Ih: Suspected Diagnoses	Active diagnostic hypotheses (not yet confirmed)	Clinical judgment
	Ii: Coverage Analysis	Symptom–diagnosis coverage percentage (DCI)	Algorithmic (see Section 7)
	Ij: Investigation Plan	Prioritized next steps (urgent / important / monitoring)	Clinical judgment
II			
Personality	Ila: PID-5 Dimensional Profile	5 trait domains, 25 facets	PID-5, PID5BF+
	Ilb: Formative Life Experiences	Biographical events shaping personality development	Clinical interview
	Ilc: Core Conflicts	Central relational patterns and conflict themes	OPD-3, clinical formulation

Table 5: Sub-axis inventory: Axis III

Axis	Sub-Axis	Description	Instrument / Source
III			
Somatic	IIIa: Acute Somatic Diagnoses	Current somatic diagnoses with PRO/CONTRA evidence	ICD-11 somatic codes
	IIIb: Chronic Diagnoses (explanatory)	Conditions that fully account for specific symptoms	Clinical records
	IIIc: Contributing Medical Factors	Somatic findings that promote or exacerbate psychopathology	Clinical records
	IIId: Remitted Conditions	Prior somatic conditions with documented inactivity	Clinical records
	IIIe: Remission Factors	Surgical interventions, medication, lifestyle changes as remission causes	Clinical records
	IIIf: Treatment History	Prior medical treatments, surgeries, side effects	Clinical records
	IIIg: Medication Adherence	Adherence from medical documentation and patient report	Clinical records
	IIIh: Suspected Diagnoses	Active medical diagnostic hypotheses	Clinical judgment
	IIIi: Coverage Analysis (Somatic)	Somatic symptom–diagnosis coverage percentage	Algorithmic (see Section 7)
	IIIj: Somatic Investigation Plan	Medical workup priorities	Clinical judgment
	IIIk: Integrated Causal Analysis	Cross-axis causal pathways (somatic ↔ psychological)	Interdisciplinary synthesis
	IIIl: Genetic/Family Burden	Hereditary risk factors and family medical history	Family history interview
	IIIm: Medication History	Current and past medications with efficacy ratings	Medication records

Table 6: Sub-axis inventory: Axes IV–VI

Axis	Sub-Axis	Description	Instrument / Source
IV Functional Status	IVa: WHODAS 2.0	6 functional domains (36-item or 12-item version)	WHODAS 2.0
	IVb: GdB	German disability degree (<i>Grad der Behinderung</i>)	VersMedV guidelines
	IVc: ICF Core Sets	Disorder-specific ICF component profiles	ICF Core Sets
	IVd: Cultural Formulation Interview	Cultural context of illness experience	CFI (DSM-5-TR)
	IVe: Treatment Network Register	Contact persons, providers, social support	Structured register
V Case Formulation	Va: Predisposing Factors	Vulnerability factors preceding disorder onset	3P/4P schema
	Vb: Precipitating Factors	Triggering events and stressors	3P/4P schema
	Vc: Perpetuating Factors	Maintaining mechanisms and feedback loops	3P/4P schema
	Vd: Protective Factors	Resilience resources and strengths	3P/4P schema
	Ve: Coverage Gap Integration	Unexplained symptoms from Axes I + III coverage analysis	Cross-axis synthesis
VI Evidence & Safety	VIa: Central Evidence Matrix	Structured evidence fields per diagnosis	System-generated
	VIb: CAVE Clinical Alerts	Cross-axis risk warnings (interactions, contraindications)	Rule-based alerts
	VIc: Longitudinal Symptom Tracking	Repeated measures with therapy response documentation	PHQ-9, GAD-7, PCL-5, etc.
	VId: Contact and Observation Log	Session documentation and process notes	Clinician entries

4 The 6-Step Gatekeeper Logic

The system implements a dynamic queue in which screening findings trigger specific DSM-5-TR/ICD-11 modules. The 6-step sequence maps exactly to the framework published by Michael B. First in the *DSM-5-TR Handbook of Differential Diagnosis* (2024) (Table 7).

Table 7: Alignment of the 6-step gatekeeper logic with First’s gold standard

Step	System Step	First’s Framework	Match
1	Malingering exclusion	Rule out malingering and factitious disorder	Exact
2	Substance exclusion	Rule out substance etiology	Exact
3	Medical exclusion	Rule out etiological medical conditions	Exact
4	Primary category	Determine specific primary disorder(s)	Exact
5	Adjustment disorder	Differentiate adjustment disorders	Exact
6	Functional threshold	Boundary with “no mental disorder”	Conceptual

First (2024) describes this framework as the definitive macro-level diagnostic process. His Handbook further contains **30 symptom-oriented decision trees** (two added in the TR edition for dissociative symptoms and repetitive pathological behaviors) and **67 differential diagnosis tables**, all following this sequence.

Note on Step 6 (“conceptual”): While Steps 1–5 can be mapped algorithmically, Step 6—drawing the boundary between a normal stress response and a mental disorder—is inherently a clinical judgment decision. The system supports this through structured functional data (WHODAS 2.0, Mini-ICF-APP from Axis IV) and the Cross-Cutting thresholds, but cannot fully automate the clinical decision. This epistemic boundary is explicitly communicated.




Figure 2: 6-step gatekeeper logic for differential diagnosis, based on First (2024). Step 6 is marked as conceptual because the boundary between normal variation and mental disorder requires clinical judgment.

5 Cross-Cutting Screening

The DSM-5 Cross-Cutting Symptom Measures form the backbone of the screening architecture. The **Level-1 adult measure** contains **23 items across 13 domains**: Depression (2), Anger (1), Mania (2), Anxiety (3), Somatic Symptoms (2), Suicidality (1), Psychosis (2), Sleep Problems (1), Memory (1), Repetitive Thoughts and Behaviors (2), Dissociation (1), Personality Functioning (2), and Substance Use (3). Each item uses a 5-point Likert scale (0 = none to 4 = severe).

The threshold logic is clinically calibrated: **Most domains trigger Level 2 at ≥ 2 (mild)**, but three safety-critical domains—Suicidality, Psychosis, and Substance Use—**trigger at ≥ 1 (slight)**. This asymmetry reflects the clinical imperative to never overlook even minimal endorsement of dangerous symptoms.

Level-2 measures refer to specific validated instruments: PROMIS Depression Short Form, PROMIS Anxiety Short Form, Altman Self-Rating Mania Scale (ASRM), PHQ-15 for somatic symptoms, PROMIS Sleep Disturbance, adapted FOCI Severity Scale for OCD, and adapted NIDA-Modified ASSIST for substance use. Five domains (Suicidality, Psychosis, Memory, Dissociation, Personality Functioning) have *no official Level-2 measures*—the APA recommends clinical evaluation for these.

The DSM-5 Field Trials (Narrow et al., 2013) demonstrated **good to excellent test-retest reliability** (ICC 0.64–0.97) for most items.

5.1 Child and Adolescent Version

The DSM-5 Cross-Cutting system includes a separate **parent-report version for children and adolescents** (ages 6–17) with **25 items across 12 domains**. The “Personality Functioning” domain is omitted for developmental reasons; instead, irritability and anger are weighted more heavily. A complete implementation requires the pediatric variant as a separate entry pathway and age-appropriate Level-2 instruments.

The present system prefers **exclusively freely available instruments**; the proprietary CBCL/YSR complex (Achenbach & Rescorla, 2001) is acknowledged as a reference standard but replaced by license-free alternatives. Table 8 lists the recommended set of free child/adolescent (C/A) instruments in parallel to the adult matrix (Table 9).

This selection preserves the diagnostic logic of the adult matrix (domain-oriented, cutoff-based) while substituting each instrument with a developmentally validated, license-free C/A variant. For safety-critical domains (suicidality, substance use, psychosis), the same lower triage threshold applies. The split between **self-report** (from ~ages 8–11) and **parent report** (ages 6–17; obligatory for younger children) follows the established convention of pediatric psychometrics.

5.2 Comprehensive Screening Instrument Matrix

Table 9 shows the recommended instruments for all major diagnostic domains.

All recommended instruments are **freely available**—no licensing costs impede implementation. The selection is based on the respective validation publications: PHQ-9 (Levis et al., 2019), GAD-7 (Spitzer et al., 2006), PCL-5 (Blevins et al., 2015), ITQ (Cloitre et al., 2018), PQ-16 (Ising et al., 2012), ASRS (Kessler et al., 2005), AQ-10 (Allison et al., 2012), AUDIT (Saunders et al., 1993), PID-5 (Oltmanns & Widiger, 2018; Riegel et al., 2021), C-SSRS (Posner et al., 2011), OCI-R (Foa et al., 2002), SSS-8

Table 8: Free screening instruments for children and adolescents (C/A matrix)

Domain	Instrument	Items	Age range	Cutoff / Norm	Cost
Cross-Cutting (Parent)	DSM-5 XC L1 Parent	25	6–17	$\geq 1/\geq 2$ triage	Free
Gen. psychosoc. screen	SDQ (Self/Parent)	25	4–17	≥ 20 (Total)	Free
Depression	PHQ-9 mod. (PHQ-A)	9	11–17	≥ 11	Free
Anxiety + Depression	RCADS-25	25	8–18	$T \geq 65$	Free
Anxiety (multidim.)	SCARED-C	41	8–18	≥ 25	Free
PTSD	CPSS-V / CRIES-8	20 / 8	7–18	$\geq 31 / \geq 17$	Free
Substance use	CRAFFT 2.1+N	6+3	12–21	≥ 2	Free
ADHD	SNAP-IV-26	26	6–18	Subscale mean	Free
Autism	AQ-10 Adolescent/Child	10	4–15	≥ 6	Free
OCD	CY-BOCS-SR	10	8–18	≥ 16	Free
Suicidality	C-SSRS Pediatric	6	≥ 5	Any endorse.	Free
Eating disorders	SCOFF (from ~age 13)	5	13–18	≥ 2	Free

(Gierk et al., 2014), DES-II (Carlson & Putnam, 1993), SCOFF (Morgan et al., 1999), ISI (Morin et al., 2011). For inter-rater reliability of categorical DSM-5 diagnoses, see Regier et al. (2013) and Aboraya et al. (2006).

6 Critical Divergences Between DSM-5-TR and ICD-11

The system must encode five critical divergences between the classification systems (Keeley et al., 2016).

6.1 Schizophrenia Duration

DSM-5-TR (295.90/F20.x) requires **6 months** of continuous signs including at least 1 month of active symptoms, while ICD-11 (6A20) requires only **1 month**. A patient may thus meet ICD-11 criteria for schizophrenia but only receive a schizophreniform disorder diagnosis under DSM-5.

6.2 PTSD Architecture

DSM-5-TR uses **4 clusters with 20 symptoms** (Intrusion $\geq 1/5$, Avoidance $\geq 1/2$, Negative Cognitions $\geq 2/7$, Arousal $\geq 2/6$). ICD-11 uses a deliberately narrower model: **3 clusters with 6 core symptoms**. ICD-11 then adds **Complex PTSD (6B41)** as a distinct diagnosis requiring all PTSD criteria plus three disturbances of self-organization (affect dysregulation, negative self-concept, relationship difficulties).

Table 9: Screening instrument matrix

Domain	Instrument	Items	Cutoff	Sens./Spec.	Cost
Depression	PHQ-9	9	≥ 10	88%/88%	Free
Anxiety	GAD-7	7	≥ 10	89%/82%	Free
PTSD (DSM-5)	PCL-5	20	31–33	85–95%/82–90%	Free
PTSD/CPTSD (ICD-11)	ITQ	18	Algorithm	Excellent	Free
Psychosis risk	PQ-16	16	≥ 6	87%/87%	Free
Bipolar screening	MDQ	15	≥ 7	73%/90%	Free
ADHD	ASRS v1.1	6	≥ 4	69%/99.5%	Free
Autism	AQ-10	10	≥ 6	88%/91%	Free
Alcohol use	AUDIT	10	≥ 8	92%/94%	Free
Drug use	DAST-10	10	≥ 3	98%/91%	Free
Personality	PID-5-BF	25	Dimensional	N/A	Free
Suicidality	C-SSRS	6	Any endors.	Risk classif.	Free
OCD	OCI-R	18	≥ 21	Good	Free
Somatization	SSS-8	8	≥ 12	Comparable	Free
Dissociation	DES-II	28	≥ 30	74%/80%	Free
Eating disorders	SCOFF	5	≥ 2	84%/90%	Free
Eating dis. (detailed)	EDE-QS	12	≥ 15	Good/Good	Free
Sleep disorders	ISI	7	≥ 15	82%/82%	Free
Functioning	WHODAS 2.0 (12)	12	Dimensional	N/A	Free

6.3 Personality Disorders

ICD-11 completely replaced categorical types with a dimensional model. The DSM-5 Alternative Model for Personality Disorders (AMPD) uses the LPFS for Criterion A (functioning level) and five trait domains with 25 facets for Criterion B (pathological traits). The PID-5-BF+M bridges both systems. **Relationship to Axis II of the present model:** The AMPD itself is implicitly biaxial (functioning level + traits). Axis II of the 6-axis model adopts the trait dimension (PID-5) but extends it with biographical contextualization (formative experiences, core conflicts) and relocates the functioning level (LPFS analogue) to Axis IV (WHODAS 2.0, Mini-ICF-APP). This fully preserves the AMPD’s diagnostic information but distributes it across axes aligned with distinct professional responsibilities.

6.4 Gaming Disorder

ICD-11 (6C51) uses a monothetic approach (all 4 criteria required; ≥ 12 months). DSM-5-TR lists Internet Gaming Disorder only as a “Condition for Further Study” with a polythetic approach (≥ 5 of 9 criteria). Concordance: $\kappa = 0.80$, but ICD-11 has a higher diagnostic threshold (prevalence 2.7% vs. DSM-5 5.2%).

6.5 Prolonged Grief Disorder

ICD-11 (6B42) and DSM-5-TR (Prolonged Grief Disorder, newly added) both encode prolonged grief disorder, but differ in time criterion (ICD-11: 6 months; DSM-5-TR: 12 months) and symptom configuration. The system must accommodate both variants.

7 The Coverage Analysis: A Proposed Approach

The coverage analysis (*Coverage Analysis*) represents a central proposed component of the system. We are not aware of directly comparable implementations, although related approaches exist (e.g., Bayesian symptom–diagnosis assignment in OPCRIT). The concept encompasses the systematic identification of symptoms not explained by current diagnoses.

The closest existing parallels are: comorbidity detection algorithms that flag symptoms indicating additional diagnoses; First’s differential diagnosis tables (First, 2024), which compare overlapping presentations; and transdiagnostic frameworks such as HiTOP, in which symptoms are modeled as network nodes. Plana-Ripoll et al. (2019) demonstrated empirically that most mental disorders co-occur far more frequently than expected by chance—**prior diagnosis of any mental disorder substantially increased the risk of all other mental disorders**—which supports the rationale for a systematic coverage analysis tool.

7.1 Formal Definition of Coverage Analysis

Let $S = \{s_1, \dots, s_n\}$ be the set of observed symptoms and $D = \{d_1, \dots, d_m\}$ the set of established diagnoses. For each symptom s_i , define the coverage function $c(s_i) = \max_{d_j \in D} w(s_i, d_j)$, where $w(s_i, d_j) \in [0, 1]$ represents the weight of symptom s_i in diagnosis d_j as defined by the diagnostic criteria. The total coverage—hereafter termed the **Diagnostic Coverage Index (DCI)**—is then $C_{\text{total}} = \frac{1}{n} \sum_{i=1}^n c(s_i)$. Symptom weights are derived from the diagnostic criteria of DSM-5-TR and ICD-11. Criteria are weighted

according to diagnostic salience: cardinal symptoms receive high weights ($w \geq 0.8$), while nonspecific symptoms receive lower weights ($0.3 \leq w \leq 0.7$). This initial weighting scheme is heuristic and requires empirical calibration in future work. Overlapping diagnoses are handled by assigning each symptom to the diagnosis providing maximum coverage. The choice of the max function (rather than, e.g., a weighted mean or Bayesian posterior probability) is deliberately conservative: it asks whether *at least one* diagnosis adequately explains the symptom, thereby avoiding the summation of partial explanations that could yield falsely elevated coverage scores. This approach reflects clinical practice, where a symptom is considered “explained” when it can be attributed to an established diagnostic entity. Alternative aggregation functions (weighted sum, Bayesian posterior) should be systematically compared in future studies.

7.2 Threshold Rationale and Sensitivity

The proposed thresholds (85%/60%) should be understood as *preliminary, heuristic starting values* based on analogies to related but methodologically distinct metrics: (1) In somatic medicine, diagnostic sensitivities $\geq 85\%$ are considered clinically acceptable for screening purposes (Levis et al., 2019); this threshold was transferred to diagnostic coverage. (2) The lower threshold of 60% is modeled on the convention that Fleiss’ κ values < 0.6 are classified as “insufficient agreement.” It must be explicitly noted that diagnostic coverage is a different construct from screening sensitivity or inter-rater agreement; the analogies serve merely as orienting reference points, not as methodological justification. These starting values need empirical calibration in at least three clinical cohorts (inpatient, outpatient, somatically comorbid). Regarding sensitivity of the overall metric: since C_{total} is an arithmetic mean over n symptoms, a single weight change of Δw shifts the total by $\Delta C = \Delta w/n$. For typical symptom counts ($n = 8\text{--}15$), a misestimation of a single weight by ± 0.2 produces an overall shift of only $\pm 1.3\text{--}2.5$ percentage points—suggesting limited sensitivity to moderate weighting errors, while also showing that with few symptoms ($n < 5$) the metric becomes unstable.

7.3 Implementation

The implementation works as follows: (1) collection of all confirmed symptoms across all screening instruments, (2) assignment of each symptom to the diagnostic criteria it fulfills, (3) calculation of a coverage percentage per symptom quantifying the degree of diagnostic explanation, (4) classification as fully covered ($\geq 85\%$), partially covered (60–84%), or insufficiently covered ($< 60\%$), (5) calculation of a total coverage score as a weighted mean across all symptoms, (6) presentation of results as a symptom–diagnosis matrix with visual highlighting of diagnostic gaps. The 4P model (Axis V) serves as a natural complement: symptoms not covered by Axis I diagnoses (Axis Ii) should be explainable through the Axis V formulation; those that are not represent genuine diagnostic gaps and lead to the prioritized investigation plan (Axis Ij).

The quantitative metric (e.g., “total coverage: $\sim 88\%$ ”) provides the clinician with immediate feedback on the completeness of their diagnostic work. Related approaches exist in Bayesian diagnostic systems (e.g., DXplain, Isabel Healthcare), which perform symptom–diagnosis assignments; the specific contribution of the present coverage analysis lies in the transparent, percentage-based presentation as a clinical quality assurance metric.

It should be noted that the term “coverage analysis” has been used in medical informatics primarily for terminological mapping between classification systems (e.g., ICF vs. SNOMED CT for disability

assessment). The present model reconceptualizes coverage analysis as a clinical quality assurance metric: rather than measuring overlap between terminologies, it quantifies the proportion of a patient’s symptom profile explained by current diagnoses.

	Depression	PTSD	Hypothyroid.	$c(s_i)$
Symptom				
Low mood	0.90	0.30	0.20	0.90
Fatigue	0.70	0.20	0.80	0.80
Insomnia	0.80	0.50	0.10	0.80
Intrusions	0.10	0.95	0.00	0.95
Hyperarousal	0.15	0.90	0.05	0.90
Concentration	0.65	0.40	0.55	0.65
C_{total}				83.3%

■ $\geq 85\%$ (full)
■ 60–84% (partial)
■ $< 60\%$ (insufficient)

Figure 3: Illustrative coverage analysis matrix. Each cell shows the weight $w(s_i, d_j)$; the coverage column shows $c(s_i) = \max_j w(s_i, d_j)$. The total coverage score $C_{\text{total}} = 83.3\%$ indicates partial overall coverage, suggesting further diagnostic investigation is warranted.

The coverage analysis is symmetrically implemented in Axis III as well (sub-axis IIIi): physical symptoms not explained by any current somatic diagnosis are systematically identified and lead to the medical investigation plan (sub-axis IIIj).

8 Dimensional Integration: HiTOP and RDoC as Complementary Perspectives

While the coverage analysis quantifies completeness *within* categorical diagnostics, dimensional frameworks address a complementary limitation: the artificial boundary between diagnostic categories (Rosenman et al., 2003). The 6-axis model is primarily based on categorical diagnostics (DSM-5-TR/ICD-11) but already contains dimensional elements (PID-5, WHODAS 2.0). Two further dimensional frameworks deserve integration as complementary layers:

8.1 HiTOP (Hierarchical Taxonomy of Psychopathology)

The Hierarchical Taxonomy of Psychopathology (Kotov et al., 2017, 2022; Krueger et al., 2018) organizes mental disorders empirically-hierarchically into six spectra: Internalizing (Depression, Anxiety, PTSD), Thought Disorder (Psychosis, Mania), Disinhibited Externalizing (Substance Use, Impulse Control), Antagonistic Externalizing (Antisocial Behavior), Detachment (Social Withdrawal, Anhedonia), and Somatoform (Somatic Symptoms). The system’s Cross-Cutting results are mapped directly onto HiTOP

spectra and visualized as a radar chart. The mapping uses the maximum expression of the associated Cross-Cutting domains:

- Internalizing = max(Depression, Anxiety, Sleep)
- Thought Disorder = max(Psychosis, Mania, Dissociation)
- Disinhibited Externalizing = max(Substance)
- Antagonistic Externalizing = max(Anger)
- Detachment = max(Personality/Withdrawal)
- Somatoform = max(Somatic)

Note on HiTOP mapping: The assignments follow the current HiTOP consensus (Kotov et al., 2021): mania is assigned to the Thought Disorder spectrum (not Disinhibited Externalizing), as manic episodes in the hierarchical factor structure primarily load on the Thought Disorder factor. Dissociation is also assigned to Thought Disorder, consistent with empirical evidence for a close association with psychotic experiences. The Somatoform spectrum uses exclusively the somatic Cross-Cutting domain; depression-associated somatic burden is captured through the Internalizing spectrum. These mappings should be understood as approximations, as the Cross-Cutting domains were not developed for HiTOP scoring.

This automatic computation requires *no additional data collection*—the domain scores already captured in the Cross-Cutting screening (Section 5) are directly reused. It must be emphasized, however, that this mapping represents a *rough approximation*: the Cross-Cutting domains were not developed for HiTOP mapping, and the max function only incompletely captures the factor-analytically derived spectra. The presentation as a radar chart (visually distinct from the PID-5 personality profile) can promote recognition of transdiagnostic patterns invisible in purely categorical diagnostics, but should be interpreted as exploratory visualization, not as validated measurement.

In summary, the described mapping represents an initial approximation that should be refined with increasing empirical evidence toward HiTOP-conforming assessments (Kotov et al., 2021).

8.2 RDoC (Research Domain Criteria)

The Research Domain Criteria of the NIMH (Insel et al., 2010) define six domains (Negative Valence, Positive Valence, Cognitive Systems, Social Processes, Arousal/Regulatory, Sensorimotor) with seven levels of analysis (Genes, Molecules, Cells, Circuits, Physiology, Behavior, Self-Report). For a clinical system, RDoC is primarily relevant as *research annotation*: when biomarker data are available (e.g., cortisol profiles, neuroimaging), these can be assigned to RDoC domains. The APA Future DSM Strategic Committee is explicitly exploring biomarker integration—the system is prepared for this.

A separate concept paper describes the detailed architecture of the dimensional integration.

9 Technical Architecture of the Python Implementation

9.1 Hierarchical State Machines as Decision Engine

After evaluating four architectural approaches—AnyTree, state machines, rule engines, and behavior trees—**Hierarchical State Machines (HSMs)** using the Python library `transitions` emerged as the most practical choice for the present prototype of a psychiatric diagnostic workflow.

The transitions library with its HierarchicalMachine extension offers: conditional transitions via guards (direct mapping of “if symptom X → enter module Y”), nested states (the 6-step process with disorder-specific submodules), history states (back navigation), and serializable state (save/resume).

The architecture maps as follows:

```
Top-level: [Intake -> Step1_Malingering -> Step2_Substance ->
            Step3_Medical -> Step4_CrossCutting ->
            Step5_DisorderModules -> Step6_Functioning -> Summary]
```

Step5_DisorderModules (nested, 11 modules):

```
+-- MoodDisorders -> {MDD_Criteria, Bipolar_Screening, Dysthymia,
                      PMDD, Prolonged_Grief}
+-- AnxietyDisorders -> {GAD, Panic, Social_Anxiety, Phobias,
                        Separation_Anxiety, Selective_Mutism}
+-- TraumaDisorders -> {PTSD_DSM5, PTSD_ICD11, CPTSD_DS0,
                        Acute_Stress, Adjustment}
+-- PsychoticDisorders -> {Schizophrenia_1mo, Schizophrenia_6mo,
                           Schizoaffective, Brief_Psychotic}
+-- PersonalityDisorders -> {LPFS, PID5_Traits, ICD11_Severity}
+-- OCDSpectrum -> {OCD_Criteria, BDD, Hoarding,
                   Trichotillomania, Excoriation}
+-- DissociativeDisorders -> {DID, Depersonalization,
                              Dissociative_Anesia}
+-- EatingDisorders -> {AN, BN, BED, ARFID}
+-- NeurodevelopmentalDisorders -> {ADHD, ASD_Assessment}
+-- SubstanceUseDisorders -> {Alcohol_Use, Drug_Use,
                              Behavioral_Addictions}
+-- SomaticDisorders -> {Somatic_Symptom, Illness_Anxiety,
                        Conversion, Factitious}
```

The expansion from 5 to **11 disorder modules** is intended to ensure that each screening instrument in the matrix (Table 9) is linked to a corresponding diagnostic workflow. An elevated DES-II score triggers the DissociativeDisorders module; an elevated SCOFF score triggers the EatingDisorders module. Without this broader module set, a structural gap between screening and diagnostics would remain.

9.2 Recommended Technology Stack

Table 10: Recommended technology stack

Component	Recommendation	Rationale
Decision engine	transitions (HSM)	Nested states, guards
Tree visualization	anytree	Graphviz export, JSON
UI (prototype)	Streamlit	Rapid prototyping, <code>st.navigation</code>
PDF reports	WeasyPrint + Jinja2	Native UTF-8, HTML/CSS templates
Personality charts	Plotly	<code>px.line_polar()</code> for PID-5 radar charts
Data persistence	SQLModel + SQLite	Pydantic + SQLAlchemy combined
Data validation	Pydantic	Type-safe diagnostic criteria models
ICD-11 codes	WHO ICD-11 API	Structured diagnosis code search
Interoperability	HL7 FHIR (R4)	Standardized data exchange

9.3 Open-Source Reference Implementation

The complete source code of the prototype (V9, approx. 1,850 lines Python/Streamlit), the bilingual translation file, the development roadmap, and this paper are publicly available at:

github.com/um-bruch/multiaxial-diagnostic-system

The provision as an open-source repository serves scientific transparency and reproducibility. Installation instructions can be found in the repository’s `README.md`.

Licensing and archiving: The repository is under the MIT license, which permits both academic and commercial use but provides no warranty (cf. liability issues, Section 12). For long-term citability and versioning, the repository is already archived on Zenodo as a software record linked to the paper (concept DOI: [10.5281/zenodo.18736725](https://doi.org/10.5281/zenodo.18736725); latest public version at the time of this manuscript update: [10.5281/zenodo.19073268](https://doi.org/10.5281/zenodo.19073268)), enabling permanent referencing of a specific code version independent of changes to the GitHub repository.

10 Functional Assessment: Bridge Between Diagnosis and Disability

The integration of functional assessment connects diagnosis and participation. The model implements three levels: disorder-specific assessment (ICF Core Sets), general disability measurement (WHODAS 2.0), and legal-administrative evaluation (GdB or equivalent national framework, see Section 3.4).

ICD-11 itself has moved toward ICF integration by introducing “Functioning Properties” linked to 103 rehabilitation-relevant health conditions. For schizophrenia and psychotic disorders, ICD-11 contains **dimensional qualifiers** consistent with rehabilitation-based psychiatric care.

11 Illustrative Case Vignette

Note: The following case vignette is fictional and serves exclusively to illustrate the applicability of the 6-axis model. Any resemblance to real persons is coincidental.

Patient M., 34 years, male, initial presentation at the psychiatric outpatient clinic.

Axis I (Mental Health Profiles)

Ia (acute): Moderate depressive episode (F32.1), confidence 85%, PRO: PHQ-9 = 16, loss of drive, sleep disturbances for 4 months; CONTRA: no suicidality, preserved work capacity.

Ih (suspected): Generalized anxiety disorder (F41.1), confidence 55%, PRO: GAD-7 = 12, chronic worry; CONTRA: possibly secondary to depression.

Ii (coverage): Total coverage ~78%. Not covered: chronic back pain (somatic? functional?), concentration problems (depression-associated or independent?).

Ij (plan): Important: neuropsychological testing to clarify concentration disorder; Important: somatic workup of back pain (functional vs. structural); Monitoring: PHQ-9 every 4 weeks, C-SSRS screening if deterioration.

Axis II (Biography)

PID-5-BF+M: Elevated Negative Affectivity (T=68), borderline Detachment (T=60).

Formative experience: Early parental divorce (age 7), intermittent school bullying (ages 12–15).

Core conflict: Autonomy–dependency conflict (OPD).

Axis III (Medical Synopsis)

IIIa: Lumbar pain syndrome (M54.5). IIIc: Hypothyroidism (E03.9), contributing to fatigue—causal analysis (IIIk): TSH = 6.2 mU/L, partial explanation for loss of drive.

III m: L-Thyroxine 75 µg, efficacy 6/10; Ibuprofen 400 mg as needed, efficacy 5/10; no relevant interactions.

Axis IV (Environment & Functioning)

WHODAS 2.0 total score: 28/100 (moderate impairment). Mini-ICF-APP: restrictions in regularity (3/4), social competence (2/4). GdB: not applied for.

Stressors: Threatened job loss, relationship crisis.

Contact persons: Partner (ambivalently supportive), GP Dr. X, no therapist so far.

Axis V (Condition Model)

P1 (predisposing): Early loss experience, elevated negative affectivity.

P2 (precipitating): Job threat for 4 months, temporally concordant with symptom onset.

P3 (perpetuating): Social withdrawal, untreated hypothyroidism, pain chronification.

P4 (protective): Average intelligence, stable housing, problem awareness.

Axis VI (Evidence Collection)

Evidence matrix: PHQ-9 (21.02.2026), GAD-7 (21.02.2026), Lab (TSH, CRP—15.02.2026).

CAVE: Hypothyroidism contributing cause of fatigue—check thyroid parameters before starting antidepressant medication!

Symptom course: Loss of drive since November 2025, progressive; back pain since 2024, fluctuating.

This vignette illustrates how the 6-axis model enables an integrated diagnostic perspective: the coverage analysis (78%)—calculated as $C_{\text{total}} = \frac{1}{n} \sum c(s_i)$ across the symptoms low mood, loss of drive, sleep disturbances, worry, back pain, and concentration problems, where back pain and concentration problems

are only partially covered by existing diagnoses (cf. Section 7)—identifies unexplained symptoms. The CAVE alert flags the need to avoid premature initiation of antidepressant medication before thyroid status has been clarified, and the condition model connects biographical vulnerability with the current trigger.

12 Ethics, Data Protection, and Algorithmic Bias

Computer-assisted psychiatric diagnosis raises specific ethical questions that must be systematically addressed during development and implementation.

12.1 Algorithmic Bias and Validation Populations

Screening instruments are validated on specific populations, and the transferability of their cutoff values to other populations is limited. The PHQ-9 shows culturally variable cutoff values: while a cutoff of ≥ 10 is validated for Western populations, lower optimal thresholds are frequently observed in Asian countries. The AQ-10 has a known gender bias for women with autism spectrum disorders (overdiagnosis in men, underdiagnosis in women due to different phenotypes). For the AUDIT (alcohol screening), lower sex-specific cutoffs for women are discussed in the literature, as the standard threshold of ≥ 8 may underestimate alcohol problems in women (Saunders et al., 1993).

Socioeconomic bias: Instruments such as WHODAS 2.0 capture functional impairments that in persons of low socioeconomic status may partly be due to missing resources (e.g., transportation, childcare) rather than the mental disorder itself. The system must document these structural factors separately in Axis IV (psychosocial circumstances) to avoid misattributions.

Migration background and language barriers: Self-report instruments presuppose sufficient language competence. In persons with a migration background, linguistic misunderstandings can lead to false-positive or false-negative results. The system should issue an explicit caveat for non-native-speaking patients regarding this limitation.

Mitigation: The system must transparently document these bias risks and—where available—offer population-specific norms. The integration of the Cultural Formulation Interview (Section 3.4) addresses cultural bias at the system level. For each screening instrument, the validation population should be documented so that clinicians can assess transferability to the specific case.

12.2 Data Protection and GDPR

Psychiatric diagnostic data are among the most sensitive health data. The implementation must meet the following requirements: encryption of all stored and transmitted data (AES-256, TLS 1.3); optional access control by professional assignment (Section 3.7); audit trail for all diagnostic decisions; right to deletion and data portability; data minimization—only diagnostically necessary information is captured. Special care is needed for the evidence collection (Axis VI), which references personal documents.

12.3 Informed Consent and Patient Autonomy

The use of a computer-assisted diagnostic system raises questions of informed consent. Patients have the right to know that their diagnostic assessment is partly supported by algorithmic procedures. The system should therefore fulfill the following transparency requirements:

- **Information about system use:** Patients are informed that screening instruments and diagnostic decision trees are used as support tools.
- **Opt-out possibility:** Patients have the right to request purely human-conducted diagnostics if they do not trust the computer-assisted method.
- **Explainability of diagnostic suggestions:** The system must make transparent which symptoms and criteria led to a diagnostic suggestion. The PRO/CONTRA evidence evaluation (Section 3.1) serves exactly this purpose.
- **Access to own data:** Patients have the right to inspect their diagnostic record (Axes I–VI) and to receive explanations of the documented findings.

These requirements are not only ethically mandated but also legally anchored through the GDPR (Art. 13–15).

12.4 Liability and Medico-Legal Responsibility

The use of a computer-assisted diagnostic system does not shift liability from the clinician to the system. The following legal principles apply:

Clinician liability remains

The treating physician or psychotherapist remains fully liable for diagnostic errors, even when supported by an algorithmic system. The system is a tool, not a decision-maker.

Duty of care in system use

Clinicians must use the system competently and be aware of its limitations. Blind adoption of algorithmic diagnostic suggestions without clinical review does not fulfill the duty of care.

Documentation obligation

The use of the system and the clinical review of system suggestions should be documented (Axis VI, contact log). This serves traceability in liability cases.

Product liability of the developer

The system developer is liable for demonstrable software errors (e.g., incorrect implementation of DSM-5-TR criteria, calculation errors in the coverage analysis). The open-source publication (Section 9) enables external code reviews and increases transparency.

Medical device classification requires legal clarification

Under the EU Medical Device Regulation (MDR 2017/745), pure documentation systems without therapeutic or predictive function are not necessarily classified as medical devices. However, the present system goes beyond pure documentation: the gatekeeper logic, the algorithmic decision trees, and the diagnostic suggestions could be classified as clinical decision support software under the MDR. A legal examination of this classification is therefore *mandatory* before the system is deployed in clinical practice.

The clear separation between *diagnostic support* (permissible) and *autonomous diagnosis* (not implemented) is essential for legal protection.

12.5 Clinical Responsibility and Epistemic Boundaries

The system is designed as a *support tool*, not as a diagnostic automaton. All algorithmic diagnostic suggestions require clinical confirmation. The epistemic boundary of automatability (cf. Step 6 of the gatekeeper logic, Section 4) is explicitly communicated within the system. Final diagnostic responsibility always lies with the treating clinician.

Critical cases that algorithmic systems cannot reliably assess:

- **Suicidality:** Self-report instruments (C-SSRS) are helpful, but any endorsement of suicidal thoughts requires an in-depth clinical interview. Algorithmic risk assessments cannot replace clinical judgment.
- **Psychotic symptoms:** Self-report instruments (PQ-16) are screening tools, not diagnostic instruments. Endorsement of psychotic symptoms requires clinical exploration and often collateral history.
- **Culture-bound syndromes:** DSM-5-TR contains glossaries of culture-bound syndromes (e.g., Ataque de nervios, Taijin kyofusho) that are difficult to capture algorithmically. Here, the clinician's cultural competence is irreplaceable.

These boundaries do not render the system useless but underscore the necessity of *hybrid* diagnostics in which algorithmic support and clinical judgment operate complementarily.

13 Validation Strategy

Current status: This paper presents the conceptual architecture and technical implementation of the 6-axis model. The validation strategy described below represents an *implementation plan*—empirical validation has not yet been conducted.

Table 11 is therefore a design requirement table, not an empirical results table. Its purpose is to keep the planned validation sequence aligned with the model's central boundary: structured decision support may be evaluated before clinical efficacy is claimed, but it must not be presented as validated clinical diagnosis without the corresponding gate data.

Phase 1: Expert Review (N=10–15)

Structured review of axis architecture by psychiatrists, clinical psychologists, and social workers. Assessment of completeness, clinical plausibility, and practicability.

Phase 2: Inter-Rater Reliability Study with Case Vignettes (N=10 raters, 20 vignettes)

This is the critical pilot study for initial system validation:

Recruitment: $N = 10$ independent raters (5 psychiatrists, 5 licensed psychologists; all with ≥ 3 years of clinical experience).

Stimulus material: 20 standardized case vignettes (10 simple single-diagnosis cases, 10 complex comorbidity cases), created following the model of the DSM-5-TR Clinical Cases (Barnhill, 2014). Each vignette contains: history, current complaints, symptom course, relevant medical history, social environment. Diagnoses established in advance by expert panel (2 independent specialists + consensus process) as gold standard.

Table 11: Validation-gate ledger for the planned post-design evaluation. The rows define the minimum data object that must be collected before a design claim can be upgraded to a process, utility, or clinical-validity claim.

Gate	Minimum data object	Pass / hold rule	Overclaim prevented
Diagnostic reasoning ledger	Extracted findings, differential hypotheses, rule/backing, exclusion criteria, uncertainty, and reviewer notes	Pass only if primary diagnoses and rejected alternatives are traceable from patient data to clinical rule and expert review	Treating top-1 diagnostic agreement or an LLM suggestion as demonstrated reasoning quality
Consultation evidence-gathering gate	Question log for missing DSM/ICD criteria, duration, function, collateral history, and somatic exclusions	Hold if a missing criterion is inferred from silence rather than actively queried or marked as unavailable	Treating static vignette accuracy as consultation competence
Synthetic-vignette fidelity and fairness	Vignette manifest with demographics, base-rate assumptions, threshold distributions, and subgroup error checks	Pass only if synthetic cases preserve clinically plausible variance and do not collapse rare or minority profiles	Treating plausible single vignettes as population-valid evaluation data
AI-agent governance gate	Role definition, human-in-the-loop point, escalation rule, audit log, privacy boundary, and post-deployment monitoring plan	Hold if the system can act as an autonomous diagnostic agent or if responsibility cannot be assigned	Treating an assistive prototype as clinically validated autonomous AI
ICD-coding boundary	Mapping from clinical decision to administrative ICD code, including coder role and disagreement handling	Pass only if coding output is explicitly downstream of, and does not alter, the clinical diagnostic conclusion	Treating coding accuracy as diagnostic validity
Axis VI biomarker queue	Signal provenance, validation population, leakage check, subgroup analysis, and prospective confirmation status	Hold unless wearable, voice, EMA, or chronobiological signals remain candidate cues until replicated	Treating exploratory digital signals as diagnostic biomarkers

Procedure: Each rater diagnoses all 20 vignettes (1) using conventional approach (free-text diagnosis with rationale), (2) using the 6-axis system (complete axis diagnostics). Method order randomized; at least 1 week washout between conditions per vignette.

Primary outcome variables:

- *Inter-rater reliability:* Fleiss' κ for categorical diagnoses (Axis I primary diagnosis); ICC for dimensional ratings (PID-5-BF on Axis II, WHODAS 2.0 on Axis IV). Acceptance criterion: $\kappa \geq 0.7$ (substantial agreement); $ICC \geq 0.75$.
- *Convergent validity:* Agreement of 6-axis diagnoses vs. gold standard. Sensitivity and specificity per diagnosis.
- *Incremental validity of coverage analysis:* Proportion of cases where Axis Ii (unexplained symptoms) identifies clinically relevant differential diagnoses missed in free-text approach. Hypothesis: $\geq 20\%$ of complex cases benefit from coverage analysis.
- *Time-on-task:* Average processing time per vignette (conventional vs. 6-axis).

Secondary outcome variables:

- System Usability Scale (SUS) after completion of all vignettes
- Subjective assessment of usefulness of individual axes (5-point Likert)
- Qualitative interviews on identified system weaknesses

Power analysis: With $N = 10$ raters and $k = 20$ vignettes (targets), an $ICC = 0.75$ can be tested with power $1 - \beta = 0.8$ and $\alpha = 0.05$ against the null hypothesis $ICC = 0.5$. The precise CI width depends on the number of targets, not on the total number of judgments ($N \times k = 200$), since these are not independent. With $k = 20$ targets and $N = 10$ raters, a 95%

CI of approximately ± 0.15 is expected (Shrout & Fleiss, 1979). An increase to $k = 30$ vignettes would substantially improve precision and should be pursued if resources permit.

Falsification criterion: If $\kappa < 0.6$ or ICC < 0.65 , inter-rater reliability is insufficient—requiring revision of axis structure or clearer operationalizations.

Phase 3: Clinical Field Trial (N=200+)

Prospective application in clinical settings (outpatient and inpatient). Measurement of: inter-rater reliability, convergent validity, incremental validity of coverage analysis, acceptance and usability (System Usability Scale, SUS).

Phase 4: Multi-Site Trial

Multicenter study for generalizability. Comparison of inpatient vs. outpatient, adults vs. children/adolescents, various cultural contexts.

The MentalBench benchmark (Song et al., 2026) demonstrates that large language models systematically fail at complex duration, functional, and exclusion criteria in psychiatric diagnosis, reinforcing the rationale for rule-based decision support systems with explicit gatekeeper logic over purely statistical approaches. Given the rapid advances in LLM-based clinical support, it should be emphasized that the present system and AI-based approaches are complementary, not competing: the 6-axis model provides the structured architecture and explicit decision logic important for clinical traceability and liability protection—properties that black-box models may not consistently offer. Future implementations could use LLMs as *assistive systems within* the rule-based architecture (e.g., for free-text analysis of history reports) without compromising the transparency of the decision path.

14 Interoperability and Health IT Standards

For integration into existing health information systems, the 6-axis model must implement standards-compliant interfaces.

HL7 FHIR (R4): The axes can be mapped to FHIR resources: Axis I/III diagnoses as `Condition` resources with extensions for sub-axis assignment; screening results as `QuestionnaireResponse`; functional status (Axis IV) as `ClinicalImpression`; case formulation (Axis V) as `CarePlan`; evidence (Axis VI) as `DocumentReference`.

SNOMED CT: All diagnoses should carry SNOMED CT concept IDs alongside DSM-5-TR and ICD-11 codes to ensure international interoperability.

LOINC: For laboratory values (Axis IIIe/IIIIf), clinical observations, and screening results, LOINC codes (Logical Observation Identifiers Names and Codes) should be used. This enables standardized documentation and exchange of laboratory findings and psychometric test results in the evidence matrix (Axis VI).

MHIRA compatibility: The MHIRA project (Mental Health Information Reporting Assistant, BMC Psychiatry 2023) represents the most relevant open-source reference architecture: a cloud-based, Docker-deployed psychiatric EHR system with digitized psychometric instruments. A FHIR-based interface to the MHIRA system should be prioritized.

15 Discussion and Outlook

The presented 6-axis model is not a return to DSM-IV but represents a **proposed advancement** toward which the psychiatric field itself is converging. Ten proposed design features deserve particular emphasis:

First, the coverage analysis (Section 7) extends existing decision-support methods with a quantitative quality assurance metric. While related approaches exist in Bayesian diagnostic systems, the specific contribution lies in the clinical quality assurance perspective: it addresses the fundamental problem of transdiagnostic comorbidity documented by Plana-Ripoll et al. (2019) and is symmetrically implemented in Axis I (Ii) and Axis III (IIIi).

Second, the operationalized integration of case formulation (Axis V) with diagnostic classification bridges the long-standing gap between “What disorder does this patient have?” and “Why does this patient have this disorder?”

Third, the dual-system architecture DSM-5-TR/ICD-11 addresses a real clinical need in contexts where both systems are applied.

Fourth, the symmetric parallel structure of Axes I and III ensures that the system functions as a shared tool for all participating professions. In the computer-assisted diagnostic systems compared here (OPCRIT, DTREE, CATEGO, CIDI, MHIRA), no such design principle was identified; however, a systematic literature review encompassing less well-known or institution-internal systems is still pending and is required for a definitive assessment of the novelty of this approach.

Fifth, the expansion to 11 disorder modules aims for end-to-end coverage between screening and diagnostics: each screening instrument is linked to a structured diagnostic workflow.

Sixth: Application in training and supervision. The system appears well suited as a teaching and supervision tool in psychiatric and psychotherapeutic training. The PRO/CONTRA structure requires trainees to explicitly justify diagnostic decisions and systematically document counterarguments—a skill not structurally demanded in conventional free-text diagnostics. The Diagnostic Coverage Index (DCI) provides supervisors with quantitative feedback on trainees’ diagnostic completeness: a low DCI score makes diagnostic gaps visible that can be addressed in case conferences. In psychotherapy training, Axis V (Condition Model) offers a structured alternative to unstructured case formulations that are often idiosyncratic and difficult to compare.

Seventh, the PRO/CONTRA evidence evaluation with numerical confidence operationalizes differential-diagnostic transparency: the clinician documents not only *which* diagnosis they make but also *why*—including the deliberately rejected counterarguments. This transparency can support *Shared Decision Making* (SDM): patients can understand the evidence basis and remaining uncertainties underlying their diagnosis, fostering therapeutic alliance and patient autonomy. The structured PRO/CONTRA presentation corresponds to the third step of the SDM model (information exchange and deliberation) and creates a shared decision basis between clinician and patient.

Eighth, the CAVE warning system in Axis VI implements a cross-axis safety layer that prominently flags critical clinical risks (lab artifacts, drug interactions, contraindications, temporal misattributions). Given the well-documented polypharmacy problem in psychiatry—particularly with comorbid somatic conditions—the CAVE system addresses a frequent clinical error source not systematically addressed in existing classification systems.

Ninth, the longitudinal symptom course complements cross-sectional diagnostics with a temporal dimension: the documentation of symptom onset, current status, and therapy response enables identi-

fication of chronification patterns and therapy resistance essential for treatment planning. Axis VI can thereby function as an *integrated Routine Outcome Monitoring (ROM)* system in the sense of Barkham et al. (2023): the regular assessment of validated instruments (PHQ-9, GAD-7, PCL-5) with course visualization enables early detection of not-on-track courses and supports adaptive treatment planning.

Tenth, the design philosophy of the *living document* realizes a paradigm that understands the diagnostic record not as a one-time form but as an evolving process documentation. Contact network (Axis IV), formative experiences and core conflicts (Axis II), and the contact and observation log (Axis VI) are open lists that document the diagnostic process itself and continuously provide material for case formulation (Axis V).

Methodological positioning. Within the design science framework (Hevner et al., 2004; Peffers et al., 2007), the present paper covers Problem Identification, Design & Development, and Demonstration (prototype and case vignette). The formal Evaluation phase—constitutive for a complete design science cycle—remains pending and is addressed by the four-phase strategy described in Section 13. The paper thus positions itself as a design research contribution, not as a completed evaluation.

Clinical practicability and time-on-task: A central question for clinical adoption is processing time. For a complete initial assessment across all six axes, a processing time of 90–120 minutes is expected (including screening, history-taking, and documentation)—comparable to a comprehensive psychiatric intake but considerably longer than a focused outpatient consultation (20–50 minutes). The skeleton principle, however, enables graduated use: a minimal assessment (Axis I with Cross-Cutting screening and Axis IV with WHODAS 2.0) is feasible in 30–45 minutes; the remaining axes are supplemented over time. The differentiation of inpatient and outpatient use is essential for the planned validation: inpatient teams can work through the axes collaboratively over several days; outpatient solo practitioners require the graduated approach. This distinction should be systematically investigated in Phase 3 of the validation (clinical field trial).

Relationship to Process-Based Therapy (PBT): The PBT movement argues against diagnostic categories and for purely process-based intervention planning. The 6-axis model positions itself as a bridge: it retains categorical diagnostics (clinically, administratively, and insurance-legally necessary) but integrates process-oriented elements through Axis V (Condition Model) and the coverage analysis—particularly the identification of perpetuating factors (P3) and unexplained symptoms that may point to treatable processes beyond categorical logic.

The technical implementation should prioritize four milestones: (1) the Cross-Cutting screening module as the system's entry point, (2) the gatekeeper state machine using transitions HSM, (3) the PID-5-BF assessment with Plotly radar chart and WeasyPrint PDF export, and (4) the FHIR interface definition for interoperability.

Implementation barriers: Experience with previous multiaxial systems and clinical IT introductions shows that technical functionality alone does not guarantee adoption. Expected barriers include: (1) time constraints in clinical practice, particularly in understaffed outpatient settings; (2) institutional inertia and resistance to new documentation systems initially perceived as additional burden; (3) the need for interdisciplinary coordination, which is organizationally challenging in fragmented care structures; and (4) integration into existing hospital information systems (HIS), which have proprietary interfaces and limited extensibility. The skeleton principle and graduated use (cf. time-on-task above) partially address the time barrier; the remaining barriers require an accompanying implementation strategy in the spirit of

the CFIR framework (Damschroder et al., 2009).

16 Limitations and Future Research Needs

The presented 6-axis model is subject to several limitations that must be considered in interpretation and further development.

No empirical validation. The central limitation is that the model has been developed on a purely conceptual-theoretical basis. Neither inter-rater reliability nor convergent or incremental validity have been empirically tested. The 4-phase validation strategy described in Section 13 represents a research plan, not existing results. Until at least Phases 1 and 2 are completed, the clinical utility of the model remains a justified hypothesis.

Complexity and clinical practicability. The system comprises six axes with a total of 40 sub-axes. Although the skeleton principle provides no mandatory fields, the complexity may be off-putting in clinical practice. A key research question is whether clinicians actually use the system at the intended depth or reduce it to a few axes. Usability studies (SUS scale) are essential.

Scalability of the weight matrix. The coverage analysis presupposes a complete weight matrix $w(s_i, d_j)$ for all symptom–diagnosis combinations. With over 300 DSM-5-TR diagnoses and several hundred ICD-11 codes, the manual creation and maintenance of this matrix is a considerable effort. A pragmatic solution is to calculate weights only for the diagnoses relevant in a given case (typically 3–8 differential diagnoses), reducing the matrix to manageable size. Long-term, weights could be semi-automatically derived from structured criteria catalogues (e.g., SNOMED CT concepts, ICD-11 Foundation Layer).

No normation of coverage analysis. The quantitative coverage analysis (Axis Ii/IIIi) uses percentage-based metrics for which no empirical norms exist. The thresholds (85%/60%) are motivated by clinical analogies (cf. Section 7) but not empirically validated. The sensitivity analysis shows robustness for $n \geq 8$ symptoms but instability for small symptom counts. Empirical calibration in at least three clinical cohort groups (inpatient, outpatient, somatically comorbid) is a prerequisite for clinical adoption.

Limited literature base. As a design work, this paper draws primarily on diagnostic classification manuals and a small number of foundational publications. A systematic review of all existing computer-assisted diagnostic systems (e.g., OPCRIT, DTREE, CATEGO) and their empirical track records would strengthen the rationale for the specific design decisions made here.

AI-supported process documentation. The substantial use of AI-assisted tools in both system design and manuscript preparation (i.e., literature organization, text structuring, translation assistance, consistency checking, and drafting assistance; cf. Methods, Phase 4) raises process-transparency questions. While the source code is publicly available, the iterative prompt, review, and revision history—including expert feedback cycles—is not fully documented in a way that permits complete process reconstruction.

Cultural generalizability and jurisdiction-specific modules. The model integrates the Cultural Formulation Interview (CFI) but was primarily developed from a Western European perspective. Jurisdiction-specific sub-axes such as the GdB (Axis IVb) are designed as interchangeable modules: for international implementations, the GdB should be replaced with the respective national disability assessment system (e.g., Disability Adjusted Life Years in WHO contexts, Social Security Disability Determination in the U.S.). Applicability in non-Western clinical contexts requires separate examination. In particular, the

personality assessment via PID-5 and the biographical components (Axis II) may be interpreted differently across cultures.

Technology dependence. The implementation as a computer-assisted decision support system presupposes functioning IT infrastructure. In resource-poor settings or during system failures, the model must also function as a paper-based schema—a requirement that has not yet been systematically tested.

Missing stakeholder perspectives and cost-effectiveness. The present paper is primarily written from a system developer’s perspective. Important viewpoints are absent: How do patients experience such a comprehensive assessment? How does the time-on-task compare to conventional diagnostics? How do payers (e.g., health insurers) evaluate the additional diagnostic effort? Future studies should include a time-on-task analysis, a cost-benefit evaluation, and a systematic assessment of the patient perspective.

Learning health system perspective. The structured, standards-coded data generated by the 6-axis model (ICD-11, SNOMED CT, ICF, PID-5) are ideally suited for secondary research use. In a learning health system paradigm, each diagnostic episode contributes to iterative refinement of the coverage analysis weight matrix: empirical symptom–diagnosis associations from aggregated, anonymized patient data can progressively replace the initial weights with data-driven estimates. This perspective connects routine clinical application with continuous system optimization.

Future research needs. Beyond empirical validation (Section 13), four research directions are prioritized: (1) developing an abbreviated “rapid assessment” mode for emergency departments and initial consultations, (2) integrating predictive models (machine learning) to support differential diagnostics based on accumulated patient data, (3) longitudinal studies on the sensitivity of symptom course (Axis VI) for therapy response and relapse prediction, and (4) integration of Ecological Momentary Assessment (EMA) and digital phenotyping: smartphone-based real-time data collection could enrich the longitudinal symptom course (Axis VI) with continuous behavioral data, substantially increasing the temporal resolution of diagnostic documentation. Furthermore, actual clinical adoption should be accompanied by an implementation science framework—such as the Consolidated Framework for Implementation Research (CFIR)—that systematically identifies barriers to and facilitators of adoption across the five CFIR domains (Intervention Characteristics, Outer Setting, Inner Setting, Individuals, Process). The historical experience with the DSM-IV multi-axial system demonstrates that even well-designed systems can fail due to inconsistent clinical use.

17 Conclusion

The proposed 6-axis system responds to a structural gap in psychiatric diagnostics that has persisted since the abolition of the DSM-IV multi-axial system. For clinical practice, the model’s primary contribution lies in restoring and extending the structured prompt for comprehensive biopsychosocial assessment. The symmetric Axis I/III architecture enables structured multi-professional collaboration, the coverage analysis provides clinicians with a transparent, quantitative metric for diagnostic completeness, and the CAVE alert system addresses the growing challenge of cross-axis risk management in complex cases. The PRO/CONTRA evidence evaluation with confidence estimation operationalizes diagnostic transparency in a way that supports both clinical accountability and training.

The model’s architecture is consistent with the institutional direction of development (cf. Section 2). The convergence with the explicit call by Erlich et al. (2025) for a return to structured axial assessment supports the timeliness of this contribution. At the same time, the model extends beyond institutional

revisions, particularly through the coverage analysis and the operationalized case formulation (Axis V) that bridges classification and treatment planning.

Concrete next steps include: (1) a focused expert review ($N = 5\text{--}10$) of the axis structure as an immediate minimal step, (2) the inter-rater reliability study with standardized case vignettes (Phase 2, Section 13), (3) the development of the HL7 FHIR mapping specification, (4) the publication of the formal mathematical specification of the coverage analysis, and (5) empirical comparisons of free-text documentation versus structured multi-axial diagnostics. The complete source code is publicly available to support independent evaluation and replication.

In summary, the 6-axis model is a draft diagnostic architecture that combines categorical classification, dimensional assessment, and individualized case formulation in a single computer-assisted system. Its clinical value now depends on expert review, reliability testing, and prospective evaluation.

References

- Aboraya, A., Rankin, E., France, C., El-Missiry, A. & John, C. (2006). The reliability of psychiatric diagnosis revisited: The clinician's guide to improve the reliability of psychiatric diagnosis. *Psychiatry (Edgmont)*, 3(1), 41–50. PMID: 21103149.
- Achenbach, T. M. & Rescorla, L. A. (2001). *Manual for the ASEBA School-Age Forms & Profiles*. Burlington, VT: University of Vermont, Research Center for Children, Youth, & Families.
- Allison, C., Auyeung, B. & Baron-Cohen, S. (2012). Toward brief “red flags” for autism screening: The Short Autism Spectrum Quotient and the Short Quantitative Checklist in 1,000 cases and 3,000 controls. *Journal of the American Academy of Child & Adolescent Psychiatry*, 51(2), 202–212.e7. DOI: 10.1016/j.jaac.2011.11.003.
- American Psychiatric Association (1980). *Diagnostic and Statistical Manual of Mental Disorders* (3rd ed.). Washington, DC: American Psychiatric Publishing.
- American Psychiatric Association (2013). *Diagnostic and Statistical Manual of Mental Disorders* (5th ed.). Arlington, VA: American Psychiatric Publishing.
- American Psychiatric Association (2022). *Diagnostic and Statistical Manual of Mental Disorders, Text Revision* (DSM-5-TR). Washington, DC: American Psychiatric Publishing.
- Ayuso-Mateos, J. L., Avila, C. C., Anaya, C., Cieza, A. & Vieta, E. (2013). Development of the International Classification of Functioning, Disability and Health core sets for bipolar disorders: Results of an international consensus process. *Disability and Rehabilitation*, 35(25), 2138–2146. DOI: 10.3109/09638288.2013.771708.
- Bach, B., Kramer, U., Doering, S. et al. (2022). The ICD-11 classification of personality disorders: A European perspective on challenges and opportunities. *Borderline Personality Disorder and Emotion Dysregulation*, 9(1), 12.
- Barkham, M., De Jong, K., Delgadillo, J. & Lutz, W. (2023). Routine Outcome Monitoring (ROM) and Feedback: Research Review and Recommendations. *Psychotherapy Research*, 33(7), 841–855. DOI: 10.1080/10503307.2023.2181114.

- Barnhill, J. W. (Ed.) (2014). *DSM-5 Clinical Cases*. Washington, DC: American Psychiatric Publishing.
- Mayall, M., McDermott, B., Sadhu, R., Teoh, Y., Bosanquet, M. & Nundeeekasen, S. (2024). Practical aspects of multiaxial classification: A clinically useful biopsychosocial framework for child and adolescent psychiatry. *BJPsych Advances*, 30(4), 242–256. DOI: 10.1192/bja.2023.39.
- Blevins, C. A., Weathers, F. W., Davis, M. T. et al. (2015). The Posttraumatic Stress Disorder Checklist for DSM-5 (PCL-5). *Journal of Traumatic Stress*, 28(6), 489–498.
- Bolton, D. (2008). *What is Mental Disorder? An Essay in Philosophy, Science, and Values*. Oxford: Oxford University Press.
- Carlson, E. B. & Putnam, F. W. (1993). An update on the Dissociative Experiences Scale. *Dissociation*, 6(1), 16–27.
- Cieza, A., Chatterji, S., Andersen, C. et al. (2004). ICF Core Sets for depression. *Journal of Rehabilitation Medicine*, 36(Suppl. 44), 128–134. DOI: 10.1080/16501960410016055.
- Cloitre, M., Shevlin, M., Brewin, C. R. et al. (2018). The International Trauma Questionnaire: Development of a self-report measure of ICD-11 PTSD and Complex PTSD. *Acta Psychiatrica Scandinavica*, 138(6), 536–546.
- Damschroder, L. J., Aron, D. C., Keith, R. E. et al. (2009). Fostering implementation of health services research findings into practice: A consolidated framework for advancing implementation science. *Implementation Science*, 4, 50.
- Erlich, M. D., First, M. B., Talley, R. M. et al. (2025). Integrating social determinants of health into clinical formulations: The need for a biaxial system in the DSM and psychiatry. *Psychiatric Services*, 76(10), 911–914.
- First, M. B., Williams, J. B. W. & Spitzer, R. L. (1993). DTREE: A decision-support system for DSM-III-R and DSM-IV diagnoses. *Psychopharmacology Bulletin*, 29(3), 255–263.
- First, M. B. (2024). *DSM-5-TR Handbook of Differential Diagnosis*. Washington, DC: American Psychiatric Publishing.
- Foa, E. B., Huppert, J. D., Leiberg, S. et al. (2002). The Obsessive-Compulsive Inventory: Development and validation of a short version. *Psychological Assessment*, 14(4), 485–496.
- Gierk, B., Kohlmann, S., Kroenke, K., Spangenberg, L., Zenger, M., Brähler, E. & Löwe, B. (2014). The Somatic Symptom Scale-8 (SSS-8): A brief measure of somatic symptom burden. *JAMA Internal Medicine*, 174(3), 399–407.
- Gómez-Benito, J., Guílera, G., Barrios, M. et al. (2018). Beyond diagnosis: The Core Sets for persons with schizophrenia based on the World Health Organization's International Classification of Functioning, Disability, and Health. *Disability and Rehabilitation*, 40(23), 2756–2766. DOI: 10.1080/09638288.2017.1356384.

- Gspandl, S., Peirson, R. P., Nahhas, R. W., Skale, T. G. & Lehrer, D. S. (2018). Comparing Global Assessment of Functioning (GAF) and World Health Organization Disability Assessment Schedule (WHODAS) 2.0 in schizophrenia. *Psychiatry Research*, 259, 251–253.
- Hevner, A. R., March, S. T., Park, J. & Ram, S. (2004). Design science in information systems research. *MIS Quarterly*, 28(1), 75–105.
- Insel, T., Cuthbert, B., Garvey, M. et al. (2010). Research Domain Criteria (RDoC): Toward a new classification framework for research on mental disorders. *American Journal of Psychiatry*, 167(7), 748–751.
- Ising, H. K., Veling, W., Loewy, R. L. et al. (2012). The validity of the 16-item version of the Prodromal Questionnaire (PQ-16) to screen for ultra high risk of developing psychosis. *Schizophrenia Research*, 138(2–3), 207–212.
- Keeley, J. W., Reed, G. M., Roberts, M. C. et al. (2016). Developing a science of clinical utility in diagnostic classification systems: Field study strategies for ICD-11 mental and behavioural disorders. *American Psychologist*, 71(1), 3–16.
- Kessler, R. C. & Üstün, T. B. (2004). The World Mental Health (WMH) Survey Initiative version of the World Health Organization (WHO) Composite International Diagnostic Interview (CIDI). *International Journal of Methods in Psychiatric Research*, 13(2), 93–121.
- Kessler, R. C., Adler, L., Ames, M. et al. (2005). The World Health Organization Adult ADHD Self-Report Scale (ASRS). *Psychological Medicine*, 35(2), 245–256.
- Kotov, R., Krueger, R. F., Watson, D. et al. (2017). The Hierarchical Taxonomy of Psychopathology (HiTOP): A dimensional alternative to traditional nosologies. *Journal of Abnormal Psychology*, 126(4), 454–477.
- Kotov, R., Krueger, R. F., Watson, D. et al. (2021). The Hierarchical Taxonomy of Psychopathology (HiTOP): A quantitative nosology based on consensus of evidence. *Annual Review of Clinical Psychology*, 17, 83–108.
- Kotov, R., Cicero, D. C., Conway, C. C. et al. (2022). The Hierarchical Taxonomy of Psychopathology (HiTOP) in psychiatric practice and research. *Psychological Medicine*, 52(9), 1666–1678. DOI: 10.1017/S0033291722001301.
- Kress, V. E., Barrio Minton, C. A., Adamson, N. A., Paylo, M. J. & Pope, V. (2014). The removal of the multi-axial system in the DSM-5: Implications and practice suggestions for counselors. *The Professional Counselor*, 4(3), 191–201.
- Krueger, R. F., Kotov, R., Watson, D. et al. (2018). Progress in achieving quantitative classification of psychopathology. *World Psychiatry*, 17(3), 282–293.
- Levis, B., Benedetti, A. & Thombs, B. D. (2019). Accuracy of Patient Health Questionnaire-9 (PHQ-9) for screening to detect major depression. *BMJ*, 365, 11476.

- Linden, M. & Baron, S. (2005). Das Mini-ICF-Rating für psychische Störungen (Mini-ICF-P): Ein Kurzinstrument zur Beurteilung von Fähigkeitsstörungen bei psychischen Erkrankungen. *Die Rehabilitation*, 44(3), 144–151. DOI: 10.1055/s-2004-834786.
- Luciano, J. V., Ayuso-Mateos, J. L., Aguado, J. et al. (2010). The 12-item World Health Organization Disability Assessment Schedule II (WHO-DAS II): A nonparametric item response analysis. *BMC Medical Research Methodology*, 10, 45.
- McGuffin, P., Farmer, A. & Harvey, I. (1991). A polydiagnostic application of operational criteria in studies of psychotic illness: Development and reliability of the OPCRIT system. *Archives of General Psychiatry*, 48(8), 764–770.
- Morgan, J. F., Reid, F. & Lacey, J. H. (1999). The SCOFF questionnaire: Assessment of a new screening tool for eating disorders. *BMJ*, 319(7223), 1467–1468.
- Morin, C. M., Belleville, G., Bélanger, L. & Ivers, H. (2011). The Insomnia Severity Index: Psychometric indicators to detect insomnia cases and evaluate treatment response. *Sleep*, 34(5), 601–608.
- Narrow, W. E., Clarke, D. E., Kuramoto, S. J. et al. (2013). DSM-5 field trials in the United States and Canada, Part III. *American Journal of Psychiatry*, 170(1), 71–82.
- Oltmanns, J. R. & Widiger, T. A. (2018). A self-report measure for the ICD-11 dimensional trait model proposal: The Personality Inventory for ICD-11. *Psychological Assessment*, 30(2), 154–169.
- Owen, G. (2023). What is formulation in psychiatry? *Psychological Medicine*, 53(5), 1700–1707. DOI: 10.1017/S0033291723000016.
- Peffer, K., Tuunanen, T., Rothenberger, M. A. & Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3), 45–77.
- Plana-Ripoll, O., Pedersen, C. B., Holtz, Y. et al. (2019). Exploring Comorbidity Within Mental Disorders Among a Danish National Population. *JAMA Psychiatry*, 76(3), 259–270.
- Posner, K., Brown, G. K., Stanley, B. et al. (2011). The Columbia-Suicide Severity Rating Scale (C-SSRS). *American Journal of Psychiatry*, 168(12), 1266–1277.
- Probst, B. (2014). The life and death of Axis IV: Caught in the quest for a theory of mental disorder. *Research on Social Work Practice*, 24(1), 123–131. DOI: 10.1177/1049731513491326.
- Regier, D. A., Narrow, W. E., Clarke, D. E. et al. (2013). DSM-5 field trials in the United States and Canada, Part II: Test-retest reliability of selected categorical diagnoses. *American Journal of Psychiatry*, 170(1), 59–70.
- Riegel, K. D., Ksinan, A. J. & Schlosserova, L. (2021). Psychometric properties of the independent 36-item PID5BF+M for ICD-11 in the Czech-speaking community sample. *Frontiers in Psychiatry*, 12, 643270. DOI: 10.3389/fpsy.2021.643270.
- Rosenman, S. J., Korten, A. E., Medway, J. & Evans, M. (2003). Dimensional vs. categorical diagnosis in psychosis. *Acta Psychiatrica Scandinavica*, 107(5), 378–384.

- Saunders, J. B., Aasland, O. G., Babor, T. F. et al. (1993). Development of the Alcohol Use Disorders Identification Test (AUDIT). *Addiction*, 88(6), 791–804.
- Shrout, P. E. & Fleiss, J. L. (1979). Intraclass correlations: Uses in assessing rater reliability. *Psychological Bulletin*, 86(2), 420–428.
- Song, H., Kang, M., Shin, J. et al. (2026). MentalBench: A DSM-Grounded Benchmark for Evaluating Psychiatric Diagnostic Capability of Large Language Models. *arXiv preprint arXiv:2602.12871*. DOI: 10.48550/arXiv.2602.12871.
- Spitzer, R. L., Kroenke, K., Williams, J. B. W. & Löwe, B. (2006). A brief measure for assessing Generalized Anxiety Disorder: The GAD-7. *Archives of Internal Medicine*, 166(10), 1092–1097.
- Zimmermann, R., Konjufca, J., Sakejo, P. et al. (2023). Mental Health Information Reporting Assistant (MHIRA)—an open-source software facilitating evidence-based assessment for clinical services. *BMC Psychiatry*, 23, 706. DOI: 10.1186/s12888-023-05201-0.
- Wakefield, J. C. (1992). The concept of mental disorder: On the boundary between biological facts and social values. *American Psychologist*, 47(3), 373–388.
- World Health Organization (2010). *WHODAS 2.0: WHO Disability Assessment Schedule 2.0*. Geneva: WHO.
- World Health Organization (2019). *International Classification of Diseases, 11th Revision (ICD-11)*. Geneva: WHO.
- Williams, J. B. W. (1985). The multi-axial system of DSM-III: Where did it come from and where should it go? I. Its origins and critiques. *Archives of General Psychiatry*, 42(2), 175–180.
- Wing, J. K., Cooper, J. E. & Sartorius, N. (1974). *Measurement and Classification of Psychiatric Symptoms: An Instruction Manual for the PSE and CATEGO Program*. Cambridge: Cambridge University Press.

Ein integriertes multiaxiales Modell zur computergestützten psychiatrischen Diagnostik

Synthese von DSM-5-TR, ICD-11 und ICF
in einem 6-Achsen-Entscheidungsunterstützungssystem

Ein Methoden- und Designpapier

Lukas Geiger^{*1}

¹Unabhängiger Forscher, Bernau

Juni 2026

Zusammenfassung

Die Abschaffung des multiaxialen Diagnosesystems im DSM-5 (2013) hinterließ eine strukturelle Lücke in der psychiatrischen Diagnostik. Die vorliegende Arbeit präsentiert ein 6-Achsen-Modell zur computergestützten multiaxialen Diagnostik, das die kategoriale Klassifikation nach DSM-5-TR und ICD-11 mit der funktionalen Erfassung der ICF in einem Entscheidungsunterstützungssystem vereint. Das Modell umfasst: Achse I (Psychische Profile mit temporaler Diagnostik und quantitativer Abdeckungsanalyse), Achse II (dimensionale Persönlichkeitsdiagnostik mittels PID-5 und biographische Kontextualisierung), Achse III (Medizinische Synopse in symmetrischer Parallelstruktur zu Achse I), Achse IV (ICF-Integration, WHODAS 2.0, Cultural Formulation), Achse V (operationalisierte Fallformulierung im 3P/4P-Modell) und Achse VI (Evidenz-Matrix, CAVE-Warnhinweise, longitudinale Symptomverlaufsdokumentation). Drei zentrale Designbeiträge werden hervorgehoben: (1) die quantitative Abdeckungsanalyse (Diagnostic Coverage Index) als prozentbasierte Metrik für diagnostische Vollständigkeit, (2) die symmetrische Achse-I/III-Architektur für multiprofessionelle Zusammenarbeit und (3) die operationalisierte Verbindung von Klassifikation und individualisierter Fallformulierung. Die 6-Stufen-Gatekeeper-Logik bildet die von First (2024) publizierte Differenzialdiagnostik-Sequenz ab. Eine Python-Referenzimplementierung als hierarchische Zustandsmaschine ist öffentlich verfügbar. Dies ist ein Methoden- und Designpapier; die empirische Validierung steht noch aus.

Schlüsselbegriffe: Multiaxiale Diagnostik, DSM-5-TR, ICD-11, Abdeckungsanalyse, Entscheidungsunterstützungssystem, HiTOP, HL7 FHIR, Fallformulierung, ICF

^{*}Korrespondenz: Lukas Geiger, Bernau, Deutschland. ORCID: [0009-0005-7296-1534](https://orcid.org/0009-0005-7296-1534)

Inhaltsverzeichnis

Erklärung zur Nutzung KI-gestützter Werkzeuge	3
1 Methodik	4
2 Einleitung: Die diagnostische Lücke nach Abschaffung des multiaxialen Systems	5
2.1 Institutionelle Konvergenz	7
2.2 Designphilosophie: Skelett, lebendes Dokument, maximale Freiheit	7
3 Architektur des 6-Achsen-Modells	8
3.1 Achse I: Psychische Profile — Temporale Diagnostik	9
3.2 Achse II: Biographie und dimensionale Persönlichkeit	10
3.3 Achse III: Medizinische Synopse — Symmetrische Parallelstruktur zu Achse I	11
3.4 Achse IV: Umwelt und Funktion — ICF-Integration und Cultural Formulation	12
3.4.1 Bezugspersonen und Behandlungsnetzwerk	13
3.4.2 Cultural Formulation Interview (CFI)	13
3.5 Achse V: Integriertes Bedingungsmodell — Operationalisierte Fallformulierung	13
3.6 Achse VI: Belegsammlung, CAVE-Warnhinweise und Symptomverlauf	14
3.7 Multiprofessionelle Zuordnung	15
3.8 Komorbiditätsregeln und diagnostische Hierarchie	16
3.9 Vollständiges Sub-Achsen-Inventar	17
4 Die 6-Stufen-Gatekeeper-Logik der Differenzialdiagnostik	19
5 Cross-Cutting Symptom Measures als intelligente Triage	20
5.1 Kinder- und Jugendversion	21
5.2 Umfassende Screening-Instrument-Matrix	21
6 Kritische Divergenzen zwischen DSM-5-TR und ICD-11	22
6.1 Schizophrenie-Dauer	22
6.2 PTBS-Architektur	24
6.3 Persönlichkeitsstörungen	24
6.4 Gaming Disorder	24
6.5 Komplexe Trauer / Prolonged Grief Disorder	24
7 Die Abdeckungsanalyse: Ein vorgeschlagener Ansatz	24
7.1 Formale Definition der Abdeckungsanalyse	25
7.2 Begründung der Schwellenwerte und Sensitivität	25
7.3 Implementierung	26
8 Dimensionale Integration: HiTOP und RDoC als ergänzende Perspektiven	27
8.1 HiTOP (Hierarchical Taxonomy of Psychopathology)	27
8.2 RDoC (Research Domain Criteria)	28
9 Technische Architektur der Python-Implementierung	28
9.1 Hierarchische Zustandsmaschinen als Entscheidungsmotor	28
9.2 Empfohlener Technologie-Stack	29
9.3 Open-Source-Referenzimplementierung	29
10 Funktionale Beurteilung: Brücke zwischen Diagnose und Behinderung	30
11 Beispielhafte Fallvignette	30
12 Ethik, Datenschutz und algorithmischer Bias	31
12.1 Algorithmischer Bias und Validierungspopulationen	31
12.2 Datenschutz und DSGVO	32
12.3 Informierte Einwilligung und Patientenautonomie	32
12.4 Haftungsfragen und medizinisch-rechtliche Verantwortung	32
12.5 Klinische Verantwortung und epistemische Grenzen	33
13 Validierungsstrategie	34
14 Interoperabilität und Gesundheits-IT-Standards	36

15 Diskussion und Ausblick	37
16 Limitationen und zukünftiger Forschungsbedarf	39
17 Zusammenfassung	41

Erklärung zur Nutzung KI-gestützter Werkzeuge

Generative KI-Werkzeuge wurden als nicht-autorschaftliche Hilfsmittel für Literaturorganisation, Textstrukturierung, Übersetzungsunterstützung, sprachliche Überarbeitung, Konsistenzprüfungen und LaTeX/PDF-Qualitätssicherung eingesetzt. Ihre Ausgaben wurden als vorläufige Vorschläge behandelt und vom Autor geprüft, überarbeitet oder verworfen. Sie dienten weder als Autoren oder Koautoren noch als Danksagungsempfänger, Fakteninstanzen oder unabhängige Validierungsinstanzen. Forschungsdesign, Quellenauswahl, wissenschaftliche Argumentation, klinische Interpretation, finale redaktionelle Entscheidungen und Verantwortung für das Manuskript liegen ausschließlich beim Autor.

1 Methodik

Diese Arbeit folgt einer Design-Science-Methodik für die Entwicklung eines klinischen Artefakts zur Entscheidungsunterstützung. Der Forschungsprozess umfasste vier Phasen:

Phase 1: Problemidentifikation und Anforderungsanalyse. Eine strukturierte Literaturübersicht zur Abschaffung des DSM-IV-Multiaxialsystems identifizierte fünf spezifische klinische Defizite: Verlust der strukturierten Aufforderung zur biopsychosozialen Beurteilung, geringe GAF-Interrater-Reliabilität, inkonsistente Achse-IV-Nutzung, die künstliche Achse-I/II-Grenze und die niedrige Adoptionsrate der Ersatz-V/Z-Codes. Anforderungen wurden aus diesen Defiziten, aus Firsts (2024) Goldstandard-Rahmen für Differenzialdiagnostik und aus aktuellen dimensional Ansätzen (HiTOP, RDoC, ICD-11 dimensionales Persönlichkeitsmodell) abgeleitet.

Phase 2: Iteratives Design. Die 6-Achsen-Architektur wurde durch iterative Zyklen von Design und Verfeinerung entwickelt. Designentscheidungen — wie die symmetrische Achse-I/III-Struktur, das Konzept der Abdeckungsanalyse und das CAVE-Warnsystem — wurden gegen die identifizierten Anforderungen evaluiert. Jede Iteration wurde dokumentiert und versioniert (V1–V5). Es ist anzumerken, dass der Designprozess kein formales Expertenpanel einschloss; die iterative Verfeinerung erfolgte primär durch den Autor mit KI-gestützter Konsistenzprüfung. Eine formale Expertenbegutachtung ist als Phase 1 der Validierungsstrategie (Abschnitt 13) vorgesehen.

Phase 3: Prototypische Implementierung. Eine Python-Referenzimplementierung (ca. 1.850 Zeilen) unter Verwendung hierarchischer Zustandsmaschinen (`transitions`-Bibliothek) und einer Streamlit-Oberfläche wurde entwickelt, um die Machbarkeit zu demonstrieren. Der Quellcode ist im [Projekt-Repository auf GitHub](#) öffentlich verfügbar.

Phase 4: KI-gestützte Prozessunterstützung. Der Autor nutzte generative KI-Werkzeuge als nicht-autorschaftliche Hilfsmittel für Literaturorganisation, Textstrukturierung, sprachliche Überarbeitung und Konsistenzprüfung. Alle generierten Vorschläge unterlagen der Prüfung durch den Autor; die KI-gestützte Arbeit ersetzte weder empirische Validierung noch Expertenbegutachtung. Die wissenschaftliche Verantwortung für alle Inhalte liegt beim Autor.

Umfang und Limitationen der vorliegenden Arbeit. Dies ist ein Methoden- und Designpapier. Es präsentiert Architektur, Begründung und prototypische Implementierung des 6-Achsen-Modells. Die empirische Validierung (Interrater-Reliabilität, klinischer Nutzen, konvergente Validität) ist in vier Phasen geplant (Abschnitt 13), aber noch nicht durchgeführt. Die Abdeckungsanalyse-Schwellenwerte (85%/60%) sind als initiale Werte auf Basis klinischer Erwägungen vorgeschlagen und bedürfen empirischer Kalibrierung in zukünftigen Studien. Gemäß der Design-Science-Methodik (Hevner et al., 2004; Peffers et al., 2007) steht die formale Evaluationsphase des Artefakts noch aus; die in Abschnitt 13 beschriebene Validierungsstrategie beschreibt den geplanten Evaluationsrahmen.

Tabelle 1: Vergleich computergestützter diagnostischer Systeme: OPCRIT (McGuffin et al., 1991), CATEGO (Wing et al., 1974), DTREE (First et al., 1993), CIDI (Kessler and Üstün, 2004), MHIRA (Zimmermann et al., 2023). DTREE- und CIDI-Einträge basieren auf veröffentlichter Dokumentation. Zu beachten: Alle bestehenden Systeme verfügen über empirische Validierung, die für das vorliegende Modell noch aussteht.

Merkmal Modell	OPCRIT	CATEGO	DTREE	CIDI	MHIRA	6-Achsen-
Multiaxiale Struktur	Nein	Nein	Nein	Nein	Nein	Ja (6 Achsen)
Duale Kodierung (DSM/ICD)	Partiell	Nur ICD	DSM/ICD	DSM/ICD	Flexibel	Vollständig
Abdeckungs- analyse	Nein	Nein	Nein	Nein	Nein	Ja
Dimensionale Integration (HiTOP)	Nein	Nein	Nein	Nein	Partiell	Ja
FHIR-Interoperabi- lität	Nein	Nein	Nein	Nein	Partiell	Geplant
Empirische Validierung	Ja	Ja	Ja	Ja (ext.)	Partiell	Geplant

2 Einleitung: Die diagnostische Lücke nach Abschaffung des multiaxialen Systems

Die Abschaffung des multiaxialen Diagnosesystems im DSM-5 (APA, 2013) hinterließ eine strukturelle Lücke in der psychiatrischen Diagnostik. Das ursprüngliche, mit dem DSM-III (APA, 1980) eingeführte System umfasste fünf Achsen: Achse I (klinische Störungen), Achse II (Persönlichkeitsstörungen und geistige Behinderung), Achse III (medizinische Krankheitsfaktoren), Achse IV (psychosoziale und umweltbezogene Probleme in 9 Kategorien) und Achse V (Globale Beurteilung des Funktionsniveaus, GAF-Score 0–100). Die APA eliminierte dieses System nach einem bereits 2004 initiierten Abschaffungsantrag aus folgenden Gründen: geringe Interrater-Reliabilität des GAF-Scores, konzeptuelle Vermengung von Symptomen und Funktionsniveau in Achse V, inkonsistente klinische Nutzung von Achse IV und die künstliche Grenze zwischen Achse I und II.

Die klinische Gemeinschaft verlor dabei mehr als sie gewann. Probst (2014) dokumentierte, dass die Eliminierung von Achse IV „die Notwendigkeit der Kontextberücksichtigung nicht eliminiert“. Kress et al. (2014) fanden, dass Kliniker nun „umso wachsamer systematische Wege zur Erfassung biopsychosozialer Informationen“ finden müssen — ohne die strukturierten Aufforderungen des alten Systems. Die als Achse-IV-Ersatz eingeführten V/Z-Codes verzeichnen eine geringe Adoptionsrate: Erlich et al. (2025) konstatieren, dass „ein allgemeines Bewusstsein für diese Codes und die Bedeutung ihrer Nutzung zur Kommunikation sozialer Determinanten der Gesundheit nicht eingetreten ist“.

Am kritischsten ist, dass die Abschaffung zum Verlust der strukturierten multiaxialen Diagnostik führte und Kliniker ohne ein systematisches Rahmenwerk zur Integration biologischer, psychologischer und sozialer Dimensionen zurückließ.

Bestehende multiaxiale und integrative Ansätze. Das vorliegende Modell baut auf mehreren grundlegenden Ansätzen zur multiaxialen und integrativen psychiatrischen Diagnostik auf, geht aber substantiell über diese hinaus. Williams (1985) dokumentierte die Ursprünge und frühen Kritiken des DSM-III-Multiaxialsystems und identifizierte sowohl dessen klinischen Nutzen als strukturierte Aufforderung zur umfassenden Beurteilung als auch seine operationalen Schwächen — insbesondere den

unzuverlässigen GAF-Score und die inkonsistente Anwendung der psychosozialen Stressoren-Achse. Das vorliegende Modell adressiert diese spezifischen Kritiken: Es ersetzt den GAF durch validierte Instrumente (WHODAS 2.0, ICF Core Sets), eliminiert die künstliche Achse-I/II-Grenze und führt die quantitative Abdeckungsanalyse als objektive Ergänzung zum klinischen Urteil ein.

Bolton (2008) argumentierte, dass Fallformulierung — der individualisierte narrative Bericht über die Schwierigkeiten eines Patienten — die kategoriale Diagnose ergänzen, nicht ersetzen sollte. Boltons zentrale Einsicht war, dass Klassifikationssysteme erfassen, *was* ein Patient hat, während die Formulierung erfasst, *warum* und *wie*. Das vorliegende Modell operationalisiert diese Einsicht durch Achse V (Integriertes Bedingungsmodell), die ein strukturiertes 3P/4P-Formulierungsschema mit expliziten Rückbezügen auf die diagnostischen Achsen implementiert — und damit die Lücke zwischen Boltons narrativer Formulierung und der strukturierten Klassifikation überbrückt, die klinische Systeme benötigen.

Wakefield (1992) schlug die einflussreiche „Harmful Dysfunction“-Analyse vor, wonach psychische Störungen Zustände sind, in denen ein interner Mechanismus seine natürliche Funktion nicht erfüllt *und* die Dysfunktion dem Individuum Schaden zufügt. Dieser konzeptuelle Rahmen prägt den Ansatz des vorliegenden Modells zur Differenzialdiagnostik: Die 6-Stufen-Gatekeeper-Logik (nach First, 2024) unterscheidet systematisch normale Variation von Dysfunktion, indem sie Evidenz sowohl für beeinträchtigte Mechanismen *als auch* für klinisch bedeutsame Belastung oder Funktionsbeeinträchtigung verlangt. Die Abdeckungsanalyse operationalisiert dies weiter, indem sie quantifiziert, welche Symptome durch etablierte Diagnosen erklärt werden und welche unerklärt bleiben — eine direkte Operationalisierung von Wakefields Forderung, genuine Dysfunktion statt bloßer statistischer Abweichung zu identifizieren.

Abgrenzung zum OPD-System. Das Operationalisierte Psychodynamische Diagnostik-System (OPD-3) stellt das wichtigste multiaxiale Diagnosesystem im deutschsprachigen Raum dar und verwendet ebenfalls einen Mehr-Achsen-Ansatz mit fünf Achsen (Krankheitserleben und Behandlungsvoraussetzungen, Beziehung, Konflikt, Struktur, psychische und psychosomatische Störungen). Während das OPD primär psychodynamisch fundiert ist und die Therapieplanung innerhalb dieses Paradigmas unterstützt, verfolgt das vorliegende Modell einen schulübergreifenden, kategorial-dimensionalen Ansatz mit Fokus auf computergestützte Entscheidungsunterstützung. Die Systeme sind komplementär: Das OPD erfasst intrapsychische Dynamik (Konflikte, Struktur, Beziehungsmuster) in einer Tiefe, die das vorliegende System nicht anstrebt; das 6-Achsen-Modell bietet dafür die quantitative Abdeckungsanalyse, die somatisch-psychische Parallelstruktur und die algorithmische Gatekeeper-Logik, die im OPD nicht enthalten sind. In der klinischen Praxis können OPD-Befunde (insbesondere Konflikt- und Strukturachse) als Material für Achse II (Grundkonflikte) und Achse V (Fallformulierung) des vorliegenden Modells verwendet werden.

Verhältnis zum AMDP-System. Das AMDP-System (Arbeitsgemeinschaft für Methodik und Dokumentation in der Psychiatrie) ist im deutschsprachigen Raum das Standardinstrument für die psychopathologische Befunderhebung. Im vorliegenden Modell liefert der AMDP-Befund das *Rohmaterial* für Achse I: Die dort dokumentierten Symptome werden in der Abdeckungsanalyse (Ii) den diagnostischen Kriterien zugeordnet. Das 6-Achsen-System ersetzt den AMDP-Befund nicht, sondern baut auf ihm auf.

Bezeichnenderweise bleibt die multiaxiale Klassifikation in der Kinder- und Jugendpsychiatrie explizit erhalten: Mayall et al. (2024) argumentieren, dass das multiaxiale Klassifikationssystem ein „klinisch nützliches biopsychosoziales Rahmenmodell“ darstellt, das in der Erwachsenenpsychiatrie voreilig aufgegeben wurde. Diese Persistenz in einem Bereich, der inhärent multidisziplinäre Zusammenarbeit erfordert,

unterstützt die Wiedereinführung multiaxialer Strukturen auch für Erwachsene.

Ein berechtigter Einwand gegen die Wiedereinführung multiaxialer Systeme lautet, dass die Probleme des DSM-IV nicht nur der Implementierung, sondern dem multiaxialen Ansatz selbst inhärent sein könnten: Die erzwungene Aufteilung in diskrete Achsen fragmentiert möglicherweise klinische Information, die besser holistisch erfasst würde. Das vorliegende Modell adressiert diesen Einwand durch das Skelett-Prinzip (keine Pflichtfelder), die achsenübergreifende Fallformulierung (Achse V) und die bewusste Flexibilität der multiprofessionellen Zuordnung. Ob diese Designentscheidungen das Fragmentierungsproblem tatsächlich lösen, ist eine empirische Frage, die erst durch die geplante Validierung beantwortet werden kann.

Die vorliegende Arbeit stellt ein 6-Achsen-Modell vor, das die spezifischen Schwächen des historischen Systems adressiert und zugleich Fähigkeiten vorschlägt, die über bestehende Systeme hinausgehen.

2.1 Institutionelle Konvergenz

Das vorgeschlagene Modell steht nicht isoliert, sondern antizipiert die Richtung, in die sich die psychiatrischen Institutionen selbst bewegen. Das 17-köpfige *APA Future DSM Strategic Committee* entwickelt derzeit einen „strategischen Fahrplan“ mit vier Unterkomitees, die Dimensionalität, Biomarker, Funktion/Lebensqualität und sozioökonomische/kulturelle/umweltbezogene Determinanten explorieren. Erlich et al. (2025) fordern explizit die Rückkehr zu einem biaxialen System zur Erfassung sozialer Determinanten der Gesundheit.

2.2 Designphilosophie: Skelett, lebendes Dokument, maximale Freiheit

Drei Designprinzipien leiten das gesamte System:

Skelett-Prinzip

Das System fungiert als diagnostisches *Skelett*: Es bietet für jede klinisch relevante Information einen definierten Ort, ohne dass irgendein Feld als Pflichtfeld deklariert wird. Kein Diagnostiker wird gezwungen, Abschnitte auszufüllen, die für den aktuellen Fall irrelevant sind. Das System ist ein Korsett zur Stütze — nicht zur Einschränkung — des diagnostischen Prozesses.

Lebendes Dokument

Die diagnostische Akte ist kein statisches Formular, sondern ein *lebendes Dokument*, das mit dem klinischen Prozess wächst. Neue Testergebnisse, Laborberichte, Beobachtungsprotokolle und Bewertungen können jederzeit integriert werden. Jede Achse ist offen für iterative Ergänzung: Ein Laborbericht wird in die Evidenz-Matrix (Achse VI) eingetragen mit Datum, Bezeichnung, klinischer Bewertung und Achsenverweis; eine spätere Fremdanamnese ergänzt das Kontaktprotokoll; ein neuer psychometrischer Test aktualisiert Achse I.

Bericht als Momentaufnahme

Berichte — ob Entlassbriefe, Gutachten oder Verlaufsberichte — sind *eingefrorene Momentaufnahmen* des lebenden Dokuments zu einem bestimmten Zeitpunkt. Das Dokument selbst lebt weiter und kann nach einem Bericht neue Informationen aufnehmen, während der Bericht den Stand zum Zeitpunkt seiner Erstellung repräsentiert.

Diese Philosophie unterscheidet das System fundamental von starren Formularsystemen: Es bietet Struktur, wo Struktur nützlich ist, und Freiheit, wo Freiheit klinisch geboten ist.

Beitrag des vorliegenden Artikels: Der Hauptbeitrag liegt in drei vorgeschlagenen Designelementen: (1) der quantitativen Abdeckungsanalyse als klinische Qualitätssicherungsmetrik für diagnostische Vollständigkeit, (2) der symmetrischen Achse-I/III-Architektur, die strukturierte multiprofessionelle Zusammenarbeit ermöglicht, und (3) der operationalisierten Verbindung von kategorialer Diagnostik und individualisierter Fallformulierung in einem einzigen System. Verwandte Ansätze existieren in Teilbereichen (z. B. Bayesianische Diagnosesysteme, OPD-Multiaxialität); der spezifische Beitrag liegt in deren Integration in ein computergestütztes Gesamtsystem. Diese Designelemente adressieren klinische Defizite, die seit der Abschaffung des DSM-IV-Multiaxialsystems bestehen und durch aktuelle Forderungen (Erich et al., 2025) erneut Dringlichkeit erhalten haben.

3 Architektur des 6-Achsen-Modells

Das vorgeschlagene Modell integriert die kategoriale Diagnostik (DSM-5-TR (APA, 2022); ICD-11 (WHO, 2019)) in ein epistemologisches Gesamtsystem. Es dient der Erfassung der diagnostischen Lebensspanne, der Kausalitätsprüfung zwischen Somatik und Psyche sowie der Dokumentation der Behandlungs- und Remissionsgeschichte. Ein zentrales Designprinzip ist die **symmetrische Parallelstruktur** zwischen Achse I und Achse III: Beide Achsen verfügen über analoge Subachsen (Verdachtsdiagnosen, Widerlegungen, Behandlungsgeschichte, Abdeckungsanalyse, Untersuchungsplan), sodass Psychologen und Mediziner mit identischen strukturellen Werkzeugen in ihren jeweiligen Domänen arbeiten können. Tabelle 2 gibt eine Übersicht.




Abbildung 1: Architektur des 6-Achsen-Modells mit Sub-Achsen. Achse I und III teilen eine symmetrische Parallelstruktur (angezeigt durch den gestrichelten Pfeil).

Tabelle 2: Übersicht der diagnostischen Achsen des 6-Achsen-Modells

Achse	Bezeichnung	Unterteilung	Kerninhalte	Typische Profession
I	Psychische Profile	Ia: Akute Störungen Ib: Chronische Verläufe Ic: Widerlegte Verdachte Id: Remittierte Diagnosen Ie: Remissionsfaktoren If: Behandlungsgeschichte Ig: Therapietreue Ih: Verdachtsdiagnosen Ii: Abdeckungsanalyse Ij: Untersuchungsplan	DSM-5 Cross-Cutting; PHQ-9, PCL-5, ITQ; Differenzialdiagnostik; Chronifizierung; Zeitliche Verortung	Psychologe / Psychiater
II	Biographie & Persönlichkeit	Entwicklungshistorie Prägende Erfahrungen Grundkonflikte Persönlichkeit (PID-5)	IQ, Bildung, Sozialisation; Lebensereignisse; OPD-Konflikte; PID-5-BF/+M	Psychologe / Sozialpädagoge
III	Medizinische Synopse	IIIa: Akute med. Diagnosen IIIb: Chron. Diagnosen (erkl.) IIIc: Beitragende Faktoren IIId: Remittierte Erkrank. IIIe: Remissionsfaktoren IIIf: Behandlungsgesch. IIIg: Medikamentenadh. IIIh: Verdachtsdiagnosen IIIi: Abdeckungsanalyse IIIj: Untersuchungsplan IIIk: Kausalitätsanalyse IIIl: Genetik/Familie IIIm: Medikamentenanamnese	Biographische Medizingeschichte; Kausalanalyse Soma–Psyche; erbbiologische Belastung; Pharmakotherapie mit Wirkungsbewertung	Mediziner / Facharzt
IV	Umwelt & Funktion	Teilhabe (ICF) Psychosoziale Umstände Bezugspersonen-Netzwerk Cultural Formulation	WHODAS 2.0, GdB; Mini-ICF-APP; Stressoren; Behandlungsnetzwerk; CFI	Sozialarbeiter / Sozialpädagoge
V	Bedingungsmodell	Prädisponierende Fakt. Auslösende Faktoren Aufrechterhaltende Fakt. Protektive Faktoren Klinische Synthese	3P/4P-Modell; Achsenintegration; Behandlungsplanung; Prognose	Interdisziplinäres
Team				
VI	Belegsammlung & Klinische Sicherheit	Evidenz-Matrix (m. Bewertung) CAVE-Warnhinweise Symptomverlauf Kontaktprotokoll	Dokumentenregister m. klin. Bewertung; CAVE-Warnhinweise; Symptomverlauf; Kontakt-/Beobachtungsprotokoll	Alle Professionen

3.1 Achse I: Psychische Profile — Temporale Diagnostik

Achse I geht weit über die einfache Diagnoseliste des DSM-5 hinaus, indem sie Diagnosen in ihrer zeitlichen Dynamik erfasst. Die Unterteilung in zehn Subachsen (Ia–Ij) ermöglicht die Dokumentation des gesamten diagnostischen Lebenslaufs: aktuelle akute Störungen (Ia), chronische Verläufe mit Chronifizierungsrisiko (Ib), explizit widerlegte Verdachtsdiagnosen mit differenzialdiagnostischer Begründung (Ic), remittierte Diagnosen mit belegter Inaktivität (Id), Remissionsfaktoren wie Therapie, Medikation oder spontane Bewältigung (Ie), vollständige Behandlungsgeschichte einschließlich Wirkungen und Nebenwirkungen (If), Therapietreue aus Selbst- und Fremdperspektive (Ig), laufende Verdachtsdiagnosen als diagnostische Hypothesen (Ih), die Abdeckungsanalyse unerklärter Restsymptomatik (Ii) und strukturierte Untersuchungspläne für nächste diagnostische Schritte (Ij).

Die Reihenfolge von Abdeckungsanalyse (Ii) vor Untersuchungsplan (Ij) folgt der klinischen Logik:

Erst müssen diagnostisch unerklärte Symptome systematisch identifiziert werden, bevor gezielte Untersuchungen zu deren Klärung geplant werden können. Der Untersuchungsplan ergibt sich somit direkt aus den Lücken der Abdeckungsanalyse.

PRO/CONTRA-Evidenzbewertung: Jede Diagnose erhält eine strukturierte Evidenzbewertung mit expliziter Dokumentation der Befunde, die für (PRO) und gegen (CONTRA) die Diagnose sprechen, sowie eine numerische Konfidenzschätzung (0–100%). Diese Operationalisierung folgt dem Prinzip der differenzialdiagnostischen Transparenz: Der Kliniker muss nicht nur dokumentieren, *dass* eine Diagnose gestellt wird, sondern *warum* — und welche Gegenargumente er erwägt und verworfen hat.

Quantitative Abdeckungsanalyse (Ii): Eine Symptom-Diagnosen-Matrix quantifiziert den Grad der diagnostischen Erklärung jedes Symptoms durch die aktiven Diagnosen. Die formale Definition, Schwellenwerte und Sensitivitätsanalyse werden in Abschnitt 7 ausführlich dargestellt.

Priorisierter Untersuchungsplan (Ij): Der Untersuchungsplan verwendet ein 3-Stufen-Priorisierungsschema: *Dringend* (innerhalb von 4 Wochen abzuklären — z. B. Suizidalitätsabklärung, medizinische Notfalldiagnostik), *Wichtig* (innerhalb von 3 Monaten — z. B. neuropsychologische Testung, Differenzialdiagnostik) und *Verlaufskontrolle* (kontinuierliches Monitoring — z. B. Symptomverlauf unter Therapie). Jede geplante Untersuchung wird einem Fachgebiet zugeordnet und mit einer klinischen Begründung versehen.

Diese temporale Dimensionalität fehlte sowohl in Achse I des DSM-IV als auch im flachen Listing des DSM-5.

3.2 Achse II: Biographie und dimensionale Persönlichkeit

Achse II modernisiert die alte Persönlichkeitsachse durch Integration der dimensional Trait-Diagnostik mittels PID-5, wie es sowohl ICD-11 als auch das Alternative Modell des DSM-5 empfehlen. Das ICD-11-Modell ersetzt die kategorialen Persönlichkeitsstörungs-Typen durch ein Schweregrad-Rating (Persönlichkeitsschwierigkeit → leicht → moderat → schwer), fünf Trait-Qualifikatoren (Negative Affektivität, Distanziertheit, Dissozialität, Enthemmung, Anankastie) und einen Borderline-Muster-Spezifikator. Das DSM-5-AMPD verwendet die Level of Personality Functioning Scale (LPFS) für Kriterium A und fünf Trait-Domänen mit 25 Facetten für Kriterium B.

Der **PID-5-BF+M** (36 Items, 6 Domänen, 18 Facetten) verbrückt beide Systeme und ist in über 12 Sprachen verfügbar. Metaanalysen zeigen eine Gesamt-Konvergenz von $r = 0,62$ zwischen den Systemen, mit Domänen-Korrelationen von $r = 0,78–0,86$, mit Ausnahme von Anankastie ($r = 0,34$), die kein direktes AMPD-Äquivalent besitzt.

Neuere Arbeiten zur Integration der dimensional Systeme von ICD-11 und DSM-5 für Persönlichkeitsstörungen in eine einheitliche Taxonomie mit nicht-überlappenden Traits unterstützen den hier verfolgten PID-5-basierten Ansatz (Bach et al., 2022).

Über die dimensionale Persönlichkeitsdiagnostik (IIa) hinaus integriert Achse II zwei weitere biographische Komponenten: **Prägende Erfahrungen (IIb)** dokumentieren lebensgeschichtlich bedeutsame Ereignisse mit Lebensabschnitt und Auswirkung auf die aktuelle Situation (z. B. frühe Verlusterfahrung, Gewalterfahrung, Migration). **Grundkonflikte (IIc)** erfassen wiederkehrende intrapsychische Themen (z. B. Autonomie-Abhängigkeits-Konflikt, Selbstwertkonflikt), wie sie in der psychodynamischen Tradition und im OPD-System beschrieben werden. Beide Komponenten sind als offene Listen implementiert, die mit dem diagnostischen Prozess wachsen, und liefern wesentliches Material für die Fallformulierung

in Achse V.

3.3 Achse III: Medizinische Synopse — Symmetrische Parallelstruktur zu Achse I

Ein zentrales Designprinzip des Modells ist die **strukturelle Symmetrie** zwischen Achse I (psychisch) und Achse III (somatisch). Die Einsicht dahinter: Wenn ein Psychologe in Achse I Verdachtsdiagnosen formulieren, Widerlegungen dokumentieren und Abdeckungsanalysen durchführen kann, muss ein Mediziner in Achse III über exakt dieselben Möglichkeiten verfügen. Nur so funktioniert das multi-professionelle Modell.

Achse III umfasst daher 13 Subachsen:

IIIa–IIIj: Parallele Kernstruktur

Diese zehn Subachsen folgen der Grundstruktur von Achse I, wobei die Subachsen IIIb (erklärende chronische Diagnosen) und IIIc (beitragende Faktoren) eine domänenspezifische Differenzierung darstellen, die in Achse I kein direktes Äquivalent hat: akute somatische Diagnosen (IIIa), chronische somatische Diagnosen mit vollständig erklärendem Charakter (IIIb), beitragende medizinische Faktoren — somatische Befunde, die Psychopathologie begünstigen oder verstärken, ohne sie vollständig zu erklären (IIIc), remittierte somatische Erkrankungen (IIId), somatische Remissionsfaktoren — operative Eingriffe, Medikation, Lebensstiländerung (IIIe), medizinische Behandlungsgeschichte einschließlich Operationen, Pharmakotherapie und Nebenwirkungen (IIIf), Medikamentenadhärenz aus ärztlicher Dokumentation und Patientenbericht (IIIg), medizinische Verdachtsdiagnosen als laufende diagnostische Hypothesen (IIIh), somatische Abdeckungsanalyse — Körpersymptome, die durch keine aktuelle medizinische Diagnose erklärt werden (IIIi), und medizinischer Untersuchungsplan für weiterführende somatische Diagnostik (IIIj).

IIIk–IIIm: Achse-III-spezifische Subachsen

Drei Subachsen haben keine Entsprechung in Achse I, da sie die spezifische Soma–Psyche-Beziehung abbilden: integrierte Kausalitätsanalyse — systematische Zuordnung somatischer Befunde zur Psychopathologie unter Differenzierung von vollständiger Erklärung (z. B. Hypothyreose erklärt Depression) und begünstigender Wirkung (z. B. chronischer Schmerz verstärkt Angststörung) (IIIk); genetische und familiäre Belastung — Familienanamnese für somatische und psychische Erkrankungen, bekannte genetische Prädispositionen und ggf. Ergebnisse aus Exom-Sequenzierung (IIIl); Medikamentenanamnese und Interaktionen — strukturierte Erfassung aller aktuellen und vergangenen Medikamente mit Dosierung, Einheit, Zweck/Indikation, Einnahmeschema, Wirkungsbewertung (0–10), Nebenwirkungen und potentiellen Interaktionen (IIIm).

Anmerkung zur Strukturentscheidung IIIb/IIIc: Die explizite Differenzierung zwischen vollständig erklärenden chronischen Diagnosen (IIIb) und bloß beitragenden Faktoren (IIIc) integriert die Kausalanalyse direkt in die Klassifikationsstruktur. Widerlegte medizinische Verdachtsdiagnosen werden innerhalb von IIIh (Verdachtsdiagnosen) durch einen Statuswechsel dokumentiert, analog zur klinischen Praxis, in der Verdachtsdiagnosen ausgeschlossen und mit Begründung verworfen werden.

Anmerkung zu IIIm: Die Medikamentenanamnese als eigenständige Subachse (statt bloßer Auflistung in IIIf) ermöglicht eine strukturierte Erfassung von Wirkungsprofilen, Interaktionsrisiken und

Therapietreue auf Präparatebene. Dies ist klinisch essentiell, da Polypharmazie und Medikamenteninteraktionen eine häufige Ursache sowohl für somatische als auch für psychiatrische Komplikationen darstellen.

Diese Symmetrie stellt sicher, dass das System als *gemeinsames Werkzeug* für Mediziner und Psychologen funktioniert. Ein Mediziner, der Achse III ausfüllt, verfügt über dieselbe diagnostische Tiefe wie ein Psychologe in Achse I.

3.4 Achse IV: Umwelt und Funktion — ICF-Integration und Cultural Formulation

Achse IV kombiniert mehrere validierte Instrumente. Der **WHODAS 2.0** (WHO, 2010) (WHO Disability Assessment Schedule) erfasst sechs Domänen — Kognition, Mobilität, Selbstversorgung, Umgang mit Menschen, Lebensaktivitäten und Partizipation — wahlweise als 12-Item-Kurzform (erklärt 81% der Varianz; Luciano et al., 2010) oder 36-Item-Vollversion. Die psychometrischen Eigenschaften sind stark: Cronbachs $\alpha = 0,94\text{--}0,96$, Test-Retest-ICC = $0,93\text{--}0,96$.

WHODAS 2.0 und GAF messen *fundamental unterschiedliche Konstrukte*: GAF vermengt Symptome und Funktionsniveau; WHODAS 2.0 misst Behinderung unabhängig von der Symptomschwere. Gspandl et al. (2018) fanden *keine signifikante Korrelation* zwischen selbstbewertetem WHODAS 2.0 und GAF bei Schizophrenie-Spektrum-Störungen. Das System verwendet primär den WHODAS 2.0 für die Behinderungserfassung. Der GAF kann optional für die Rückwärtskompatibilität beibehalten werden, ist jedoch keine Kernkomponente des Modells.

Für den deutschen Kontext ist die **GdB-Integration** (Grad der Behinderung) essentiell. Der GdB verwendet eine 20–100-Skala (≥ 50 = Schwerbehinderung) und wird nach den Versorgungsmedizinischen Grundsätzen (VMG) bewertet.

Drei **ICF-Core-Set**-Familien für psychische Gesundheit wurden für Depression, bipolare Störung und Schizophrenie entwickelt (Cieza et al., 2004; Ayuso-Mateos et al., 2013; Gómez-Benito et al., 2018): Depression (31 kurze/121 umfassende Kategorien), bipolare Störung (19/38) und Schizophrenie (25/97). Für die praktische Implementierung ist das **Mini-ICF-P**-Rating von Linden & Baron (2005) mit 13 Kapazitätsdimensionen das effizienteste Werkzeug.

Operationalisierung der ICF-Integration in Achsen III und VI: Die ICF-Codierung im 6-Achsen-Modell folgt einer dreistufigen Logik. *Erstens* werden auf Achse III (Medizinische Synopse) die Körperfunktionen (ICF-Kapitel b) und Körperstrukturen (ICF-Kapitel s) dokumentiert, die für die somatisch-psychische Kausalanalyse (IIIk) relevant sind — beispielsweise b130 (Funktionen der psychischen Energie und des Antriebs), b152 (emotionale Funktionen) oder b144 (Funktionen des Gedächtnisses). *Zweitens* erfasst Achse IV die Aktivitäten und Partizipation (ICF-Kapitel d) sowie Umweltfaktoren (ICF-Kapitel e) — operationalisiert über WHODAS 2.0 (Domänen d1–d6) und Mini-ICF-APP (13 Kapazitätsdimensionen, z. B. Fähigkeit zur Regelmäßigkeit, Flexibilität, Kontaktfähigkeit). *Drittens* werden in der Evidenz-Matrix (Achse VI) die ICF-Qualifikatoren (Ausmaß der Beeinträchtigung: 0–4) zu jeder codierten Funktionseinschränkung dokumentiert, um die Quantifizierung über die Zeit zu ermöglichen.

Mehrwert gegenüber dem WHODAS 2.0 allein: Während der WHODAS 2.0 als globales Behinderungsinstrument sechs Domänen auf einer Summenskala erfasst, ermöglicht das 6-Achsen-Modell eine *achsenbezogene Differenzierung*: Funktionseinschränkungen werden nicht nur quantifiziert, sondern kausal den Achsen I (psychisch) und III (somatisch) zugeordnet. Die Abdeckungsanalyse (Ii/IIIi) identifiziert zudem Funktionsdefizite, die durch keine aktuelle Diagnose erklärt werden — eine Dimension, die

WHODAS 2.0 nicht adressiert. Das Mini-ICF-APP ergänzt den WHODAS 2.0 durch störungsspezifische Kapazitätsprofile, die für die Behandlungsplanung und Prognose in Achse V (Bedingungsmodell) direkt verwertbar sind.

3.4.1 Bezugspersonen und Behandlungsnetzwerk

Achse IV erfasst neben den psychosozialen Stressoren und Funktionsinstrumenten auch das **Bezugspersonen- und Behandlungsnetzwerk** des Patienten. Für jede Kontaktperson werden Name, Rolle (Elternteil, Partner, Hausarzt, Facharzt, Therapeut, Sozialarbeiter, Betreuer etc.), Institution, Kontaktdaten und Anmerkungen dokumentiert. Diese strukturierte Netzwerkerfassung dient mehreren Zwecken: Sie macht das soziale Stützsystem sichtbar, das für die Fallformulierung (Achse V, protektive Faktoren) und die Behandlungsplanung essentiell ist; sie dokumentiert das beteiligte professionelle Netzwerk für die Koordination; und sie identifiziert potentielle Informationsquellen für Fremdanamnesen (dokumentiert im Kontaktprotokoll, Achse VI).

3.4.2 Cultural Formulation Interview (CFI)

Das DSM-5-TR enthält ein strukturiertes **Cultural Formulation Interview** (CFI) mit 16 Kernfragen in vier Domänen: kulturelle Definition des Problems, kulturelle Wahrnehmung von Ursache/Kontext/Unterstützung, kulturelle Faktoren in der Bewältigung und kulturelle Faktoren in der Kliniker-Patient-Beziehung. Für ein Modell, das umfassende biopsychosoziale Erfassung beansprucht, ist die Integration des CFI als optionales Modul in Achse IV essentiell. Die 12 supplementären Module des CFI (für spezifische Populationen und Kontexte) können bedarfsorientiert aktiviert werden.

3.5 Achse V: Integriertes Bedingungsmodell — Operationalisierte Fallformulierung

Achse V stellt eine vorgeschlagene Erweiterung dar, die in bisherigen Systemen nicht enthalten ist. Das prädisponierende–auslösende–aufrechterhaltende Faktorenmodell (klinisches 3P/4P-Modell) verbrückt diagnostische Klassifikation mit Fallformulierung — etwas, das keine DSM-Edition jemals enthalten hat. Owen (2023) argumentiert, dass dieser Formulierungsansatz „die Auswahl der Fakten diszipliniert und die Behandlung zielgerichtet macht“. Die Synthese aller Achsen — wie Biologie (III), Biographie (II) und aktuelle Stressoren (IV) mit der Psychopathologie (I) interagieren — wird hier expliziert.

Das Modell operationalisiert die Fallformulierung durch vier strukturierte Komponenten:

Prädisponierende Faktoren (P1)

Vulnerabilitätsfaktoren, die vor der Störung existierten. Quellen: Achse II (biographische Risikofaktoren, Persönlichkeits-Traits), Achse III (genetische Belastung, III_m), Achse IV (frühe psychosoziale Belastungen). Kodierung: Faktor, Quellenachse, Evidenzstärke (gesichert/wahrscheinlich/möglich), Beleg (Achse VI-Referenz).

Auslösende Faktoren (P2)

Ereignisse oder Veränderungen, die das Auftreten der Störung ausgelöst haben. Quellen: Achse IV (aktuelle Stressoren, Life Events), Achse III (somatische Auslöser). Kodierung: Faktor, zeitlicher Zusammenhang, Quellenachse, Beleg.

Aufrechterhaltende Faktoren (P3)

Bedingungen, die die Störung perpetuieren. Quellen: Achse I (Komorbiditäten, Therapietreue), Achse III (unbehandelte somatische Befunde), Achse IV (fortbestehende psychosoziale Belastungen). Kodierung: Faktor, Mechanismus, Änderbarkeit (modifizierbar/stabil), Priorität für Intervention.

Protektive Faktoren (P4)

Ressourcen, die Resilienz fördern. Quellen: Achse II (Persönlichkeitsstärken), Achse IV (soziale Unterstützung, ökonomische Ressourcen), Achse I (Remissionsfaktoren, Ie). Kodierung: Faktor, Quellenachse, Aktivierbarkeit.

Schulenübergreifende Kompatibilität: Das 3P/4P-Modell ist bewusst schulenübergreifend konzipiert. Verhaltenstherapeutische Fallkonzeptionen (z. B. das SORKC-Modell) lassen sich direkt in die Achse-V-Struktur übersetzen: Stimulus-Situationen entsprechen auslösenden Faktoren (P2), Organismus-Variablen den prädisponierenden Faktoren (P1), Reaktionsmuster und Konsequenzen den aufrechterhaltenden Faktoren (P3). Psychodynamische Formulierungen (OPD-Konflikte, strukturelle Einschränkungen) finden ihren Platz ebenfalls in P1 und P3. Diese Kompatibilität ist kein Zufall, sondern reflektiert die empirische Konvergenz verschiedener Therapieschulen auf gemeinsame ätiologische Faktoren.

Die Verknüpfung mit der Abdeckungsanalyse (Achse II) ist zentral: Symptome, die durch keine Achse-I-Diagnose abgedeckt sind, *sollten* durch die Achse-V-Formulierung erklärbar sein. Symptome, die weder diagnostisch noch formulatorisch erklärt werden, repräsentieren genuine diagnostische Lücken und lösen den Untersuchungsplan (Achse Ij) aus.

3.6 Achse VI: Belegsammlung, CAVE-Warnhinweise und Symptomverlauf

Achse VI wurde gegenüber dem Originalentwurf substantiell erweitert und umfasst nun drei Komponenten:

Evidenz-Matrix

Ein zentrales Dokumentenverzeichnis, das jede kodierte Information mit einem Beleg verknüpft (Dokumentenanalyse, Befragung, Testung). Jeder Eintrag umfasst neben Achsenbezug, Dokumententyp und Beschreibung ein explizites **Bewertungsfeld** für die klinische Einschätzung: Ein eingehender Laborbericht wird mit Datum, Bezeichnung, Quelle *und* klinischer Bewertung dokumentiert — so ist transparent, wie der Kliniker den Befund im diagnostischen Kontext interpretiert. Dieses Designmerkmal ist in bestehenden diagnostischen Klassifikationssystemen nach Kenntnis des Autors nicht üblich, wobei eine systematische Literaturrecherche hierzu noch aussteht. Es unterstützt direkt die klinische Rechenschaftspflicht.

CAVE-Warnhinweise

Ein strukturiertes Warnsystem für kritische klinische Risiken, die achsenübergreifend Relevanz haben. Jeder Warnhinweis wird mit einer Kategorie versehen: *Medikamenten-Interaktion* (z. B. Lithium + NSAR), *Labor-Artefakt* (z. B. CRP-Erhöhung durch chronische Entzündung, nicht akute Infektion), *Kontraindikation* (z. B. Schwangerschaft bei bestimmter Medikation), *zeitliche Fehlzuordnung* (z. B. Symptombeginn vor oder nach vermutetem Auslöser), *diagnostische Einschränkung* (z. B. nicht verwertbarer Testbefund) und *sonstiger Warnhinweis*. Jeder

Warnhinweis verweist auf die betroffene Quellenachse (I–VI), sodass die klinische Relevanz sofort kontextualisiert ist. CAVE-Warnhinweise werden in der Gesamtsynopse prominent rot hervorgehoben.

Longitudinaler Symptomverlauf

Eine strukturierte Dokumentation des zeitlichen Symptomverlaufs: Für jedes relevante Symptom wird Beginn (Erstmanifestation), aktueller Status (aktiv/remittiert/fluktuierend) und Therapieansprechen (Ansprechen/kein Ansprechen/partielles Ansprechen) erfasst. Diese longitudinale Perspektive ermöglicht die Identifikation von Verlaufsmustern, Therapieresistenz und Chronifizierungsrisiken, die in einer rein querschnittlichen Diagnostik unsichtbar bleiben.

Kontakt- und Beobachtungsprotokoll

Ein strukturiertes Protokoll für alle klinisch relevanten Kontakte und Beobachtungen. Jeder Eintrag umfasst Datum, Kontaktart (Telefonat, Gespräch, Beobachtung, Hausbesuch, Fremdanamnese, E-Mail/Brief), beteiligte Kontaktperson, Inhalt und optionalen Achsenbezug. Das Protokoll dokumentiert den *Prozess* der Informationsgewinnung: Wann wurde mit wem gesprochen, was wurde beobachtet, und welche Achse profitiert von dieser Information? Damit fungiert Achse VI nicht nur als statische Belegsammlung, sondern als **Prozessdokumentation** des diagnostischen Arbeitens — ein wesentlicher Bestandteil des Konzepts des lebenden Dokuments (vgl. Abschnitt 2.2).

Die Erweiterung von Achse VI reflektiert die klinische Erkenntnis, dass ein diagnostisches System nicht nur *klassifizieren*, sondern auch *warnen*, *über die Zeit verfolgen* und den *diagnostischen Prozess selbst dokumentieren* muss. Die CAVE-Funktion adressiert das in der Polypharmazie- und Komplexitätsmedizin wachsende Problem klinischer Risiken, die in keiner einzelnen Achse vollständig abgebildet sind, aber achsenübergreifend Konsequenzen haben.

3.7 Multiprofessionelle Zuordnung

Das 6-Achsen-Modell bietet eine **empfohlene**, nicht verpflichtende Zuordnung von Achsen zu Professionsgruppen. Tabelle 3 zeigt eine exemplarische Konfiguration für interdisziplinäre Teams. In der klinischen Praxis können die Zuständigkeiten flexibel angepasst werden: Ein Psychiater, der sowohl psychodiagnostische als auch somatische Kompetenz besitzt, kann selbstverständlich Achse I *und* Achse III ausfüllen; eine Fachärztin für Psychosomatische Medizin kann alle sechs Achsen bedienen. Das System *ermöglicht* interdisziplinäre Arbeitsteilung, *erzwingt* sie aber nicht.

Tabelle 3: Exemplarische multiprofessionelle Achsenzuordnung (nicht verpflichtend)

Achse	Typische Profession	Fachliche Begründung
I	Psychologe / Psychiater	Psychodiagnostische Kompetenz; Testungshoheit
II	Psychologe / Sozialpädagoge	Biographische Anamnese; Persönlichkeitsdiagnostik
III	Mediziner / Facharzt	Somatische Diagnosestellung; Kausalanalyse
IV	Sozialarbeiter / Sozialpädagoge	Lebensweltexpertise; ICF-Kompetenz; Teilhabebewertung
V	Interdisziplinäres Team	Synthese profitiert von allen Perspektiven
VI	Alle Professionen	Jede beteiligte Profession belegt ihre eigenen Befunde

Der Mehrwert der Zuordnung liegt nicht in einer starren Zugangsbeschränkung, sondern in der **strukturierten Aufforderung**: Das System macht transparent, *welche* Kompetenz für welche Achse typischerweise benötigt wird. In Einzelpraxen oder kleineren Settings kann eine einzelne Fachperson alle Achsen bearbeiten; in Kliniken und interdisziplinären Teams ermöglicht das Modell eine effiziente Arbeitsteilung, bei der jede Profession in ihrer Domäne mit identischen strukturellen Werkzeugen arbeitet. Die identische Subachsen-Struktur von Achse I und III ist dabei kein Zufall, sondern Designentscheidung: Ein Mediziner, der in IIIh eine somatische Verdachtsdiagnose formuliert, nutzt exakt dieselbe Logik wie ein Psychologe, der in Ih eine psychische Verdachtsdiagnose einträgt.

3.8 Komorbiditätsregeln und diagnostische Hierarchie

Das System implementiert drei Ebenen von Komorbiditätsregeln, die für die korrekte diagnostische Entscheidungsfindung essentiell sind:

Hierarchische Exklusionsregeln

Bestimmte Diagnosen schließen andere aus. Beispiel: Eine Schizophrenie-Diagnose schließt eine gleichzeitige schizoaffective Störung aus. Das System kodiert diese als harte Constraints, die bei der Diagnoseeingabe automatisch geprüft werden.

„Due to another condition“-Regeln

Viele DSM-5-TR-Diagnosen erfordern den Ausschluss, dass die Symptomatik durch eine andere psychische Störung, eine Substanz oder einen medizinischen Krankheitsfaktor besser erklärt wird. Diese Regeln werden direkt durch die Gatekeeper-Stufen 1–3 (Abschnitt 4) implementiert.

Erlaubte Komorbiditäten mit Priorisierung

Bei 4+ aktiven Diagnosen priorisiert das System nach: (1) klinischer Dringlichkeit (Suizidalität, Psychose), (2) Schweregrad (Achse-I-Akutstatus), (3) Behandelbarkeit (modifizierbare aufrechterhaltende Faktoren aus Achse V), (4) chronologischer Reihenfolge.

3.9 Vollständiges Sub-Achsen-Inventar

Die Tabellen 4, 5 und 6 bieten ein vollständiges Inventar aller Sub-Achsen der sechs Hauptachsen einschließlich der zugeordneten Instrumente und Datenquellen.

Tabelle 4: Sub-Achsen-Inventar: Achsen I–II

Achse	Sub-Achse	Beschreibung	Instrument / Quelle
I			
Psychisch	Ia: Akute Störungen	Aktuelle DSM-5-TR/ICD-11-Diagnosen mit PRO/CONTRA-Evidenz und Konfidenz	DSM-5-TR, ICD-11
	Ib: Chronische Verläufe	Langzeitdiagnosen mit Chronifizierungsrisiko	Klinische Akten
	Ic: Widerlegte Verdachte	Explizit ausgeschlossene Diagnosen mit differenzialdiagn. Begründung	Differenzialdiagnostik
	Id: Remittierte Diagnosen	Frühere Diagnosen mit belegter Inaktivität	Klinische Akten
	Ie: Remissionsfaktoren	Therapie, Medikation oder spontane Bewältigung als Remissionsursache	Klinische Akten
	If: Behandlungsgeschichte	Frühere Behandlungen, Medikation, Wirkungen und Nebenwirkungen	Klinische Akten
	Ig: Therapietreue	Adhärenz aus Selbst- und Fremdperspektive	Klinisches Interview
	Ih: Verdachtsdiagnosen	Laufende diagnostische Hypothesen (noch nicht bestätigt)	Klinisches Urteil
	Ii: Abdeckungsanalyse	Symptom-Diagnosen-Abdeckungsprozentsatz (DCI)	Algorithmisch (s. Abschnitt 7)
	Ij: Untersuchungsplan	Priorisierte nächste Schritte (dringend / wichtig / Monitoring)	Klinisches Urteil
II			
Persönlichkeit	Ila: PID-5 Dimensionales Profil	5 Trait-Domänen, 25 Facetten	PID-5, PID5BF+
	Ilb: Prägende Lebenserfahrungen	Biographische Ereignisse mit Einfluss auf Persönlichkeitsentwicklung	Klinisches Interview
	Ilc: Grundkonflikte	Zentrale Beziehungsmuster und Konfliktthemen	OPD-3, klin. Formulierung

Tabelle 5: Sub-Achsen-Inventar: Achse III

Achse	Sub-Achse	Beschreibung	Instrument / Quelle
III			
Somatisch	IIIa: Akute somatische Diagnosen	Aktuelle somatische Diagnosen mit PRO/CONTRA-Evidenz	ICD-11 somatische Codes
	IIIb: Chronische Diagnosen (erklärend)	Erkrankungen, die bestimmte Symptome vollständig erklären	Klinische Akten
	IIIc: Beitragende med. Faktoren	Somatische Befunde, die Psychopathologie begünstigen oder verstärken	Klinische Akten
	IIId: Remittierte Erkrankungen	Frühere somatische Erkrankungen mit belegter Inaktivität	Klinische Akten
	IIIe: Remissionsfaktoren	Operative Eingriffe, Medikation, Lebensstiländerung als Remissionsursache	Klinische Akten
	IIIf: Behandlungsgeschichte	Frühere medizinische Behandlungen, Operationen, Nebenwirkungen	Klinische Akten
	IIIg: Medikamentenadhärenz	Adhärenz aus ärztlicher Dokumentation und Patientenbericht	Klinische Akten
	IIIh: Verdachtsdiagnosen	Laufende medizinische diagnostische Hypothesen	Klinisches Urteil
	IIIi: Abdeckungsanalyse (somatisch)	Somatische Symptom-Diagnosen-Abdeckung	Algorithmisch (s. Abschnitt 7)
	IIIj: Somatischer Untersuchungsplan	Medizinische Abklärungsprioritäten	Klinisches Urteil
	IIIk: Integrierte Kausalanalyse	Achsenübergreifende Kausalpfade (somatisch ↔ psychisch)	Interdisziplinäre Synthese
	IIIl: Genetik/Familie	Hereditäre Risikofaktoren und Familienanamnese	Familienanamnese-Interview
	IIIm: Medikamentenanamnese	Aktuelle und frühere Medikation mit Wirksamkeitsbewertung	Medikamentenakten

Tabelle 6: Sub-Achsen-Inventar: Achsen IV–VI

Achse	Sub-Achse	Beschreibung	Instrument / Quelle
IV Funktions- status	IVa: WHODAS 2.0	6 Funktionsdomänen (36- oder 12-Item-Version)	WHODAS 2.0
	IVb: GdB	Grad der Behinderung	VersMedV-Richtlinien
	IVc: ICF Core Sets	Störungsspezifische ICF-Komponentenprofile	ICF Core Sets
	IVd: Cultural Formulation Interview	Kultureller Kontext der Krankheitserfahrung	CFI (DSM-5-TR)
	IVe: Behandlungsnetzwerk		
Register	Kontaktpersonen, Versorger, soziale Unterstützung	Strukturiertes Register	
V Fall- formulierung	Va: Prädisponierende Faktoren	Vulnerabilitätsfaktoren vor Störungsbeginn	3P/4P-Modell
	Vb: Auslösende Faktoren	Triggerereignisse und Stressoren	3P/4P-Modell
	Vc: Aufrechterhaltende Faktoren	Aufrechterhaltende Mechanismen und Rückkopplungsschleifen	3P/4P-Modell
	Vd: Protektive Faktoren	Resilienzressourcen und Stärken	3P/4P-Modell
	Ve: Abdeckungslücken-Integration	Unerklärte Symptome aus Achse-I/III-Abdeckungsanalyse	Achsenübergreifende Synthese
VI Evidenz & Sicherheit	VIa: Zentrale Evidenz-Matrix	Strukturierte Evidenzfelder pro Diagnose	Systemgeneriert
	VIb: CAVE Klinische Warnungen	Achsenübergreifende Risikowarnungen (Interaktionen, Kontraindikationen)	Regelbasierte Warnhinweise
	VIc: Longitudinale Symptomverlaufsdokumentation	Wiederholte Messungen mit Therapieansprechen-Dokumentation	PHQ-9, GAD-7, PCL-5 etc.
	VId: Kontakt- und Beobachtungsprotokoll	Sitzungsdokumentation und Prozessnotizen	Kliniker-Einträge

4 Die 6-Stufen-Gatekeeper-Logik der Differenzialdiagnostik

Das System implementiert eine dynamische Warteschlange, in der Screening-Auffälligkeiten spezifische DSM-5-TR/ICD-11-Module auslösen. Die 6-Stufen-Sequenz bildet exakt die von Michael B. First im *DSM-5-TR Handbook of Differential Diagnosis* (2024) publizierte differenzialdiagnostische Sequenz ab (Tabelle 7).

Tabelle 7: Abgleich der 6-Stufen-Gatekeeper-Logik mit Firsts Goldstandard-Sequenz

Stufe	Systemschritt	Firsts Sequenz	Passung
1	Simulationsausschluss	Malingering und artifizielle Störung ausschließen	Exakt
2	Substanzausschluss	Substanzätiologie ausschließen	Exakt
3	Medizinischer Ausschluss	Ätiologische medizinische Erkrankung ausschließen	Exakt
4	Primärkategorie	Spezifische Primärstörung(en) bestimmen	Exakt
5	Anpassungsstörung	Anpassungsstörungen differenzieren	Exakt
6	Funktionsschwelle	Grenze zu „keine psychische Störung“	Konzeptuell

First (2024) beschreibt diese Sequenz als den definitiven Makro-Level-Diagnoseprozess. Sein Hand-book enthält darüber hinaus **30 symptomorientierte Entscheidungsbäume** (zwei in der TR-Edition ergänzt für dissoziative Symptome und repetitive pathologische Verhaltensweisen) und **67 Differenzialdiagnosetabellen**, die alle dieser Sequenz folgen.

Anmerkung zu Stufe 6 („konzeptuell“): Während die Stufen 1–5 exakt algorithmisch abbildbar sind, ist Stufe 6 — die Grenzziehung zwischen normaler Stressreaktion und psychischer Störung — inhärent eine klinische Urteilsentscheidung. Das System unterstützt diese durch objektive Funktionsdaten (WHODAS 2.0, Mini-ICF-APP aus Achse IV) und die Cross-Cutting-Schwellenwerte, kann aber die klinische Entscheidung nicht vollständig automatisieren. Diese epistemische Grenze wird transparent kommuniziert.

5 Cross-Cutting Symptom Measures als intelligente Triage

Die DSM-5 Cross-Cutting Symptom Measures bilden das Rückgrat der Screening-Architektur. Das **Level-1-Erwachsenenmaß** enthält **23 Items über 13 Domänen**: Depression (2), Ärger (1), Manie (2), Angst (3), somatische Symptome (2), Suizidalität (1), Psychose (2), Schlafprobleme (1), Gedächtnis (1), repetitive Gedanken und Verhaltensweisen (2), Dissoziation (1), Persönlichkeitsfunktion (2) und Substanzgebrauch (3). Jedes Item verwendet eine 5-stufige Likert-Skala (0 = keine bis 4 = schwer).

Die Schwellenlogik ist klinisch kalibriert: **Die meisten Domänen lösen Level 2 bei ≥ 2 (leicht) aus**, aber drei sicherheitskritische Domänen — Suizidalität, Psychose und Substanzgebrauch — **lösen bei ≥ 1 (gering) aus**. Diese Asymmetrie reflektiert den klinischen Imperativ, selbst minimale Bestätigung gefährlicher Symptome nicht zu übersehen.

Die Level-2-Maße verweisen auf spezifische validierte Instrumente: PROMIS Depression Short Form, PROMIS Anxiety Short Form, Altman Self-Rating Mania Scale (ASRM), PHQ-15 für somatische Symptome, PROMIS Sleep Disturbance, adaptierte FOCI Severity Scale für Zwangsstörungen und adaptierter NIDA-Modified ASSIST für Substanzgebrauch. Fünf Domänen (Suizidalität, Psychose, Gedächtnis, Dissoziation, Persönlichkeitsfunktion) besitzen *keine offiziellen Level-2-Maße* — die APA empfiehlt hier klinische Evaluation.

Die DSM-5 Field Trials (Narrow et al., 2013) zeigten **gute bis exzellente Test-Retest-Reliabilität** (ICC 0,64–0,97) für die meisten Items.




Abbildung 2: 6-Stufen-Gatekeeper-Logik für die Differenzialdiagnostik, basierend auf First (2024). Stufe 6 ist als konzeptuell markiert, da die Grenzziehung zwischen normaler Variation und psychischer Störung klinisches Urteil erfordert.

5.1 Kinder- und Jugendversion

Das DSM-5 Cross-Cutting-System umfasst eine separate **Elternberichtsversion für Kinder und Jugendliche** (6–17 Jahre) mit **25 Items über 12 Domänen**. Die Domäne „Persönlichkeitsfunktion“ entfällt entwicklungsbedingt; stattdessen werden Reizbarkeit und Ärger stärker gewichtet. Eine vollständige Implementierung erfordert die pädiatrische Variante als separaten Einstiegspfad sowie altersangepasste Level-2-Instrumente.

Das vorliegende System bevorzugt **ausschließlich frei verfügbare Instrumente**; der proprietäre CBCL/YSR-Komplex (Achenbach & Rescorla, 2001) wird zwar als Referenzstandard anerkannt, aber durch lizenzfreie Alternativen ersetzt. Tabelle 8 listet die empfohlene Auswahl freier K/J-Instrumente parallel zur Erwachsenenmatrix (Tabelle 9).

Diese Auswahl bewahrt die diagnostische Logik der Erwachsenenmatrix (Domänen-orientiert, Cutoff-basiert), substituiert aber jedes Instrument durch eine entwicklungspsychologisch validierte und lizenzfreie K/J-Variante. Für sicherheitskritische Domänen (Suizidalität, Substanzgebrauch, Psychose) gilt analog die niedrigere Triage-Schwelle. Die Trennung in **Selbstbericht** (ab ~8–11 J.) und **Elternbericht** (6–17 J., bei jungen Kindern obligatorisch) folgt der etablierten Konvention der pädiatrischen Psychometrie.

5.2 Umfassende Screening-Instrument-Matrix

Tabelle 9 zeigt die empfohlenen Instrumente für alle wesentlichen diagnostischen Domänen.

Tabelle 8: Freie Screening-Instrumente für Kinder und Jugendliche (K/J-Matrix)

Domäne	Instrument	Items	Alter	Cutoff / Norm	Kosten
Cross-Cutting (Eltern)	DSM-5 XC L1 Parent	25	6–17	$\geq 1/\geq 2$ Triage	Frei
Allg. psychosoz. Screen	SDQ (Self/Parent)	25	4–17	≥ 20 (Total)	Frei
Depression	PHQ-9 mod. (PHQ-A)	9	11–17	≥ 11	Frei
Angst + Depression	RCADS-25	25	8–18	$T \geq 65$	Frei
Angst (multidim.)	SCARED-C	41	8–18	≥ 25	Frei
PTBS	CPSS-V / CRIES-8	20 / 8	7–18	$\geq 31 / \geq 17$	Frei
Substanzgebrauch	CRAFFT 2.1+N	6+3	12–21	≥ 2	Frei
ADHS	SNAP-IV-26	26	6–18	Subskalen-Mittelwert	Frei
Autismus	AQ-10 Adolescent/Child	10	4–15	≥ 6	Frei
Zwang	CY-BOCS-SR	10	8–18	≥ 16	Frei
Suizidalität	C-SSRS Pediatric	6	≥ 5	Jede Bestät.	Frei
Essstörungen	SCOFF (ab ~13 J.)	5	13–18	≥ 2	Frei

Alle empfohlenen Instrumente sind **frei verfügbar** — keine Lizenzkosten behindern die Implementierung. Die Auswahl basiert auf den jeweiligen Validierungspublikationen: PHQ-9 (Levis et al., 2019), GAD-7 (Spitzer et al., 2006), PCL-5 (Blevins et al., 2015), ITQ (Cloitre et al., 2018), PQ-16 (Ising et al., 2012), ASRS (Kessler et al., 2005), AQ-10 (Allison et al., 2012), AUDIT (Saunders et al., 1993), PID-5 (Oltmanns & Widiger, 2018; Riegel et al., 2021), C-SSRS (Posner et al., 2011), OCI-R (Foa et al., 2002), SSS-8 (Gierk et al., 2014), DES-II (Carlson & Putnam, 1993), SCOFF (Morgan et al., 1999), ISI (Morin et al., 2011). Für die Interrater-Reliabilität kategorialer DSM-5-Diagnosen siehe Regier et al. (2013) und Aboraya et al. (2006).

6 Kritische Divergenzen zwischen DSM-5-TR und ICD-11

Das System muss fünf kritische Divergenzen zwischen den Klassifikationssystemen kodieren (Keeley et al., 2016).

6.1 Schizophrenie-Dauer

DSM-5-TR (295.90/F20.x) verlangt **6 Monate** kontinuierlicher Zeichen einschließlich mindestens 1 Monat aktiver Symptome, während ICD-11 (6A20) nur **1 Monat** fordert. Ein Patient kann somit die ICD-11-Kriterien für Schizophrenie erfüllen, unter DSM-5 aber nur die Diagnose einer schizophreniformen Störung erhalten.

Tabelle 9: Screening-Instrument-Matrix

Domäne	Instrument	Items	Cutoff	Sens./Spez.	Kosten
Depression	PHQ-9	9	≥ 10	88%/88%	Frei
Angst	GAD-7	7	≥ 10	89%/82%	Frei
PTBS (DSM-5)	PCL-5	20	31–33	85–95%/82–90%	Frei
PTBS/KPTBS (ICD-11)	ITQ	18	Algorithmus	Exzellent	Frei
Psychoserisiko	PQ-16	16	≥ 6	87%/87%	Frei
Bipolar-Screening	MDQ	15	≥ 7	73%/90%	Frei
ADHS	ASRS v1.1	6	≥ 4	69%/99,5%	Frei
Autismus	AQ-10	10	≥ 6	88%/91%	Frei
Alkoholgebrauch	AUDIT	10	≥ 8	92%/94%	Frei
Drogengebrauch	DAST-10	10	≥ 3	98%/91%	Frei
Persönlichkeit	PID-5-BF	25	Dimensional	N/A	Frei
Suizidalität	C-SSRS	6	Jede Bestät.	Risikoklassif.	Frei
Zwang	OCI-R	18	≥ 21	Gut	Frei
Somatisierung	SSS-8	8	≥ 12	Vergleichbar	Frei
Dissoziation	DES-II	28	≥ 30	74%/80%	Frei
Essstörungen	SCOFF	5	≥ 2	84%/90%	Frei
Essstörungen (detail.)	EDE-QS	12	≥ 15	Gut/Gut	Frei
Schlafstörungen	ISI	7	≥ 15	82%/82%	Frei
Funktionsfähigkeit	WHODAS 2.0 (12)	12	Dimensional	N/A	Frei

6.2 PTBS-Architektur

DSM-5-TR verwendet **4 Cluster mit 20 Symptomen** (Intrusion $\geq 1/5$, Vermeidung $\geq 1/2$, Negative Kognitionen $\geq 2/7$, Arousal $\geq 2/6$). ICD-11 verwendet ein bewusst schmaleres Modell: **3 Cluster mit 6 Kernsymptomen**. ICD-11 fügt dann die **Komplexe PTBS (6B41)** als distinkte Diagnose hinzu, die alle PTBS-Kriterien plus drei Störungen der Selbstorganisation (Affektdysregulation, negatives Selbstkonzept, Beziehungsschwierigkeiten) erfordert.

6.3 Persönlichkeitsstörungen

ICD-11 ersetzte kategoriale Typen vollständig durch ein dimensionales Modell. Das DSM-5 Alternative Model for Personality Disorders (AMPD) verwendet die LPFS für Kriterium A (Funktionsniveau) und fünf Trait-Domänen mit 25 Facetten für Kriterium B (pathologische Traits). Der PID-5-BF+M verbrückt beide Systeme. **Abgrenzung zu Achse II des vorliegenden Modells:** Das AMPD selbst ist implizit zweiachsig (Funktionsniveau + Traits). Achse II des 6-Achsen-Modells übernimmt die Trait-Dimension (PID-5), erweitert sie aber um biographische Kontextualisierung (prägende Erfahrungen, Grundkonflikte) und verlagert das Funktionsniveau (LPFS-Analogon) systematisch auf Achse IV (WHODAS 2.0, Mini-ICF-APP). Dadurch wird die diagnostische Information des AMPD vollständig abgebildet, aber über mehrere Achsen verteilt, was eine klarere Zuordnung zu unterschiedlichen professionellen Zuständigkeiten ermöglicht.

6.4 Gaming Disorder

ICD-11 (6C51) verwendet einen monothetischen Ansatz (alle 4 Kriterien erforderlich; ≥ 12 Monate). DSM-5-TR listet Internet Gaming Disorder nur als „Condition for Further Study“ mit polythetischem Ansatz (≥ 5 von 9 Kriterien). Konkordanz: $\kappa = 0,80$, aber ICD-11 hat eine höhere diagnostische Schwelle (Prävalenz 2,7% vs. DSM-5 5,2%).

6.5 Komplexe Trauer / Prolonged Grief Disorder

ICD-11 (6B42) und DSM-5-TR (Prolonged Grief Disorder, neu aufgenommen) kodieren Anhaltende Trauerstörung, unterscheiden sich aber in Zeitkriterium (ICD-11: 6 Monate; DSM-5-TR: 12 Monate) und Symptomkonfiguration. Das System muss beide Varianten abbilden.

7 Die Abdeckungsanalyse: Ein vorgeschlagener Ansatz

Die Abdeckungsanalyse (*Coverage Analysis*) stellt eine zentrale vorgeschlagene Komponente des Systems dar. Uns sind keine direkt vergleichbaren Implementierungen bekannt, obwohl verwandte Ansätze existieren (z. B. Bayesianische Symptom-Diagnosen-Zuordnung in OPCRIT). Das Konzept umfasst die systematische Kennzeichnung von Symptomen, die durch aktuelle Diagnosen nicht erklärt werden.

Die engsten existierenden Parallelen sind: Komorbiditäts-Detektionsalgorithmen, die Symptome kennzeichnen, die auf zusätzliche Diagnosen hindeuten; Firsts Differenzialdiagnosetabellen (First, 2024), die überlappende Präsentationen vergleichen; und transdiagnostische Rahmenmodelle wie HiTOP, in denen Symptome als Netzwerkknoten modelliert werden. Plana-Ripoll et al. (2019) zeigten empirisch, dass die meisten psychischen Störungen weit häufiger gemeinsam auftreten als durch Zufall erwartet —

eine vorangegangene Diagnose irgendeiner psychischen Störung erhöhte das Risiko für alle anderen psychischen Störungen substanziell — was den Bedarf an einem systematischen Abdeckungsanalyse-Werkzeug direkt stützt.

7.1 Formale Definition der Abdeckungsanalyse

Sei $S = \{s_1, \dots, s_n\}$ die Menge der beobachteten Symptome und $D = \{d_1, \dots, d_m\}$ die Menge der etablierten Diagnosen. Für jedes Symptom s_i definieren wir die Abdeckungsfunktion $c(s_i) = \max_{d_j \in D} w(s_i, d_j)$, wobei $w(s_i, d_j) \in [0, 1]$ das Gewicht des Symptoms s_i in der Diagnose d_j gemäß den diagnostischen Kriterien repräsentiert. Die Gesamtabdeckung — im Folgenden als **Diagnostic Coverage Index (DCI)** bezeichnet — ergibt sich als $C_{\text{total}} = \frac{1}{n} \sum_{i=1}^n c(s_i)$.

Die Symptomgewichte werden aus den diagnostischen Kriterien von DSM-5-TR und ICD-11 abgeleitet. Kriterien werden nach diagnostischer Salienz gewichtet: Kardinalsymptome erhalten hohe Gewichte ($w \geq 0,8$), während unspezifische Symptome niedrigere Gewichte ($0,3 \leq w \leq 0,7$) erhalten. Dieses initiale Gewichtungsschema ist heuristisch und bedarf empirischer Kalibrierung in zukünftiger Arbeit.

Überlappende Diagnosen werden behandelt, indem jedes Symptom der Diagnose mit maximaler Abdeckung zugeordnet wird. Die Wahl der Max-Funktion (statt z. B. eines gewichteten Mittels oder einer Bayesianischen Posterior-Wahrscheinlichkeit) ist bewusst konservativ: Sie fragt, ob *mindestens eine* Diagnose das Symptom hinreichend erklärt, und vermeidet dadurch die Summation partieller Erklärungen, die zu falsch hohen Abdeckungswerten führen könnte. Dieser Ansatz reflektiert die klinische Praxis, in der ein Symptom als „erklärt“ gilt, wenn es einem etablierten Krankheitsbild zugeordnet werden kann. Alternative Aggregationsfunktionen (gewichtete Summe, Bayesianische Posterior) sollten in zukünftigen Studien systematisch verglichen werden.

7.2 Begründung der Schwellenwerte und Sensitivität

Die vorgeschlagenen Schwellenwerte (85%/60%) sind als *vorläufige, heuristische Ausgangswerte* zu verstehen, die auf Analogien zu verwandten, aber methodisch distinkten Metriken basieren: (1) In der somatischen Medizin gelten diagnostische Sensitivitäten $\geq 85\%$ als klinisch akzeptabel für Screening-Zwecke (Levis et al., 2019); dieser Schwellenwert wurde auf die diagnostische Abdeckung übertragen. (2) Der untere Schwellenwert von 60% orientiert sich an der Konvention, dass Fleiss' κ -Werte $< 0,6$ als „unzureichende Übereinstimmung“ klassifiziert werden. Es ist ausdrücklich anzumerken, dass diagnostische Abdeckung ein anderes Konstrukt ist als Screening-Sensitivität oder Interrater-Übereinstimmung; die Analogien dienen lediglich als orientierende Anhaltspunkte, nicht als methodische Begründung. Diese Ausgangswerte müssen zwingend durch empirische Kalibrierung in mindestens drei klinischen Kohorten (stationär, ambulant, somatisch komorbid) ersetzt werden. Hinsichtlich der Sensitivität der Gesamtmetriken: Da C_{total} ein arithmetisches Mittel über n Symptome ist, verändert eine Einzelgewichtsänderung von Δw den Gesamtwert um $\Delta C = \Delta w/n$. Bei typischen Symptomzahlen ($n = 8\text{--}15$) führt eine Fehlschätzung eines einzelnen Gewichts um $\pm 0,2$ zu einer Gesamtverschiebung von lediglich $\pm 1,3\text{--}2,5$ Prozentpunkten — was die Robustheit der Metrik gegenüber moderaten Gewichtungsfehlern belegt, aber auch zeigt, dass bei wenigen Symptomen ($n < 5$) die Metrik instabil wird.

7.3 Implementierung

Die Implementierung arbeitet wie folgt: (1) Sammlung aller bestätigten Symptome über alle Screening-Instrumente, (2) Zuordnung jedes Symptoms zu den diagnostischen Kriterien, die es erfüllt, (3) Berechnung eines Abdeckungsprozentsatzes pro Symptom, der den Grad der diagnostischen Erklärung quantifiziert, (4) Klassifikation als vollständig abgedeckt ($\geq 85\%$), partiell abgedeckt (60–84%) oder unzureichend abgedeckt ($< 60\%$), (5) Berechnung eines Gesamtabdeckungswerts als gewichteter Mittelwert über alle Symptome, (6) Präsentation der Ergebnisse als Symptom-Diagnosen-Matrix mit visueller Hervorhebung diagnostischer Lücken. Das 4P-Modell (Achse V) dient als natürliches Komplement: Symptome, die nicht durch Achse-I-Diagnosen abgedeckt sind (Achse II), sollten durch die Achse-V-Formulierung erklärbar sein; solche, die es nicht sind, repräsentieren genuine diagnostische Lücken und münden in den priorisierten Untersuchungsplan (Achse Ij).

Die quantitative Metrik (z. B. „Gesamtabdeckung: $\sim 88\%$ “) liefert dem Kliniker eine unmittelbare Rückmeldung über die Vollständigkeit seiner diagnostischen Arbeit. Verwandte Ansätze existieren in Bayesianischen Diagnosesystemen (z. B. DXplain, Isabel Healthcare), die Symptom-Diagnose-Zuordnungen vornehmen; der spezifische Beitrag der vorliegenden Abdeckungsanalyse liegt in der transparenten, prozentbasierten Darstellung als klinische Qualitätssicherungsmetrik.

Es sei angemerkt, dass der Begriff „Abdeckungsanalyse“ (*coverage analysis*) in der medizinischen Informatik primär für die terminologische Zuordnung zwischen Klassifikationssystemen verwendet wird (z. B. ICF vs. SNOMED CT für die Behinderungsbewertung). Das vorliegende Modell rekonzeptualisiert die Abdeckungsanalyse als klinische Qualitätssicherungsmetrik: Statt die Überlappung zwischen Terminologien zu messen, quantifiziert sie den Anteil des Symptomprofils eines Patienten, der durch aktuelle Diagnosen erklärt wird.

	Depression	PTBS	Hypothyreose	
Symptom				$c(s_i)$
Niedergeschl.	0.90	0.30	0.20	0.90
Fatigue	0.70	0.20	0.80	0.80
Insomnie	0.80	0.50	0.10	0.80
Intrusionen	0.10	0.95	0.00	0.95
Hyperarousal	0.15	0.90	0.05	0.90
Konzentration	0.65	0.40	0.55	0.65
C_{total}				83.3%

■ $\geq 85\%$ (vollst.)
 ■ 60–84% (partiell)
 ■ $< 60\%$ (unzureich.)

Abbildung 3: Illustrative Abdeckungsanalyse-Matrix. Jede Zelle zeigt das Gewicht $w(s_i, d_j)$; die Abdeckungsspalte zeigt $c(s_i) = \max_j w(s_i, d_j)$. Der Gesamtabdeckungswert $C_{\text{total}} = 83,3\%$ deutet auf partielle Gesamtabdeckung hin und legt weitere diagnostische Untersuchung nahe.

Die Abdeckungsanalyse wird symmetrisch auch in Achse III implementiert (Subachse IIIi): Körper-

symptome, die durch keine aktuelle somatische Diagnose erklärt werden, werden systematisch identifiziert und führen zum medizinischen Untersuchungsplan (Subachse IIIj).

8 Dimensionale Integration: HiTOP und RDoC als ergänzende Perspektiven

Während die Abdeckungsanalyse die Vollständigkeit *innerhalb* der kategorialen Diagnostik quantifiziert, adressieren dimensionale Rahmenmodelle eine komplementäre Limitation: die künstliche Grenzziehung zwischen diagnostischen Kategorien (Rosenman et al., 2003). Das 6-Achsen-Modell basiert primär auf kategorialer Diagnostik (DSM-5-TR/ICD-11), enthält aber bereits dimensionale Elemente (PID-5, WHODAS 2.0). Zwei weitere dimensionale Rahmenmodelle verdienen Integration als ergänzende Schichten:

8.1 HiTOP (Hierarchical Taxonomy of Psychopathology)

Die Hierarchical Taxonomy of Psychopathology (Kotov et al., 2017, 2022; Krueger et al., 2018) organisiert psychische Störungen empirisch-hierarchisch in sechs Spektren: Internalizing (Depression, Angst, PTBS), Thought Disorder (Psychose, Manie), Disinhibited Externalizing (Substanzgebrauch, Impulskontrolle), Antagonistic Externalizing (Antisoziales Verhalten), Detachment (soziale Zurückgezogenheit, Anhedonie) und Somatoform (somatische Symptome). Die Cross-Cutting-Ergebnisse des Systems werden direkt den HiTOP-Spektren zugeordnet und als Radardiagramm visualisiert. Die Zuordnung nutzt die maximale Ausprägung der zugehörigen Cross-Cutting-Domänen:

- Internalizing = max(Depression, Anxiety, Sleep)
- Thought Disorder = max(Psychosis, Mania, Dissociation)
- Disinhibited Externalizing = max(Substance)
- Antagonistic Externalizing = max(Anger)
- Detachment = max(Personality/Withdrawal)
- Somatoform = max(Somatic)

Anmerkung zur HiTOP-Zuordnung: Die Zuordnung folgt dem aktuellen HiTOP-Konsensus (Kotov et al., 2021): Manie wird dem Thought-Disorder-Spektrum zugeordnet (nicht Disinhibited Externalizing), da manische Episoden in der hierarchischen Faktorstruktur primär mit dem Thought-Disorder-Faktor laden. Dissoziation wird ebenfalls Thought Disorder zugeordnet, konsistent mit der empirischen Evidenz für eine enge Assoziation mit psychotischen Erfahrungen. Das Somatoform-Spektrum verwendet ausschließlich die somatische Cross-Cutting-Domäne; die Depression-assoziierte somatische Belastung wird über das Internalizing-Spektrum erfasst. Diese Zuordnungen sind als Approximationen zu verstehen, da die Cross-Cutting-Domänen nicht für die HiTOP-Zuordnung entwickelt wurden.

Diese automatische Berechnung erfordert *keine zusätzliche Datenerhebung* — die bereits im Cross-Cutting-Screening (Abschnitt 5) erfassten Domänenwerte werden direkt wiederverwendet. Es ist jedoch zu betonen, dass diese Zuordnung eine *grobe Approximation* darstellt: Die Cross-Cutting-Domänen wurden nicht für die HiTOP-Zuordnung entwickelt, und die Max-Funktion bildet die faktorenanalytisch ermittelten Spektren nur unvollständig ab. Die Darstellung als Radardiagramm (visuell klar vom PID-5-Persönlichkeitsprofil abgesetzt) kann die Erkennung transdiagnostischer Muster fördern, die bei rein

kategorialer Diagnostik unsichtbar bleiben, sollte aber als explorative Visualisierung, nicht als validierte Messung interpretiert werden.

Zusammengefasst bildet die beschriebene Zuordnung eine erste Approximation, die mit zunehmender empirischer Evidenz zu HiTOP-konformen Assessments verfeinert werden sollte (Kotov et al., 2021).

8.2 RDoC (Research Domain Criteria)

Die Research Domain Criteria des NIMH (Insel et al., 2010) definieren sechs Domänen (Negative Valence, Positive Valence, Cognitive Systems, Social Processes, Arousal/Regulatory, Sensorimotor) mit sieben Analyseebenen (Gene, Moleküle, Zellen, Schaltkreise, Physiologie, Verhalten, Selbstbericht). Für ein klinisches System ist RDoC primär als *Forschungsannotation* relevant: Wenn Biomarker-Daten verfügbar sind (z. B. Cortisol-Profile, Neuroimaging), können diese den RDoC-Domänen zugeordnet werden. Das APA Future DSM Strategic Committee exploriert explizit die Integration von Biomarkern — das System ist darauf vorbereitet.

Ein separates Konzeptpapier beschreibt die detaillierte Architektur der dimensionalen Integration.

9 Technische Architektur der Python-Implementierung

9.1 Hierarchische Zustandsmaschinen als Entscheidungsmotor

Nach Evaluation von vier Architekturansätzen — AnyTree, Zustandsmaschinen, Rule Engines und Behavior Trees — erweisen sich **Hierarchische Zustandsmaschinen (HSMs)** mittels der Python-Bibliothek `transitions` als optimale Lösung für psychiatrische Diagnostik-Workflows.

Die `transitions`-Bibliothek mit ihrer `HierarchicalMachine`-Erweiterung bietet: konditionelle Transitionen via Guards (direkte Abbildung von „wenn Symptom X → betrete Modul Y“), verschachtelte Zustände (der 6-Stufen-Prozess mit störungsspezifischen Submodulen), History States (Rücknavigation) und serialisierbaren Zustand (Speichern/Fortsetzen).

Die Architektur bildet sich wie folgt ab:

```
Top-level: [Intake -> Step1_Malingering -> Step2_Substance ->
            Step3_Medical -> Step4_CrossCutting ->
            Step5_DisorderModules -> Step6_Functioning -> Summary]
```

```
Step5_DisorderModules (verschachtelt, 11 Module):
```

```
+-- MoodDisorders -> {MDD_Criteria, Bipolar_Screening, Dysthymia,
                      PMDD, Prolonged_Grief}
+-- AnxietyDisorders -> {GAD, Panic, Social_Anxiety, Phobias,
                        Separation_Anxiety, Selective_Mutism}
+-- TraumaDisorders -> {PTSD_DSM5, PTSD_ICD11, CPTSD_DS0,
                        Acute_Stress, Adjustment}
+-- PsychoticDisorders -> {Schizophrenia_1mo, Schizophrenia_6mo,
                           Schizoaffective, Brief_Psychotic}
+-- PersonalityDisorders -> {LPFS, PID5_Traits, ICD11_Severity}
+-- OCDspectrum -> {OCD_Criteria, BDD, Hoarding, Trichotillomania,
```

```

        Excoriation}
+-- DissociativeDisorders -> {DID, Depersonalization,
        Dissociative_Amnesia}
+-- EatingDisorders -> {AN, BN, BED, ARFID}
+-- NeurodevelopmentalDisorders -> {ADHD, ASD_Assessment}
+-- SubstanceUseDisorders -> {Alcohol_Use, Drug_Use,
        Behavioral_Addictions}
+-- SomaticDisorders -> {Somatic_Symptom, Illness_Anxiety,
        Conversion, Factitious}

```

Die Erweiterung von 5 auf **11 Störungsmodule** stellt sicher, dass jedes Screening-Instrument der Matrix (Tabelle 9) in einen diagnostischen Workflow mündet. Ein auffälliger DES-II-Score triggert das Modul DissociativeDisorders; ein erhöhter SCOFF-Score das Modul EatingDisorders. Ohne diese Vollständigkeit bestünde eine systemische Lücke zwischen Screening und Diagnostik.

AnyTree wird weiterhin für **Visualisierung und Serialisierung** der Baumstruktur genutzt (Graphviz-Export, JSON-Repräsentation), während transitions die Laufzeitlogik verwaltet.

9.2 Empfohlener Technologie-Stack

Tabelle 10: Empfohlener Technologie-Stack

Komponente	Empfehlung	Begründung
Entscheidungsmotor	transitions (HSM)	Verschachtelte Zustände, Guards
Baumvisualisierung	anytree	Graphviz-Export, JSON
UI (Prototyp)	Streamlit	Schnelles Prototyping, <code>st.navigation</code>
PDF-Berichte	WeasyPrint + Jinja2	Natives UTF-8, HTML/CSS-Templates
Persönlichkeits-Charts	Plotly	<code>px.line_polar()</code> für PID-5-Radardiagramme
Datenpersistenz	SQLModel + SQLite	Pydantic + SQLAlchemy kombiniert
Datenvalidierung	Pydantic	Typsichere Diagnosekriterien-Modelle
ICD-11-Codes	WHO ICD-11 API	Strukturierte Diagnose-Code-Suche
Interoperabilität	HL7 FHIR (R4)	Standardisierter Datenaustausch

9.3 Open-Source-Referenzimplementierung

Der vollständige Quellcode des Prototyps (V9, ca. 1.850 Zeilen Python/Streamlit), die bilinguale Übersetzungsdatei, der Entwicklungsfahrplan und das vorliegende Manuskript sind öffentlich verfügbar unter:

github.com/um-bruch/multiaxial-diagnostic-system

Die Bereitstellung als Open-Source-Repository dient der wissenschaftlichen Transparenz und Reproduzierbarkeit. Installationsanweisungen finden sich in der `README.md` des Repositories.

Lizenzierung und Archivierung: Das Repository steht unter der MIT-Lizenz, die sowohl akademische als auch kommerzielle Nutzung erlaubt, jedoch keinerlei Gewährleistung übernimmt (vgl. Haftungsfragen, Abschnitt 12). Für die langfristige Zitierbarkeit und Versionierung ist das Repository bereits als Software-Record auf Zenodo archiviert und mit dem Beitrag verknüpft (Concept-DOI: [10.5281/zenodo.18736725](https://doi.org/10.5281/zenodo.18736725); neueste öffentliche Version zum Zeitpunkt dieser Manuskriptaktualisierung:

[10.5281/zenodo.19073268](https://doi.org/10.5281/zenodo.19073268)). Dadurch bleibt eine konkrete Codeversion dauerhaft referenzierbar, unabhängig von Änderungen am GitHub-Repository.

10 Funktionale Beurteilung: Brücke zwischen Diagnose und Behinderung

Die Integration funktionaler Beurteilung verbindet Diagnose und Teilhabe. Das Modell implementiert drei Ebenen: das krankheitsspezifische Assessment (ICF Core Sets), die allgemeine Behinderungsmessung (WHODAS 2.0) und die rechtlich-administrative Bewertung (GdB).

ICD-11 selbst hat sich in Richtung ICF-Integration bewegt, indem „Functioning Properties“ eingeführt wurden, die mit 103 rehabilitationsrelevanten Gesundheitszuständen verknüpft sind. Für Schizophrenie und psychotische Störungen enthält ICD-11 **dimensionale Qualifikatoren**, die mit rehabilitationsbasierter psychiatrischer Versorgung konsistent sind.

11 Beispielhafte Fallvignette

Hinweis: Die folgende Fallvignette ist fiktiv und dient ausschließlich der Illustration der Anwendbarkeit des 6-Achsen-Modells. Jede Ähnlichkeit mit realen Personen ist zufällig.

Patient M., 34 Jahre, männlich, Erstvorstellung in der psychiatrischen Ambulanz.

Achse I (Psychische Profile)

Ia (akut): Mittelgradige depressive Episode (F32.1), Konfidenz 85%, PRO: PHQ-9 = 16, Antriebslosigkeit, Schlafstörungen seit 4 Monaten; CONTRA: keine Suizidalität, erhaltene Arbeitsfähigkeit.

Ih (Verdacht): Generalisierte Angststörung (F41.1), Konfidenz 55%, PRO: GAD-7 = 12, chronische Sorgen; CONTRA: möglicherweise sekundär zur Depression.

Ii (Abdeckung): Gesamtabdeckung ~78%. Nicht abgedeckt: chronische Rückenschmerzen (somatisch? funktionell?), Konzentrationsprobleme (depressionsassoziiert oder eigenständig?).

Ij (Plan): Wichtig: Neuropsychologische Testung zur Klärung der Konzentrationsstörung; Wichtig: Somatische Abklärung der Rückenschmerzen (funktionell vs. strukturell); Verlauf: PHQ-9-Monitoring alle 4 Wochen, C-SSRS-Screening bei Verschlechterung.

Achse II (Biographie)

PID-5-BF+M: Erhöhte Negative Affektivität (T=68), grenzwertige Distanziertheit (T=60).

Prägende Erfahrung: Frühe Scheidung der Eltern (Alter 7), intermittierendes Mobbing in der Schule (12–15 J.).

Grundkonflikt: Autonomie-Abhängigkeits-Konflikt (OPD).

Achse III (Med. Synopse)

IIIa: Lumbales Schmerzsyndrom (M54.5). IIIc: Hypothyreose (E03.9), beitragend zur Fatigue — Kausalanalyse (IIIk): TSH = 6.2 mU/L, partielle Erklärung der Antriebsminderung.

IIIIm: L-Thyroxin 75 µg, Wirkung 6/10; Ibuprofen 400 mg b.B., Wirkung 5/10; keine relevanten Interaktionen.

Achse IV (Umwelt & Funktion)

WHODAS 2.0 Gesamtscore: 28/100 (moderate Beeinträchtigung). Mini-ICF-APP: Einschränkungen in Regelmäßigkeit (3/4), Kontaktfähigkeit (2/4). GdB: nicht beantragt.

Stressoren: Drohender Arbeitsplatzverlust, Partnerschaftskrise.

Bezugspersonen: Partnerin (ambivalent stützend), Hausarzt Dr. X, kein Therapeut bisher.

Achse V (Bedingungsmodell)

P1 (Prädisposition): Frühe Verlusterfahrung, erhöhte Negative Affektivität.

P2 (Auslöser): Arbeitsplatzbedrohung seit 4 Monaten, zeitlich konkordant mit Symptombeginn.

P3 (Aufrechterhaltung): Sozialer Rückzug, unbehandelte Hypothyreose, Schmerzchronifizierung.

P4 (Protektiv): Durchschnittliche Intelligenz, stabile Wohnsituation, Problembewusstsein.

Achse VI (Belegsammlung)

Evidenz-Matrix: PHQ-9 (21.02.2026), GAD-7 (21.02.2026), Labor (TSH, CRP — 15.02.2026).

CAVE: Hypothyreose beitragende Ursache der Fatigue — Schilddrüsenparameter vor Antidepressiva-Einstellung kontrollieren!

Symptomverlauf: Antriebslosigkeit seit November 2025, progredient; Rückenschmerzen seit 2024, fluktuierend.

Diese Vignette illustriert, wie das 6-Achsen-Modell eine integrierte diagnostische Perspektive ermöglicht: Die Abdeckungsanalyse (78%) — berechnet als $C_{\text{total}} = \frac{1}{n} \sum c(s_i)$ über die Symptome Niedergeschlagenheit, Antriebslosigkeit, Schlafstörungen, Sorgen, Rückenschmerzen und Konzentrationsstörungen, wobei Rückenschmerzen und Konzentrationsstörungen nur partiell durch bestehende Diagnosen abgedeckt sind (vgl. Abschnitt 7) — identifiziert ungeklärte Symptome. Der CAVE-Hinweis verhindert eine vorschnelle Antidepressiva-Einstellung ohne Schilddrüsenkontrolle, und das Bedingungsmodell verbindet biographische Vulnerabilität mit aktuellem Auslöser.

12 Ethik, Datenschutz und algorithmischer Bias

Die computergestützte psychiatrische Diagnostik wirft spezifische ethische Fragen auf, die bei der Entwicklung und Implementierung systematisch adressiert werden müssen.

12.1 Algorithmischer Bias und Validierungspopulationen

Screening-Instrumente sind an spezifischen Populationen validiert, und die Übertragbarkeit ihrer Cutoff-Werte auf andere Populationen ist limitiert. Der PHQ-9 zeigt kulturell variable Cutoff-Werte: Während für westliche Populationen ein Cutoff von ≥ 10 validiert ist, liegen in asiatischen Ländern häufig niedrigere optimale Schwellenwerte vor. Der AQ-10 hat eine bekannte Geschlechterverzerrung bei Frauen mit Autismus-Spektrum-Störungen (Überdiagnose bei Männern, Unterdiagnose bei Frauen aufgrund unterschiedlicher Phänotypen). Für das AUDIT (Alkoholscreening) werden in der Literatur niedrigere geschlechtsspezifische Cutoffs für Frauen diskutiert, da die Standardschwelle von ≥ 8 möglicherweise Alkoholprobleme bei Frauen unterschätzt (Saunders et al., 1993).

Sozioökonomischer Bias: Instrumente wie das WHODAS 2.0 erfassen Funktionseinschränkungen, die bei Personen mit niedrigem sozioökonomischem Status teilweise durch fehlende Ressourcen

(z. B. Transport, Kinderbetreuung) bedingt sind, nicht durch die psychische Störung selbst. Das System muss diese strukturellen Faktoren in Achse IV (psychosoziale Umstände) separat dokumentieren, um Fehlattritionen zu vermeiden.

Migrationshintergrund und Sprachbarrieren: Selbstberichts-Instrumente setzen ausreichende Sprachkompetenz voraus. Bei Personen mit Migrationshintergrund können sprachliche Missverständnisse zu falsch-positiven oder falsch-negativen Ergebnissen führen. Das System sollte bei nicht-muttersprachlichen Patienten einen expliziten Hinweis auf diese Limitation ausgeben.

Mitigation: Das System muss diese Bias-Risiken transparent dokumentieren und — wo verfügbar — populationsspezifische Normen anbieten. Die Integration des Cultural Formulation Interview (Abschnitt 3.4) adressiert kulturellen Bias auf der Systemebene. Für jedes Screening-Instrument sollte die Validierungspopulation dokumentiert sein, sodass Kliniker die Übertragbarkeit auf den konkreten Fall beurteilen können.

12.2 Datenschutz und DSGVO

Psychiatrische Diagnosedaten gehören zu den sensibelsten Gesundheitsdaten. Die Implementierung muss folgende Anforderungen erfüllen: Verschlüsselung aller gespeicherten und übertragenen Daten (AES-256, TLS 1.3); optionale Zugriffskontrolle nach Professionszuordnung (Abschnitt 3.7); Audit-Trail für alle diagnostischen Entscheidungen; Recht auf Löschung und Datenportabilität; Datensparsamkeit — nur diagnostisch notwendige Informationen werden erfasst. Besondere Vorsicht gilt für die Belegsammlung (Achse VI), die persönliche Dokumente referenziert.

12.3 Informierte Einwilligung und Patientenautonomie

Die Nutzung eines computergestützten Diagnosesystems wirft Fragen der informierten Einwilligung auf. Patienten haben das Recht zu wissen, dass ihre diagnostische Beurteilung teilweise durch algorithmische Verfahren unterstützt wird. Das System sollte daher folgende Transparenzanforderungen erfüllen:

- **Aufklärung über Systemnutzung:** Patienten werden darüber informiert, dass Screening-Instrumente und diagnostische Entscheidungsbäume als Unterstützungswerkzeuge eingesetzt werden.
- **Opt-out-Möglichkeit:** Patienten haben das Recht, eine rein menschlich durchgeführte Diagnostik zu verlangen, falls sie der computergestützten Methode nicht vertrauen.
- **Erklärbarkeit von Diagnosevorschlägen:** Das System muss nachvollziehbar machen, welche Symptome und Kriterien zu einem Diagnosevorschlag geführt haben. Die PRO/CONTRA-Evidenzbewertung (Abschnitt 3.1) dient genau diesem Zweck.
- **Zugang zu eigenen Daten:** Patienten haben das Recht auf Einsicht in ihre diagnostische Akte (Achse I–VI) und auf Erklärung der dokumentierten Befunde.

Diese Anforderungen sind nicht nur ethisch geboten, sondern auch rechtlich durch die DSGVO (Art. 13–15) verankert.

12.4 Haftungsfragen und medizinisch-rechtliche Verantwortung

Die Nutzung eines computergestützten Diagnosesystems verschiebt nicht die Haftung vom Kliniker auf das System. Folgende rechtliche Prinzipien gelten:

Behandler-Haftung bleibt bestehen

Der behandelnde Arzt oder Psychotherapeut bleibt vollumfänglich haftbar für diagnostische Fehlentscheidungen, auch wenn diese durch ein algorithmisches System unterstützt wurden. Das System ist ein Werkzeug, kein Entscheidungsträger.

Sorgfaltspflicht bei Systemnutzung

Kliniker müssen das System sachgemäß nutzen und dessen Grenzen kennen. Eine blinde Übernahme algorithmischer Diagnosevorschläge ohne klinische Prüfung erfüllt nicht die ärztliche Sorgfaltspflicht.

Dokumentationspflicht

Die Nutzung des Systems und die klinische Überprüfung der Systemvorschläge sollten dokumentiert werden (Achse VI, Kontaktprotokoll). Dies dient der Nachvollziehbarkeit im Haftungsfall.

Produkthaftung des Entwicklers

Der Systementwickler haftet für nachweisliche Softwarefehler (z. B. falsche Implementierung von DSM-5-TR-Kriterien, Rechenfehler in der Abdeckungsanalyse). Die Open-Source-Veröffentlichung (Abschnitt 9) ermöglicht externe Code-Reviews und erhöht die Transparenz.

Medizinprodukt-Einstufung bedarf juristischer Klärung

Nach EU-Medizinprodukteverordnung (MDR 2017/745) sind reine Dokumentationssysteme ohne therapeutische oder prädiktive Funktion nicht zwingend als Medizinprodukt einzustufen. Das vorliegende System geht jedoch über reine Dokumentation hinaus: Die Gatekeeper-Logik, die algorithmischen Entscheidungsbäume und die Diagnosevorschläge könnten als Entscheidungsunterstützungssysteme im Sinne der MDR klassifiziert werden. Eine juristische Prüfung dieser Einstufung ist daher *zwingend erforderlich*, bevor das System in der klinischen Praxis eingesetzt wird.

Die klare Trennung zwischen *diagnostischer Unterstützung* (zulässig) und *autonomer Diagnosestellung* (nicht implementiert) ist essentiell für die rechtliche Absicherung.

12.5 Klinische Verantwortung und epistemische Grenzen

Das System ist als *Unterstützungswerkzeug* konzipiert, nicht als diagnostischer Automat. Alle algorithmischen Diagnosevorschläge erfordern klinische Bestätigung. Die epistemische Grenze der Automatisierbarkeit (vgl. Stufe 6 der Gatekeeper-Logik, Abschnitt 4) wird im System explizit kommuniziert. Die finale diagnostische Verantwortung liegt stets beim behandelnden Kliniker.

Kritische Fälle, die algorithmische Systeme nicht zuverlässig bewerten können:

- **Suizidalität:** Selbstberichts-Instrumente (C-SSRS) sind hilfreich, aber jede Bestätigung suizidaler Gedanken erfordert ein ausführliches klinisches Gespräch. Algorithmische Risikobewertungen können die klinische Einschätzung nicht ersetzen.
- **Psychotische Symptome:** Selbstberichts-Instrumente (PQ-16) sind Screening-Werkzeuge, keine diagnostischen Instrumente. Eine Bestätigung psychotischer Symptome erfordert klinische Exploration und oft Fremdanamnese.

- **Kulturgebundene Syndrome:** Das DSM-5-TR enthält Glossare kulturgebundener Syndrome (z. B. Ataque de nervios, Taijin kyofusho), die algorithmisch schwer zu erfassen sind. Hier ist kulturelle Kompetenz des Klinikerns unersetzlich.

Diese Grenzen machen das System nicht unbrauchbar, sondern unterstreichen die Notwendigkeit einer *hybriden* Diagnostik, in der algorithmische Unterstützung und klinisches Urteil komplementär wirken.

13 Validierungsstrategie

Aktueller Status: Der vorliegende Artikel präsentiert die konzeptionelle Architektur und technische Implementierung des 6-Achsen-Modells. Die nachfolgend beschriebene Validierungsstrategie stellt einen *Implementierungsplan* dar — die empirische Validierung ist zum gegenwärtigen Zeitpunkt noch nicht durchgeführt. Dieser Abschnitt beschreibt daher die geplanten Validierungsschritte, nicht bereits vorliegende Ergebnisse.

Die Abschaffung des DSM-IV-Systems wurde unter anderem durch mangelnde Interrater-Reliabilität begründet. Das vorliegende System muss daher von Anfang an eine rigorose Validierungsstrategie verfolgen:

Tabelle 11: Validierungs-Gate-Ledger für die geplante Post-Design-Evaluation. Die Zeilen definieren das minimale Datenobjekt, das vorliegen muss, bevor ein Designclaim zu einem Prozess-, Nutzen- oder klinischen Validitätsclaim angehoben werden darf.

Gate	Minimales Datenobjekt	Pass- / Hold-Regel	Verhinderter Überclaim
Diagnostisches Herleitungs-Ledger	Extrahierte Befunde, Differenzialhypthesen, Regel/Backing, Ausschlusskriterien, Unsicherheit und Gutachter-Notizen	Pass nur, wenn Primärdiagnosen und verworfene Alternativen von Patientendaten zu klinischer Regel und Expertenbegutachtung rückverfolgbar sind	Top-1-Diagnoseübereinstimmung oder LLM-Vorschlag wird als nachgewiesene Entscheidungsqualität gelesen
Konsultations-Evidenzerhebungs-Gate	Frageprotokoll zu fehlenden DSM-/ICD-Kriterien, Dauer, Funktion, Fremdanamnese und somatischen Ausschlüssen	Hold, wenn ein fehlendes Kriterium aus Schweigen erschlossen statt aktiv erfragt oder als nicht verfügbar markiert wird	Statische Vignettenkorrektheit wird als Konsultationskompetenz missverstanden
Synthetik-Fidelity-/Fairness-Gate	Vignettenmanifest mit Demografie, Basisratenannahmen, Schwellenverteilungen und Subgruppenfehlern	Pass nur, wenn synthetische Fälle klinisch plausible Varianz erhalten und seltene oder Minderheitenprofile nicht kollabieren	Plausible Einzelfälle werden als populationsvalide Evaluationsdaten behandelt
KI-Agenten-Governance-Gate	Rollendefinition, Human-in-the-loop-Punkt, Eskalationsregel, Prüfprotokoll, Datenschutzgrenze und Überwachungsplan	Hold, wenn das System autonom diagnostisch handeln kann oder Verantwortung nicht zuordenbar ist	Ein Assistenzprototyp wird als klinisch validierte autonome KI dargestellt
ICD-Codierungsgrenze	Zuordnung der klinischen Entscheidung zu administrativem ICD-Code mit Codierrolle und Umgang mit Dissens	Pass nur, wenn die Codierung explizit nachgelagert bleibt und die klinische Diagnose nicht verändert	Codiergenauigkeit wird als diagnostische Validität gewertet
Achse-VI-Biomarker-Warteschlange	Signalprovenienz, Validierungspopulation, Informationsabfluss-Prüfung, Subgruppenanalyse und prospektiver Bestätigungsstatus	Hold, solange Wearable-, Stimm-, EMA- oder Chronosignale nicht repliziert sind und nur Kandidatensignale bleiben	Explorative digitale Signale werden zu diagnostischen Biomarkern erhoben

Tabelle 11 ist damit eine Designanforderungstabelle, keine Ergebnistabelle. Sie hält die geplante Validierungssequenz an der zentralen Grenze des Modells fest: Strukturierte Entscheidungsunterstützung kann vor klinischer Wirksamkeit evaluiert werden, darf aber ohne entsprechende Gate-Daten nicht als validierte klinische Diagnostik dargestellt werden.

Phase 1: Expertenbegutachtung (N=10–15)

Strukturierte Begutachtung der Achsenarchitektur durch Psychiater, klinische Psychologen und Sozialarbeiter. Bewertung der Vollständigkeit, klinischen Plausibilität und Praktikabilität. Ziel: Identifikation fehlender Subachsen oder überflüssiger Komponenten.

Phase 2: Inter-Rater-Reliabilitätsstudie mit Fallvignetten (N=10 Rater, 20 Vignetten)

Dies ist die kritische Pilotstudie zur initialen Validierung des Systems:

Rekrutierung: $N = 10$ unabhängige Rater (5 Psychiater, 5 approbierte Psychologische Psychotherapeuten; alle mit ≥ 3 Jahren klinischer Erfahrung).

Stimulusmaterial: 20 standardisierte Fallvignetten (10 einfache Fälle mit Einzeldiagnose, 10 komplexe Fälle mit Komorbidität), erstellt nach Vorbild der DSM-5-TR Clinical Cases (Barnhill, 2014). Jede Vignette enthält: Anamnese, aktuelle Beschwerden, Symptomverlauf, relevante medizinische Vorgeschichte, soziales Umfeld. Diagnosen vorab durch Expertenpanel (2 unabhängige Fachärzte + Konsensprozess) als Goldstandard etabliert.

Prozedur: Jeder Rater diagnostiziert alle 20 Vignetten (1) mit konventionellem Vorgehen (Freitext-Diagnose mit Begründung), (2) mit dem 6-Achsen-System (vollständige Achsendiagnostik). Reihenfolge der Methoden randomisiert; mindestens 1 Woche Washout zwischen Bedingungen pro Vignette.

Primäre Outcome-Variablen:

- *Inter-Rater-Reliabilität:* Fleiss' κ für kategoriale Diagnosen (Achse I Primärdiagnose); Intraklassen-Korrelation (ICC) für dimensionale Ratings (PID-5-BF auf Achse II, WHO-DAS 2.0 auf Achse IV). Akzeptanzkriterium: $\kappa \geq 0,7$ (substanzielle Übereinstimmung); ICC $\geq 0,75$.
- *Konvergente Validität:* Übereinstimmung 6-Achsen-Diagnosen vs. Goldstandard. Sensitivität und Spezifität pro Diagnose.
- *Inkrementelle Validität der Abdeckungsanalyse:* Anteil der Fälle, in denen Achse Ii (unerklärte Symptome) klinisch relevante Differenzialdiagnosen identifiziert, die im Freitext-Vorgehen übersehen wurden. Hypothese: $\geq 20\%$ der komplexen Fälle profitieren von Abdeckungsanalyse.
- *Bearbeitungszeit:* Durchschnittliche Bearbeitungszeit pro Vignette (konventionell vs. 6-Achsen).

Sekundäre Outcome-Variablen:

- System Usability Scale (SUS) nach Abschluss aller Vignetten
- Subjektive Einschätzung der Nützlichkeit einzelner Achsen (5-Punkt-Likert)
- Qualitative Interviews zu identifizierten Schwachstellen des Systems

Power-Analyse: Bei $N = 10$ Ratern und $k = 20$ Vignetten (Targets) kann ein ICC = 0,75 mit Power $1 - \beta = 0,8$ und $\alpha = 0,05$ gegen die Nullhypothese ICC = 0,5 getestet werden. Die präzise KI-Breite hängt von der Anzahl der Targets ab, nicht von der Gesamtzahl der Urteile ($N \times k = 200$), da diese nicht unabhängig sind. Bei $k = 20$ Targets und $N = 10$ Ratern ist ein 95%-KI von ungefähr $\pm 0,15$ zu erwarten (Shrout & Fleiss, 1979). Eine Erhöhung auf $k = 30$

Vignetten würde die Präzision substanziell verbessern und sollte bei ausreichenden Ressourcen angestrebt werden.

Falsifikationskriterium: Falls $\kappa < 0,6$ oder ICC $< 0,65$, ist die Inter-Rater-Reliabilität unzureichend — dies erfordert Revision der Achsenstruktur oder klarere Operationalisierungen.

Phase 3: Klinische Felderprobung (N=200+)

Prospektive Anwendung in klinischen Settings (ambulant und stationär). Messung von: Interrater-Reliabilität, konvergente Validität gegenüber etablierten Systemen, inkrementelle Validität der Abdeckungsanalyse (werden durch Ii/IIIi identifizierte Lücken klinisch bestätigt?), Akzeptanz und Usability (System Usability Scale, SUS).

Phase 4: Multi-Site-Trial

Multizentrische Studie zur Generalisierbarkeit. Vergleich stationär vs. ambulant, Erwachsene vs. Kinder/Jugendliche, verschiedene kulturelle Kontexte.

Der MentalBench-Benchmark (Song et al., 2026) zeigt, dass große Sprachmodelle systematisch an komplexen Dauer-, Funktions- und Ausschlusskriterien in der psychiatrischen Diagnostik scheitern, was die Begründung für regelbasierte Entscheidungsunterstützungssysteme mit expliziter Gatekeeper-Logik gegenüber rein statistischen Ansätzen verstärkt. Angesichts der rapiden Fortschritte in der LLM-basierten klinischen Unterstützung ist zu betonen, dass das vorliegende System und KI-basierte Ansätze komplementär, nicht konkurrierend sind: Das 6-Achsen-Modell liefert die strukturierte Architektur und die explizite Entscheidungslogik, die für klinische Nachvollziehbarkeit und Haftungssicherheit unerlässlich sind — Eigenschaften, die Black-Box-Modelle systemisch nicht bieten können. Zukünftige Implementierungen könnten LLMs als *Assistenzsysteme innerhalb* der regelbasierten Architektur nutzen (z. B. für Freitext-Analyse von Anamnese-Berichten), ohne die Transparenz des Entscheidungspfads zu kompromittieren.

14 Interoperabilität und Gesundheits-IT-Standards

Für die Integration in bestehende Gesundheitsinformationssysteme muss das 6-Achsen-Modell standardkonforme Schnittstellen implementieren.

HL7 FHIR (R4): Die Achsen lassen sich auf FHIR-Ressourcen abbilden: Achse I/III-Diagnosen als Condition-Ressourcen mit Extensions für Subachsen-Zuordnung; Screening-Ergebnisse als QuestionnaireResponse; Funktionsstatus (Achse IV) als ClinicalImpression; die Fallformulierung (Achse V) als CarePlan; Belege (Achse VI) als DocumentReference.

SNOMED CT: Alle Diagnosen sollten neben DSM-5-TR- und ICD-11-Codes auch SNOMED-CT-Konzept-IDs führen, um internationale Interoperabilität zu gewährleisten.

LOINC: Für Laborwerte (Achse IIIe/IIIIf), klinische Beobachtungen und Screening-Ergebnisse sollten LOINC-Codes (Logical Observation Identifiers Names and Codes) verwendet werden. Dies ermöglicht die standardisierte Dokumentation und den Austausch von Laborbefunden und psychometrischen Testergebnissen in der Evidenz-Matrix (Achse VI).

MHIRA-Kompatibilität: Das MHIRA-Projekt (Mental Health Information Reporting Assistant, BMC Psychiatry 2023) stellt die relevanteste Open-Source-Referenzarchitektur dar: ein cloud-basiertes,

Docker-deployiertes psychiatrisches EHR-System mit digitalisierten psychometrischen Instrumenten. Eine FHIR-basierte Schnittstelle zum MHIRA-System sollte priorisiert werden.

15 Diskussion und Ausblick

Das vorgestellte 6-Achsen-Modell ist kein Rückgriff auf das DSM-IV, sondern repräsentiert eine **vorgeschlagene Weiterentwicklung**, auf die die psychiatrische Fachwelt selbst konvergiert. Zehn vorgeschlagene Designmerkmale verdienen besondere Hervorhebung:

Erstens erweitert die Abdeckungsanalyse (Abschnitt 7) bestehende Entscheidungsunterstützungsmethoden um eine quantitative Qualitätssicherungsmetrik. Während verwandte Ansätze in Bayesianischen Diagnosesystemen existieren, liegt der spezifische Beitrag in der klinischen Qualitätssicherungsperspektive: Sie adressiert das von Plana-Ripoll et al. (2019) dokumentierte Grundproblem transdiagnostischer Komorbidität und wird symmetrisch in Achse I (Ii) und Achse III (IIIi) implementiert.

Zweitens verbrückt die operationalisierte Integration von Fallformulierung (Achse V) mit diagnostischer Klassifikation die langjährige Kluft zwischen „Welche Störung hat dieser Patient?“ und „Warum hat dieser Patient diese Störung?“.

Drittens adressiert die Dual-System-Architektur DSM-5-TR/ICD-11 ein reales klinisches Bedürfnis in Kontexten, in denen beide Systeme Anwendung finden.

Viertens stellt die symmetrische Parallelstruktur von Achse I und Achse III sicher, dass das System als gemeinsames Werkzeug für alle beteiligten Professionen funktioniert. In den hier verglichenen computergestützten Diagnosesystemen (OPCRIT, DTREE, CATEGO, CIDI, MHIRA) wurde ein solches Designprinzip nicht identifiziert; eine systematische Literaturrecherche, die auch weniger bekannte oder institutionsinterne Systeme umfasst, steht jedoch noch aus und ist für die endgültige Bewertung der Neuheit dieses Ansatzes erforderlich.

Fünftens bietet die Erweiterung auf 11 Störungsmodul eine vollständige Abdeckung zwischen Screening und Diagnostik: Jedes Screening-Instrument mündet in einen strukturierten diagnostischen Workflow.

Sechstens: Anwendung in Ausbildung und Supervision. Das System eignet sich besonders als Lehr- und Supervisionswerkzeug in der psychiatrischen und psychotherapeutischen Ausbildung. Die PRO/CONTRA-Struktur zwingt Auszubildende, ihre diagnostischen Entscheidungen explizit zu begründen und Gegenargumente systematisch zu dokumentieren — eine Fähigkeit, die in konventioneller Freitext-Diagnostik nicht strukturell gefordert wird. Der Diagnostic Coverage Index (DCI) liefert Supervisoren eine quantitative Rückmeldung über die diagnostische Vollständigkeit der Auszubildenden: Ein niedriger DCI-Wert macht diagnostische Lücken sichtbar, die in Fallbesprechungen adressiert werden können. In der psychotherapeutischen Ausbildung bietet Achse V (Bedingungsmodell) eine strukturierte Alternative zu unstrukturierten Fallformulierungen, die häufig idiosynkratisch und schwer vergleichbar sind.

Siebtens operationalisiert die PRO/CONTRA-Evidenzbewertung mit numerischer Konfidenz die differenzialdiagnostische Transparenz: Der Kliniker dokumentiert nicht nur, *welche* Diagnose er stellt, sondern auch *warum* — einschließlich der bewusst verworfenen Gegenargumente. Diese Transparenz ermöglicht *Shared Decision Making* (SDM): Patienten können nachvollziehen, auf welchen Befunden ihre Diagnose basiert und welche Unsicherheiten bestehen, was die therapeutische Allianz und die Patientenautonomie

fördert. Die strukturierte PRO/CONTRA-Darstellung entspricht dabei dem dritten Schritt des SDM-Modells (Informationsaustausch und Deliberation) und schafft eine gemeinsame Entscheidungsgrundlage zwischen Kliniker und Patient.

Achtens implementiert das CAVE-Warnsystem in Achse VI eine achsenübergreifende Sicherheitsschicht, die kritische klinische Risiken (Labor-Artefakte, Medikamenten-Interaktionen, Kontraindikationen, zeitliche Fehlzusammenhänge) prominent kennzeichnet. Angesichts der bekannten Polypharmazie-Problematik in der Psychiatrie — insbesondere bei komorbiden somatischen Erkrankungen — adressiert das CAVE-System eine häufige klinische Fehlerquelle, die in bestehenden Klassifikationssystemen nicht systematisch berücksichtigt wird.

Neuntens ergänzt der longitudinale Symptomverlauf die querschnittliche Diagnostik um eine zeitliche Dimension: Die Dokumentation von Symptombeginn, aktuellem Status und Therapieansprechen ermöglicht die Identifikation von Chronifizierungsmustern und Therapieresistenz, die für die Behandlungsplanung essentiell sind. Achse VI realisiert damit de facto ein *integriertes Routine Outcome Monitoring (ROM)*-System im Sinne von Barkham et al. (2023): Die regelmäßige Erfassung validierter Instrumente (PHQ-9, GAD-7, PCL-5) mit Verlaufsvisualisierung ermöglicht die frühzeitige Erkennung von Not-on-Track-Verläufen und unterstützt adaptive Behandlungsplanung.

Zehntens realisiert die Designphilosophie des *lebenden Dokuments* ein Paradigma, das die diagnostische Akte nicht als einmalig auszufüllendes Formular, sondern als mitwachsende Prozessdokumentation versteht. Bezugspersonen-Netzwerk (Achse IV), prägende Erfahrungen und Grundkonflikte (Achse II) sowie das Kontakt- und Beobachtungsprotokoll (Achse VI) sind offene Listen, die den diagnostischen Prozess selbst dokumentieren und kontinuierlich Material für die Fallformulierung (Achse V) liefern.

Methodische Einordnung: Im Design-Science-Rahmen (Hevner et al., 2004; Peffers et al., 2007) umfasst der vorliegende Artikel die Phasen Problem Identification, Design & Development sowie Demonstration (Prototyp und Fallvignette). Die formale Evaluationsphase — die für den vollständigen Design-Science-Zyklus konstitutiv ist — steht noch aus und wird durch die in Abschnitt 13 beschriebene 4-Phasen-Strategie adressiert. Der Artikel versteht sich daher als Beitrag zur Designforschung, nicht als abgeschlossene Evaluation.

Klinische Praktikabilität und Bearbeitungszeit: Eine zentrale Frage für die klinische Adoption ist die Bearbeitungszeit. Bei vollständiger Ersterhebung aller sechs Achsen ist mit einer Bearbeitungszeit von 90–120 Minuten zu rechnen (einschließlich Screening, Anamnese und Dokumentation) — vergleichbar mit einer umfassenden psychiatrischen Erstaufnahme, aber deutlich länger als eine fokussierte ambulante Konsultation (20–50 Minuten). Das Skelett-Prinzip ermöglicht jedoch eine gestufte Nutzung: Eine Minimalerhebung (Achse I mit Cross-Cutting-Screening und Achse IV mit WHODAS 2.0) ist in 30–45 Minuten möglich; die übrigen Achsen werden im Verlauf ergänzt. Die Differenzierung ambulanter und stationärer Nutzung ist für die geplante Validierung essentiell: Stationäre Teams können die Achsen arbeitsteilig und über mehrere Tage bearbeiten; ambulante Einzelbehandler benötigen den gestuften Ansatz. Diese Unterscheidung sollte in Phase 3 der Validierung (klinische Felderprobung) systematisch untersucht werden.

Verhältnis zur Process-Based Therapy (PBT): Die PBT-Bewegung argumentiert gegen diagnostische Kategorien und für eine rein prozessbasierte Interventionsplanung. Das 6-Achsen-Modell positioniert sich als Brücke: Es behält kategoriale Diagnostik bei (klinisch, administrativ und versicherungsrechtlich notwendig), integriert aber über Achse V (Bedingungsmodell) und die Abdeckungsanalyse prozessori-

enterte Elemente — insbesondere die Identifikation aufrechterhaltender Faktoren (P3) und ungeklärter Symptome, die auf behandelbare Prozesse jenseits der Kategorienlogik hinweisen können.

Die technische Implementierung sollte vier Meilensteine priorisieren: (1) das Cross-Cutting-Screening-Modul als Einstiegspunkt des Systems, (2) die Gatekeeper-Zustandsmaschine mittels `transitions` HSM, (3) das PID-5-BF-Assessment mit Plotly-Radardiagramm und WeasyPrint-PDF-Export, und (4) die FHIR-Schnittstellendefinition für Interoperabilität.

Implementierungsbarrieren: Die Erfahrung mit früheren multiaxialen Systemen und klinischen IT-Einführungen zeigt, dass technische Funktionalität allein keine Adoption gewährleistet. Zu den erwartbaren Barrieren gehören: (1) Zeitmangel im klinischen Alltag, insbesondere in unterbesetzten ambulanten Settings; (2) institutionelle Trägheit und Widerstand gegen neue Dokumentationssysteme, die zunächst als Mehrbelastung wahrgenommen werden; (3) die Notwendigkeit interdisziplinärer Abstimmung, die in fragmentierten Versorgungsstrukturen organisatorisch anspruchsvoll ist; und (4) die Integration in bestehende Krankenhausinformationssysteme (KIS), die proprietäre Schnittstellen und eingeschränkte Erweiterbarkeit aufweisen. Das Skelett-Prinzip und die gestufte Nutzung (vgl. Bearbeitungszeit oben) adressieren die Zeitbarriere partiell; die übrigen Barrieren erfordern eine begleitende Implementierungsstrategie im Sinne des CFIR-Frameworks (Damschroder et al., 2009).

16 Limitationen und zukünftiger Forschungsbedarf

Das vorgestellte 6-Achsen-Modell unterliegt mehreren Limitationen, die bei der Interpretation und Weiterentwicklung berücksichtigt werden müssen.

Fehlende empirische Validierung: Die zentrale Limitation besteht darin, dass das Modell bislang rein konzeptionell-theoretisch entwickelt wurde. Weder Interrater-Reliabilität noch konvergente oder inkrementelle Validität sind empirisch geprüft. Die in Abschnitt 13 beschriebene 4-Phasen-Validierungsstrategie stellt einen Forschungsplan dar, keine vorliegenden Ergebnisse. Bis zur Durchführung mindestens der Phasen 1 und 2 bleibt der klinische Nutzen des Modells eine begründete Hypothese.

Komplexität und klinische Praktikabilität: Das System umfasst sechs Achsen mit insgesamt 40 Subachsen. Obwohl das Skelett-Prinzip keine Pflichtfelder vorsieht, könnte die Komplexität in der klinischen Praxis abschreckend wirken. Eine wesentliche Forschungsfrage ist, ob Kliniker das System tatsächlich in der intendierten Tiefe nutzen oder auf wenige Achsen reduzieren. Usability-Studien (SUS-Skala) sind essenziell.

Skalierbarkeit der Gewichtsmatrix: Die Abdeckungsanalyse setzt eine vollständige Gewichtsmatrix $w(s_i, d_j)$ für alle Symptom-Diagnose-Kombinationen voraus. Bei über 300 DSM-5-TR-Diagnosen und mehreren hundert ICD-11-Codes ist die manuelle Erstellung und Pflege dieser Matrix ein erheblicher Aufwand. Eine pragmatische Lösung besteht darin, die Gewichte nur für die im konkreten Fall relevanten Diagnosen zu berechnen (typischerweise 3–8 Differenzialdiagnosen), wodurch die Matrix auf handhabbare Größe reduziert wird. Langfristig könnten die Gewichte aus strukturierten Kriterienkatalogen (z. B. SNOMED-CT-Konzepte, ICD-11 Foundation Layer) semi-automatisch abgeleitet werden.

Keine Normierung der Abdeckungsanalyse: Die quantitative Abdeckungsanalyse (Achse Ii/IIIi) verwendet prozentuale Metriken, für die keine empirischen Normen existieren. Die Schwellenwerte (85%/60%) sind durch klinische Analogien motiviert (vgl. Abschnitt 7), aber nicht empirisch validiert. Die Sensitivitätsanalyse zeigt Robustheit bei $n \geq 8$ Symptomen, aber Instabilität bei kleinen Symptomzahlen. Die empirische Kalibrierung in mindestens drei klinischen Kohortengruppen (stationär, ambulant,

somatisch komorbid) ist eine Voraussetzung für klinische Adoption.

Eingeschränkte Literaturbasis: Als Designarbeit stützt sich diese Arbeit primär auf diagnostische Klassifikationshandbücher und eine kleine Anzahl grundlegender Publikationen. Ein systematisches Review aller existierenden computergestützten Diagnosesysteme (z. B. OPCRIT, DTREE, CATEGO) und deren empirische Erfolgsbilanz würde die Begründung für die hier getroffenen spezifischen Designentscheidungen stärken.

Dokumentation des KI-gestützten Prozesses: Der substanzielle Einsatz KI-gestützter Werkzeuge sowohl am Systemdesign als auch an der Manuskripterstellung (d. h. Literaturorganisation, Textstrukturierung, Übersetzungsunterstützung, Konsistenzprüfung und Formulierungshilfe; vgl. Methoden, Phase 4) wirft Fragen zur Prozesstransparenz auf. Während der Quellcode öffentlich verfügbar ist, ist die iterative Prompt-, Review- und Revisionsgeschichte — einschließlich der Expertenfeedback-Zyklen — nicht vollständig so dokumentiert, dass eine vollständige Prozessrekonstruktion möglich wäre.

Kulturelle Generalisierbarkeit und jurisdiktionsspezifische Module: Das Modell integriert das Cultural Formulation Interview (CFI), wurde aber primär aus westlich-europäischer Perspektive entwickelt. Jurisdiktionsspezifische Subachsen wie der GdB (Achse IVb) sind als austauschbare Module konzipiert: Für internationale Implementierungen sollte der GdB durch das jeweilige nationale Behinderungsbewertungssystem ersetzt werden (z. B. Disability Adjusted Life Years in WHO-Kontexten, Social Security Disability Determination in den USA). Die Anwendbarkeit in nicht-westlichen klinischen Kontexten bedarf gesonderter Prüfung. Insbesondere die Persönlichkeitsdiagnostik mittels PID-5 und die biographischen Komponenten (Achse II) können kulturell unterschiedlich interpretiert werden.

Technologieabhängigkeit: Die Implementierung als computergestütztes Entscheidungsunterstützungssystem setzt eine funktionsfähige IT-Infrastruktur voraus. In ressourcenarmen Settings oder bei Systemausfällen muss das Modell auch als papierbasiertes Schema funktionieren — eine Anforderung, die bislang nicht systematisch geprüft wurde.

Fehlende Stakeholder-Perspektive und Kosteneffektivität: Der vorliegende Artikel ist primär aus der Systementwickler-Perspektive geschrieben. Wesentliche Perspektiven fehlen: Wie erleben Patienten eine derart umfassende diagnostische Erhebung? Wie verhält sich die Bearbeitungszeit im Vergleich zur konventionellen Diagnostik? Wie bewerten Kostenträger (z. B. Krankenkassen) den zusätzlichen diagnostischen Aufwand? Zukünftige Studien sollten eine Bearbeitungszeitanalyse, eine Kosten-Nutzen-Bewertung und eine systematische Erhebung der Patientenperspektive einschließen.

Learning-Health-System-Perspektive: Die strukturierten, standardisiert kodierten Daten des 6-Achsen-Modells (ICD-11, SNOMED CT, ICF, PID-5) eignen sich ideal für sekundäre Forschungsnutzung. In einem Learning-Health-System-Paradigma trägt jede diagnostische Episode zur iterativen Verbesserung der Gewichtsmatrix der Abdeckungsanalyse bei: Empirische Symptom-Diagnose-Assoziationen aus aggregierten, anonymisierten Patientendaten können die initialen Gewichte schrittweise durch datengestützte Schätzungen ersetzen. Diese Perspektive verbindet die klinische Routineanwendung mit der kontinuierlichen Systemoptimierung.

Zukünftiger Forschungsbedarf: Neben der empirischen Validierung (Abschnitt 13) sind vier Forschungsrichtungen prioritär: (1) die Entwicklung eines abgekürzten „Rapid Assessment“-Modus für Notaufnahmen und Erstgespräche, (2) die Integration prädiktiver Modelle (maschinelles Lernen) zur Unterstützung der Differenzialdiagnostik auf Basis der akkumulierten Patientendaten, (3) längsschnittliche Studien zur Sensitivität des Symptomverlaufs (Achse VI) für Therapieansprechen und Rückfallprädik-

tion, und (4) die Anbindung an Ecological Momentary Assessment (EMA) und Digital Phenotyping: Smartphone-basierte Echtzeit-Datenerhebung könnte den longitudinalen Symptomverlauf (Achse VI) mit kontinuierlichen Verhaltensdaten anreichern und die zeitliche Auflösung der diagnostischen Dokumentation substanziell erhöhen. Darüber hinaus sollte die tatsächliche klinische Einführung durch einen Implementation-Science-Rahmen — etwa das Consolidated Framework for Implementation Research (CFIR) — begleitet werden, der Barrieren und Förderfaktoren der Adoption in den fünf CFIR-Domänen (Intervention Characteristics, Outer Setting, Inner Setting, Individuals, Process) systematisch erfasst. Die historische Erfahrung mit dem DSM-IV-Multiaxialsystem zeigt, dass selbst gut konzipierte Systeme an inkonsistenter klinischer Nutzung scheitern können.

17 Zusammenfassung

Das vorgeschlagene 6-Achsen-System adressiert eine strukturelle Lücke in der psychiatrischen Diagnostik, die seit der Abschaffung des DSM-IV-Multiaxialsystems besteht. Für die klinische Praxis liegt der primäre Beitrag des Modells in der Wiederherstellung — und substanziellen Erweiterung — der strukturierten Aufforderung zur umfassenden biopsychosozialen Beurteilung. Die symmetrische Achse-I/III-Architektur ermöglicht strukturierte multiprofessionelle Zusammenarbeit, die Abdeckungsanalyse liefert Klinikern eine transparente, quantitative Metrik für diagnostische Vollständigkeit, und das CAVE-Warnsystem adressiert die wachsende Herausforderung des achsenübergreifenden Risikomanagements bei komplexen Fällen. Die PRO/CONTRA-Evidenzbewertung mit Konfidenzschätzung operationalisiert diagnostische Transparenz in einer Weise, die sowohl klinische Rechenschaftspflicht als auch Ausbildung unterstützt.

Die Architektur des Modells ist konsistent mit der institutionellen Entwicklungsrichtung (vgl. Abschnitt 2). Die Konvergenz mit der expliziten Forderung von Erlich et al. (2025) nach einer Rückkehr zur strukturierten axialen Beurteilung unterstützt die Aktualität dieses Beitrags. Zugleich geht das Modell über institutionelle Revisionen hinaus, insbesondere durch die Abdeckungsanalyse und die operationalisierte Fallformulierung (Achse V), die Klassifikation und Behandlungsplanung verbrückt.

Konkrete nächste Schritte umfassen: (1) eine fokussierte Expertenbegutachtung ($N = 5–10$) der Achsenstruktur als unmittelbarer Minimalschritt, (2) die Interrater-Reliabilitätsstudie mit standardisierten Fallvignetten (Phase 2, Abschnitt 13), (3) die Entwicklung der HL7-FHIR-Mapping-Spezifikation, (4) die Publikation der formalen mathematischen Spezifikation der Abdeckungsanalyse und (5) empirische Vergleiche von Freitext-Dokumentation versus strukturierter multiaxialer Diagnostik. Der vollständige Quellcode ist öffentlich verfügbar, um unabhängige Evaluation und Replikation zu ermöglichen.

Zusammengefasst: Das 6-Achsen-Modell versteht sich als Entwurf einer diagnostischen Architektur, die das Beste aus kategorialer Klassifikation, dimensionaler Erfassung und individualisierter Fallformulierung in einem einzigen, computergestützten System vereint — ein Entwurf, der seine klinische Bewährungsprobe noch vor sich hat.

Literatur

Aboraya, A., Rankin, E., France, C., El-Missiry, A. & John, C. (2006). The reliability of psychiatric diagnosis revisited: The clinician's guide to improve the reliability of psychiatric diagnosis. *Psychiatry (Edgmont)*, 3(1), 41–50. PMID: 21103149.

- Achenbach, T. M. & Rescorla, L. A. (2001). *Manual for the ASEBA School-Age Forms & Profiles*. Burlington, VT: University of Vermont, Research Center for Children, Youth, & Families.
- Allison, C., Auyeung, B. & Baron-Cohen, S. (2012). Toward brief “red flags” for autism screening: The Short Autism Spectrum Quotient and the Short Quantitative Checklist in 1,000 cases and 3,000 controls. *Journal of the American Academy of Child & Adolescent Psychiatry*, 51(2), 202–212.e7. DOI: 10.1016/j.jaac.2011.11.003.
- American Psychiatric Association (1980). *Diagnostic and Statistical Manual of Mental Disorders* (3rd ed.). Washington, DC: American Psychiatric Publishing.
- American Psychiatric Association (2013). *Diagnostic and Statistical Manual of Mental Disorders* (5th ed.). Arlington, VA: American Psychiatric Publishing.
- American Psychiatric Association (2022). *Diagnostic and Statistical Manual of Mental Disorders, Text Revision* (DSM-5-TR). Washington, DC: American Psychiatric Publishing.
- Ayuso-Mateos, J. L., Avila, C. C., Anaya, C., Cieza, A. & Vieta, E. (2013). Development of the International Classification of Functioning, Disability and Health core sets for bipolar disorders: Results of an international consensus process. *Disability and Rehabilitation*, 35(25), 2138–2146. DOI: 10.3109/09638288.2013.771708.
- Bach, B., Kramer, U., Doering, S. et al. (2022). The ICD-11 classification of personality disorders: A European perspective on challenges and opportunities. *Borderline Personality Disorder and Emotion Dysregulation*, 9(1), 12.
- Barkham, M., De Jong, K., Delgadillo, J. & Lutz, W. (2023). Routine Outcome Monitoring (ROM) and Feedback: Research Review and Recommendations. *Psychotherapy Research*, 33(7), 841–855. DOI: 10.1080/10503307.2023.2181114.
- Barnhill, J. W. (Ed.) (2014). *DSM-5 Clinical Cases*. Washington, DC: American Psychiatric Publishing.
- Mayall, M., McDermott, B., Sadhu, R., Teoh, Y., Bosanquet, M. & Nundeeekasen, S. (2024). Practical aspects of multiaxial classification: A clinically useful biopsychosocial framework for child and adolescent psychiatry. *BJPsych Advances*, 30(4), 242–256. DOI: 10.1192/bja.2023.39.
- Blevins, C. A., Weathers, F. W., Davis, M. T. et al. (2015). The Posttraumatic Stress Disorder Checklist for DSM-5 (PCL-5). *Journal of Traumatic Stress*, 28(6), 489–498.
- Bolton, D. (2008). *What is Mental Disorder? An Essay in Philosophy, Science, and Values*. Oxford: Oxford University Press.
- Carlson, E. B. & Putnam, F. W. (1993). An update on the Dissociative Experiences Scale. *Dissociation*, 6(1), 16–27.
- Cieza, A., Chatterji, S., Andersen, C. et al. (2004). ICF Core Sets for depression. *Journal of Rehabilitation Medicine*, 36(Suppl. 44), 128–134. DOI: 10.1080/16501960410016055.

- Cloitre, M., Shevlin, M., Brewin, C. R. et al. (2018). The International Trauma Questionnaire: Development of a self-report measure of ICD-11 PTSD and Complex PTSD. *Acta Psychiatrica Scandinavica*, 138(6), 536–546.
- Damschroder, L. J., Aron, D. C., Keith, R. E. et al. (2009). Fostering implementation of health services research findings into practice: A consolidated framework for advancing implementation science. *Implementation Science*, 4, 50.
- Erlich, M. D., First, M. B., Talley, R. M. et al. (2025). Integrating social determinants of health into clinical formulations: The need for a biaxial system in the DSM and psychiatry. *Psychiatric Services*, 76(10), 911–914.
- First, M. B., Williams, J. B. W. & Spitzer, R. L. (1993). DTREE: A decision-support system for DSM-III-R and DSM-IV diagnoses. *Psychopharmacology Bulletin*, 29(3), 255–263.
- First, M. B. (2024). *DSM-5-TR Handbook of Differential Diagnosis*. Washington, DC: American Psychiatric Publishing.
- Foa, E. B., Huppert, J. D., Leiberg, S. et al. (2002). The Obsessive-Compulsive Inventory: Development and validation of a short version. *Psychological Assessment*, 14(4), 485–496.
- Gierk, B., Kohlmann, S., Kroenke, K., Spangenberg, L., Zenger, M., Brähler, E. & Löwe, B. (2014). The Somatic Symptom Scale-8 (SSS-8): A brief measure of somatic symptom burden. *JAMA Internal Medicine*, 174(3), 399–407.
- Gómez-Benito, J., Guilera, G., Barrios, M. et al. (2018). Beyond diagnosis: The Core Sets for persons with schizophrenia based on the World Health Organization's International Classification of Functioning, Disability, and Health. *Disability and Rehabilitation*, 40(23), 2756–2766. DOI: 10.1080/09638288.2017.1356384.
- Gspandl, S., Peirson, R. P., Nahhas, R. W., Skale, T. G. & Lehrer, D. S. (2018). Comparing Global Assessment of Functioning (GAF) and World Health Organization Disability Assessment Schedule (WHODAS) 2.0 in schizophrenia. *Psychiatry Research*, 259, 251–253.
- Hevner, A. R., March, S. T., Park, J. & Ram, S. (2004). Design science in information systems research. *MIS Quarterly*, 28(1), 75–105.
- Insel, T., Cuthbert, B., Garvey, M. et al. (2010). Research Domain Criteria (RDoC): Toward a new classification framework for research on mental disorders. *American Journal of Psychiatry*, 167(7), 748–751.
- Ising, H. K., Veling, W., Loewy, R. L. et al. (2012). The validity of the 16-item version of the Prodromal Questionnaire (PQ-16) to screen for ultra high risk of developing psychosis. *Schizophrenia Research*, 138(2–3), 207–212.
- Keeley, J. W., Reed, G. M., Roberts, M. C. et al. (2016). Developing a science of clinical utility in diagnostic classification systems: Field study strategies for ICD-11 mental and behavioural disorders. *American Psychologist*, 71(1), 3–16.

- Kessler, R. C. & Üstün, T. B. (2004). The World Mental Health (WMH) Survey Initiative version of the World Health Organization (WHO) Composite International Diagnostic Interview (CIDI). *International Journal of Methods in Psychiatric Research*, 13(2), 93–121.
- Kessler, R. C., Adler, L., Ames, M. et al. (2005). The World Health Organization Adult ADHD Self-Report Scale (ASRS). *Psychological Medicine*, 35(2), 245–256.
- Kotov, R., Krueger, R. F., Watson, D. et al. (2017). The Hierarchical Taxonomy of Psychopathology (HiTOP): A dimensional alternative to traditional nosologies. *Journal of Abnormal Psychology*, 126(4), 454–477.
- Kotov, R., Krueger, R. F., Watson, D. et al. (2021). The Hierarchical Taxonomy of Psychopathology (HiTOP): A quantitative nosology based on consensus of evidence. *Annual Review of Clinical Psychology*, 17, 83–108.
- Kotov, R., Cicero, D. C., Conway, C. C. et al. (2022). The Hierarchical Taxonomy of Psychopathology (HiTOP) in psychiatric practice and research. *Psychological Medicine*, 52(9), 1666–1678. DOI: 10.1017/S0033291722001301.
- Kress, V. E., Barrio Minton, C. A., Adamson, N. A., Paylo, M. J. & Pope, V. (2014). The removal of the multi-axial system in the DSM-5: Implications and practice suggestions for counselors. *The Professional Counselor*, 4(3), 191–201.
- Krueger, R. F., Kotov, R., Watson, D. et al. (2018). Progress in achieving quantitative classification of psychopathology. *World Psychiatry*, 17(3), 282–293.
- Levis, B., Benedetti, A. & Thombs, B. D. (2019). Accuracy of Patient Health Questionnaire-9 (PHQ-9) for screening to detect major depression. *BMJ*, 365, 11476.
- Linden, M. & Baron, S. (2005). Das Mini-ICF-Rating für psychische Störungen (Mini-ICF-P): Ein Kurz-instrument zur Beurteilung von Fähigkeitsstörungen bei psychischen Erkrankungen. *Die Rehabilitation*, 44(3), 144–151. DOI: 10.1055/s-2004-834786.
- Luciano, J. V., Ayuso-Mateos, J. L., Aguado, J. et al. (2010). The 12-item World Health Organization Disability Assessment Schedule II (WHO-DAS II): A nonparametric item response analysis. *BMC Medical Research Methodology*, 10, 45.
- McGuffin, P., Farmer, A. & Harvey, I. (1991). A polydiagnostic application of operational criteria in studies of psychotic illness: Development and reliability of the OPCRIT system. *Archives of General Psychiatry*, 48(8), 764–770.
- Morgan, J. F., Reid, F. & Lacey, J. H. (1999). The SCOFF questionnaire: Assessment of a new screening tool for eating disorders. *BMJ*, 319(7223), 1467–1468.
- Morin, C. M., Belleville, G., Bélanger, L. & Ivers, H. (2011). The Insomnia Severity Index: Psychometric indicators to detect insomnia cases and evaluate treatment response. *Sleep*, 34(5), 601–608.
- Narrow, W. E., Clarke, D. E., Kuramoto, S. J. et al. (2013). DSM-5 field trials in the United States and Canada, Part III. *American Journal of Psychiatry*, 170(1), 71–82.

- Oltmanns, J. R. & Widiger, T. A. (2018). A self-report measure for the ICD-11 dimensional trait model proposal: The Personality Inventory for ICD-11. *Psychological Assessment*, 30(2), 154–169.
- Owen, G. (2023). What is formulation in psychiatry? *Psychological Medicine*, 53(5), 1700–1707. DOI: 10.1017/S0033291723000016.
- Peffers, K., Tuunanen, T., Rothenberger, M. A. & Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3), 45–77.
- Plana-Ripoll, O., Pedersen, C. B., Holtz, Y. et al. (2019). Exploring Comorbidity Within Mental Disorders Among a Danish National Population. *JAMA Psychiatry*, 76(3), 259–270.
- Posner, K., Brown, G. K., Stanley, B. et al. (2011). The Columbia-Suicide Severity Rating Scale (C-SSRS). *American Journal of Psychiatry*, 168(12), 1266–1277.
- Probst, B. (2014). The life and death of Axis IV: Caught in the quest for a theory of mental disorder. *Research on Social Work Practice*, 24(1), 123–131. DOI: 10.1177/1049731513491326.
- Regier, D. A., Narrow, W. E., Clarke, D. E. et al. (2013). DSM-5 field trials in the United States and Canada, Part II: Test-retest reliability of selected categorical diagnoses. *American Journal of Psychiatry*, 170(1), 59–70.
- Riegel, K. D., Ksinan, A. J. & Schlosserova, L. (2021). Psychometric properties of the independent 36-item PID5BF+M for ICD-11 in the Czech-speaking community sample. *Frontiers in Psychiatry*, 12, 643270. DOI: 10.3389/fpsyt.2021.643270.
- Rosenman, S. J., Korten, A. E., Medway, J. & Evans, M. (2003). Dimensional vs. categorical diagnosis in psychosis. *Acta Psychiatrica Scandinavica*, 107(5), 378–384.
- Saunders, J. B., Aasland, O. G., Babor, T. F. et al. (1993). Development of the Alcohol Use Disorders Identification Test (AUDIT). *Addiction*, 88(6), 791–804.
- Shrout, P. E. & Fleiss, J. L. (1979). Intraclass correlations: Uses in assessing rater reliability. *Psychological Bulletin*, 86(2), 420–428.
- Song, H., Kang, M., Shin, J. et al. (2026). MentalBench: A DSM-Grounded Benchmark for Evaluating Psychiatric Diagnostic Capability of Large Language Models. *arXiv preprint arXiv:2602.12871*. DOI: 10.48550/arXiv.2602.12871.
- Spitzer, R. L., Kroenke, K., Williams, J. B. W. & Löwe, B. (2006). A brief measure for assessing Generalized Anxiety Disorder: The GAD-7. *Archives of Internal Medicine*, 166(10), 1092–1097.
- Zimmermann, R., Konjufca, J., Sakejo, P. et al. (2023). Mental Health Information Reporting Assistant (MHIRA)—an open-source software facilitating evidence-based assessment for clinical services. *BMC Psychiatry*, 23, 706. DOI: 10.1186/s12888-023-05201-0.
- Wakefield, J. C. (1992). The concept of mental disorder: On the boundary between biological facts and social values. *American Psychologist*, 47(3), 373–388.

- World Health Organization (2010). *WHODAS 2.0: WHO Disability Assessment Schedule 2.0*. Geneva: WHO.
- World Health Organization (2019). *International Classification of Diseases, 11th Revision (ICD-11)*. Geneva: WHO.
- Williams, J. B. W. (1985). The multiaxial system of DSM-III: Where did it come from and where should it go? I. Its origins and critiques. *Archives of General Psychiatry*, 42(2), 175–180.
- Wing, J. K., Cooper, J. E. & Sartorius, N. (1974). *Measurement and Classification of Psychiatric Symptoms: An Instruction Manual for the PSE and CATEGO Program*. Cambridge: Cambridge University Press.